
Uso de inteligencias generativas para la ayuda a
la toma de decisiones en el ámbito médico.

Use of generative intelligence for
decision-making support in the medical field



Trabajo de Fin de Grado
Curso 2024–2025

Autor

Miguel Antonio Amato Hermo

Jorge Ortega Carretero

Director

Antonio Sarasa Cabezuelo

Javier Cambroneró Santos

Colaborador

Carlos Pascual Mateo

Grado en Ingeniería Informática

Facultad de Informática

Universidad Complutense de Madrid

Uso de inteligencias generativas para la
ayuda a la toma de decisiones en el ámbito
médico.

Use of generative intelligence for
decision-making support in the medical
field

Trabajo de Fin de Grado en Ingeniería Informática

Autor

Miguel Antonio Amato Hermo

Jorge Ortega Carretero

Director

Antonio Sarasa Cabezuelo

Javier Cambrono Santos

Colaborador

Carlos Pascual Mateo

Convocatoria: *Junio 2025*

Grado en Ingeniería Informática

Facultad de Informática

Universidad Complutense de Madrid

13 de Mayo de 2025

Dedicatoria

*A nuestro tutor por toda la ayuda y la
dedicación proporcionada durante la
realización del Trabajo de Fin de Grado. A
nuestras familias por el apoyo incondicional y
constante a lo largo de toda nuestra formación
Y de manera muy especial, a nuestros
compañeros de carrera, quienes con el tiempo
se han convertido en verdaderos amigos para
toda la vida...*

Agradecimientos

Agradecemos a Antonio Sarasa por su valiosa guía en el ámbito informático, a Javier por compartir su tesis como base del estudio y a Carlos por su apoyo en la validación biomédica y el análisis riguroso de los datos.

Miguel: Agradezco a cada una de las personas que me encontré en el camino durante mi carrera universitaria, mi yo de hace muchos años estaría orgulloso de a donde llegó pero, sobretodo, de la gente que me acompaña. Este trabajo es gracias a todos ustedes.

Jorge: Agradezco a todas las personas que han estado a mi lado durante esta etapa. A mis amigos y a mi familia, por su constante apoyo y ánimo. Muy especialmente, a mis padres, a mi pareja, Leire, y a mi mejor amigo, Christian, quienes han creído en mí en cada momento y me han transmitido el apoyo que necesitaba. Sin su ayuda, no hubiese sido capaz de llegar hasta aquí. Gracias.

Resumen

Uso de inteligencias generativas para la ayuda a la toma de decisiones en el ámbito médico.

Urolobot es una aplicación web desarrollada para asistir en la toma de decisiones del ámbito de la urología, concretamente en el estudio de análisis biomédicos de supervivencia.

La aplicación se centra principalmente en la generación de informes clínicos estadísticos a partir de una base de datos y un archivo maestro proporcionado por el propio usuario.

Además, cuenta con gestión de cuentas de usuario y un chat integrado en la aplicación que permite realizar consultas a ChatGPT.

Para el desarrollo de la aplicación se tomó un estudio real de biomedicina sobre la Recaída Bioquímica (RBQ) en pacientes con cáncer de próstata. Durante todo el desarrollo, junto con la ayuda de un experto en el campo, se contrastaron, discutieron y se revisaron los resultados para mantener la mayor precisión clínica posible y que el resultado de Urolobot sea una herramienta fiable para la toma de decisiones en trabajo de campo.

Palabras clave

Urología, Inteligencia Artificial, Análisis Estadísticos, Generación de Informes, ChatGPT, Modelos de Lenguaje de Gran Escala, Agentes LLM, Prompts, Ingeniería de prompts, Análisis biomédico, Análisis de supervivencia.

Abstract

Use of generative intelligence for decision-making support in the medical field

Urolobot is a web application developed to assist in decision-making within the field of urology, specifically focused on the analysis of biomedical survival data.

The application primarily enables the generation of clinical statistical reports based on a dataset and a master file provided by the user.

It also features user account management and an integrated chat system that allows users to consult ChatGPT directly within the platform.

For the development of the application, a real biomedical study on Biochemical Recurrence (BCR) in prostate cancer patients was used. Throughout the development process, the results were reviewed, discussed, and validated with the support of an expert in the field to ensure the highest possible clinical accuracy, making Urolobot a reliable tool for decision-making in clinical practice.

Keywords

Urology, Artificial Intelligence, Statistical Analysis, Report Generation, ChatGPT, Large Language Models, LLM Agents, Prompts, Prompt Engineering, Biomedical Analysis, Survival Analysis.

Índice

1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	2
1.3. Plan de trabajo	2
Introduction	5
1.4. Motivation	5
1.5. Goals	5
1.6. Work plan	6
2. Estado de la Cuestión	9
2.1. Inteligencia Artificial	9
2.2. Modelos de Lenguaje de Gran Escala (LLM)	9
2.2.1. Prompt	10
2.2.2. Prompt Engineering	11
2.2.3. Agente LLM	12
2.2.4. Características clave de un agente LLM	12
2.2.5. Aplicaciones en el ámbito médico	13
2.3. Análisis de supervivencia en el Ámbito biomédico	13
2.3.1. Análisis Descriptivo de la Población	13
2.3.2. Análisis Comparativo de las Variables con la Variable Objetivo	16
2.3.3. Conclusión y el Valor p	17
2.3.4. Análisis de supervivencia y predictores	17
2.4. Desafíos Enfrentados	20
3. Tecnologías Empleadas	23
3.1. Frontend	23
3.2. Backend	23
3.3. Módulo de IA	24
4. Arquitectura y Modelo de datos	25
4.1. Arquitectura	25

4.2. Modelo de Datos	26
5. Implementación de la Plataforma	29
5.1. Módulo Gestión de Usuarios:	29
5.2. Módulo Preparación y Procesamiento de los Datos:	33
5.3. Módulo Realización Análisis Estadísticos:	38
5.4. Módulo Generación de Informes Clínicos:	47
5.5. Módulo Desarrollo de Aplicación Web:	54
6. Resultados de la aplicación	73
6.0.1. Variables Numéricas:	73
6.0.2. Variables Categóricas:	74
6.0.3. Análisis comparativo con la variable objetivo.	76
6.0.4. Test Kaplan Meier General:	80
6.0.5. Test Kaplan Meier Estratificado:	81
7. Conclusiones y Trabajo Futuro	89
7.1. Conclusiones	89
7.2. Trabajo Futuro	89
7.2.1. Funcionalidades a implementar en un futuro	90
Conclusions and Future Work	93
7.3. Conclusions	93
7.4. Future Work	93
7.4.1. Functionalities to be developed in the future	93
Contribuciones Personales	97
Bibliografía	103
A. Casos de Uso	105
B. Manual de Instalación del Proyecto:	121
C. Manual de Usuario:	125
C.1. Autenticación	125
C.2. Página Principal	126
C.3. Gestión de Cuenta de Usuario	137
D. Documento Generado	139
D.1. Ejemplo de reporte generado por Urolobot.	139

Índice de figuras

2.1. Iteración de un prompt y los pasos a seguir según OpenAI y DeepLearning AI	12
2.2. Cálculo media aritmética	14
2.3. Cálculo desviación estándar	15
2.4. Cálculo calculo de la frecuencia absoluta	15
2.5. Cálculo calculo de intervalo de confianza	15
2.6. t de Student clásica	16
2.7. Fórmula del estadístico U	16
2.8. Fórmula del estadístico Chi^2	17
2.9. Fórmula de la probabilidad exacta	17
2.10. Curva resultante del evento RBQ en la tesis de Javier Cambronero . .	19
4.1. Arquitectura de la Aplicación	25
4.2. Diagrama ER Base de Datos	27
5.1. Inicio de Sesión	30
5.2. Registro Nueva Cuenta	30
5.3. Petición HTTP vía API	31
5.4. Añadir Usuario a Base de Datos	31
5.5. Código Guardar Información Usuario	32
5.6. Código Eliminar Usuario	32
5.7. Código Actualizar Contraseña	32
5.8. Prompt Identificar Variable de Grupo	34
5.9. Prompt categorización de variables	35
5.10. Procesado de datos variables numéricas	36
5.11. Prompt identificar variable de tiempo	37
5.12. Procesar datos de variables comparativas	38
5.13. Código prueba chi cuadrado	39
5.14. Código prueba de fisher	40
5.15. Código prueba t student	41
5.16. Código prueba de Mann Whitney bilateral	43
5.17. Código Obtención Variables Significativas	44
5.18. Código Curvas de Supervivencia con Kaplan Meier	44

5.19. CSV Resultados de la prueba Log-Rank	45
5.20. Código Análisis Variables con Cox Univariante	46
5.21. Código Orquestador para la generación de informes	47
5.22. Agentes Generación Documento	48
5.23. Prompt Contexto para la llamada al modelo	48
5.24. Código Llamada al modelo de conclusiones sobre el dataset	49
5.25. Prompt Conclusiones Kaplan Meier General	54
5.26. Página de Inicio de Sesión	54
5.27. Iniciar Sesión Usuario	55
5.28. Página de Registro de Nuevo Usuario	55
5.29. Página de Bienvenida Urolobot	56
5.30. Obtener información del usuario activo.	57
5.31. Información de la cuenta del usuario	57
5.32. Restaurar Contraseña	58
5.33. Chat con Asistente IA GPT-4o-mini	58
5.34. Código Envío consulta de usuario a API de OpenAI	59
5.35. Subida y Preparación de los datos	60
5.36. Alerta datos preparados	60
5.37. Variable objetivo identificada	60
5.38. Categorización variables	61
5.39. Obtención de Media y Desviación Típica para Visualización	63
5.40. Tabla y Gráficos Desviación Típica en React	63
5.41. Visualización Gráficos Mediana	63
5.42. Visualización Gráfica Frecuencias Absolutas	64
5.43. Visualización Gráfica Intervalos de Confianza 95 %	64
5.44. Código Mostrar y Confirmar Variable de Tiempo	65
5.45. Gráfica P-Valor Chi^2	66
5.46. Código Tabla de Análisis <i>Fisher</i> con React	67
5.47. Visualización Análisis Supervivencia General Kaplan Meier	68
5.48. Código Tabla y Curva de Supervivencia de una Variable	69
5.49. Visualización Análisis Supervivencia Estratificado de gleason2	69
5.50. Gráficas Análisis de Supervivencia con Modelo de regresión Cox Uni- variante	70
5.51. Código Generar archivo zip	71
6.1. Análisis descriptivo de las variables numéricas	73
6.2. Análisis descriptivo de variables numéricas Experto	74
6.3. Comparación Análisis descriptivo de variables categóricas IA	74
6.4. Comparación Análisis descriptivo de variables categóricas Experto	75
6.5. Comparación Análisis descriptivo de variables categóricas IA 2	75
6.6. Comparación Análisis descriptivo de variables categóricas Experto 2	76
6.7. Comparación Análisis comparativo con Chi^2 IA	78
6.8. Comparación Análisis comparativo con Chi^2 Experto	79
6.9. Comparación Análisis comparativo con <i>MannWhitney</i> IA	80

6.10. Comparación Análisis comparativo con <i>MannWhitney</i> Experto . . .	80
6.11. Curva Supervivencia Kaplan Meier general IA	81
6.12. Curva Supervivencia Kaplan Meier general Experto	81
6.13. Curvas Supervivencia Kaplan Meier estratificadas IA	83
6.14. Curvas Supervivencia Kaplan Meier estratificadas IA 2	84
6.15. Curvas Supervivencia Kaplan Meier estratificadas Experto	85
6.16. Curvas Supervivencia Kaplan Meier estratificadas Experto 2	86
6.17. Modelo de Regresión de Cox Univariante IA	87
6.18. Modelo de Regresión de Cox Univariante Experto	87
 B.1. User Database	 122
B.2. User Group Database	122
B.3. User Meta Database	123
 C.1. Manual: Formulario Inicio de Sesión	 125
C.2. Manual: Formulario Registrar Nuevo Usuario	126
C.3. Manual: Página de Bienvenida	126
C.4. Manual: Chat con Asistente Inteligencia Artificial	127
C.5. Manual: Cargar BBDD y Archivo Maestro	127
C.6. Manual: Preparar los datos subidos para los análisis	128
C.7. Manual: Identificación Variable de Grupo	128
C.8. Manual: Confirmar variable de Grupo y Categorizar las Variables . .	129
C.9. Manual: Procesar datos para análisis descriptivos	129
C.10. Manual: Procesamiento de datos para análisis descriptivos completado	129
C.11. Manual: Tabla Análisis Media de Variables Numéricas	130
C.12. Manual: Gráficos Análisis Desviación Típica de Variables Numéricas .	130
C.13. Manual: Tabla de Frecuencias Absolutas para Variables Categóricas .	131
C.14. Manual: Gráfica de Frecuencias Absolutas para Variables Categóricas	131
C.15. Manual: Tabla de Intervalos de Confianza al 95 % para Variables Ca- tegóricas	131
C.16. Manual: Gráfica de Intervalos de Confianza al 95 % para Variables Categóricas	132
C.17. Manual: Identificar Variable de Tiempo	132
C.18. Manual: Confirmar Variable de Tiempo	132
C.19. Manual: Procesar datos para análisis comparativos	133
C.20. Manual: Datos para análisis comparativos procesados	133
C.21. Manual: Gráfica pValores de las variables con Chi^2	134
C.22. Manual: Tabla de resultados con <i>MannWhitney</i>	134
C.23. Manual: Tabla de Variables Significativas	134
C.24. Manual: Gráfica de pValores Variables Significativas	135
C.25. Manual: Visualización Análisis de Supervivencia según la variable de grupo (Kaplan Meier)	135
C.26. Manual: Análisis de Supervivencia Estratificado en función de cada variable (Kaplan Meier)	136

C.27.Manual: Tabla Análisis con Modelo de Regresión de Cox Univariante	136
C.28.Manual: Gráficos Análisis con Modelo de Regresión de Cox Univariante	136
C.29.Manual: Generar Informe y descargar archivos generados	137
C.30.Manual: Menú de Gestión de Cuenta de Usuario	137
C.31.Manual: Modificar información de la cuenta del usuario	138
C.32.Manual: Restaurar contraseña de la cuenta del usuario	138

Índice de tablas

A.1. Requisito para Registrar Usuario	106
A.2. Requisito de Login	107
A.3. Requisito para Restaurar Contraseña	108
A.4. Requisito para Logout	109
A.5. Requisito para Modificar Usuario	110
A.6. Requisito para Dar de Baja a un Usuario	111
A.7. Requisito para Consultar a la IA mediante el Chat	112
A.8. Requisito para Añadir Base de Datos y Archivo Maestro	113
A.9. Requisito para Identificar Variable Objetivo y Categorizar Variables .	114
A.10.Requisito para Análisis Estadísticos de Variables Descriptivas	115
A.11.Requisito para Identificar Variable de Tiempo	116
A.12.Requisito para Análisis Estadísticos de Variables Comparativas	117
A.13.Requisito para Abrir Documento Generado	118
A.14.Requisito para Descargar Documentos del Proceso de Generación de Documento	119

Introducción

En los últimos años, el uso de la inteligencia artificial ha experimentado un crecimiento enorme en muchos sectores, uno de los ámbitos donde más impacto esta teniendo es en el ámbito de la medicina. Avances en apoyo de diagnósticos, gestión de datos clínicos, detección de enfermedades... Cada vez avanzan más estas herramientas, que permiten mejorar la eficiencia, la precisión y la toma de decisiones.

Nuestro Trabajo de Fin de Grado tiene como objetivo el desarrollo de otra herramienta mediante una aplicación web para facilitar su uso a los usuarios, capaz de generar de manera automatizada informes científicos a partir de datos clínicos proporcionados por el usuario. La herramienta es capaz de realizar análisis estadísticos y generar conclusiones sobre los resultados mediante el uso de un modelo de procesamiento de lenguaje natural de OpenAI, en concreto el modelo GPT-4o-mini. Esto permite a los profesionales sanitarios interesados en el campo de la investigación, obtener resultados precisos, de manera eficiente y rápida sin necesidad de tener grandes conocimientos tecnológicos.

Además, antes de la generación del informe con las conclusiones finales, la herramienta permite visualizar los resultados poco a poco obtenidos por el modelo y volver atrás si en alguna ocasión el usuario considera que los resultados no son correctos o modificar las variables decididas para realizar el estudio (variable objetivo y variable de tiempo). Así, el profesional no tiene que esperar a recibir el documento generado en caso de no convencerlo los resultados obtenidos.

1.1. Motivación

En un momento en el que la tecnología avanza a gran velocidad, especialmente en el ámbito de la inteligencia artificial, decidimos comprobar hasta donde es capaz de llegar en la generación de informes clínicos estadísticos y en las conclusiones que es capaz de obtener basándose en datos reales, comparándolas con las obtenidas por un experto en este campo en su tesis doctoral. Todo ello con el objetivo de conocer el alcance que podría llegar a tener en un futuro.

1.2. Objetivos

Objetivo general: Este proyecto tiene como objetivo proporcionar una herramienta basada en inteligencia artificial, capaz de generar informes clínicos basándose en datos reales mediante análisis estadísticos. Y comparar los resultados con los obtenidos por un experto en su tesis doctoral.

Objetivos específicos:

1. **Detección de necesidades médicas:** Contacto con expertos en medicina para identificar las necesidades de apoyo en el ámbito clínico que podrían ser realizadas con el uso de inteligencia artificial, para decidir el enfoque de la herramienta.
2. **Especificación de requisitos del proyecto:** Realización de un documento especificando los requisitos de la aplicación.
3. **Recopilación de datos y documentación:** Obtención de la base de datos médica y búsqueda de documentación sobre el uso de las inteligencias artificiales en la generación de informes clínicos.
4. **Preparación y procesamiento de datos:** Limpieza y estructuración de los datos proporcionados por los médicos, identificación de variables relevantes, categorización de las variables en función de la variable de grupo y procesamiento del conjunto de datos para su buen funcionamiento con el modelo de ChatGPT.
5. **Realización de análisis estadísticos:** Aplicación de técnicas de análisis estadístico sobre los datos clínicos para obtener resultados fiables.
6. **Generación de informes clínicos:** Elaboración de informes clínicos basados en los análisis estadísticos realizados.
7. **Desarrollo de Aplicación Web:** Creación de una aplicación web con gestión de usuarios, integración de un chat básico mediante llamadas a la API de OpenAI y generador de informes clínicos basados en análisis estadísticos de datos reales.
8. **Validación de resultados:** Comparación de los informes generados con los resultados obtenidos por un experto en su tesis doctoral, para evaluar la precisión y fiabilidad de la herramienta.

1.3. Plan de trabajo

Basándonos en los objetivos descritos en el anterior apartado, podemos distinguir las diferentes fases de realización del proyecto:

- **Fase 1: - Detección de necesidades médicas:** Realización de varias reuniones con nuestro tutor y dos expertos en el campo de la urología para decidir el

enfoque que le íbamos a dar a nuestra herramienta de apoyo con inteligencia artificial en el ámbito médico.

- **Fase 2: - Especificación de requisitos del proyecto:** Elaboración de un documento especificando los distintos requisitos de la aplicación. Diferenciando tres secciones:
 - Gestión de Cuentas de Usuario
 - Uso de la inteligencia generativa
 - Administración y gestión de pacientes (No realizado por cambio de enfoque) TODO
- **Fase 3: - Recopilación de datos y documentación:** Investigación sobre el uso de la inteligencia artificial en la generación de informes médicos, comparaciones de redacción entre un humano y un modelo LLM e información sobre la capacidad de la IA para la realización de análisis estadísticos. Además, solicitamos a uno de los expertos la base de datos y el archivo maestro donde estuviesen las descripciones y posibles valores de cada variable con las que se había realizado la tesis doctoral.
- **Fase 4: - Preparación y procesamiento de datos:** Se desarrollaron varios agentes especializados, cada uno encargado de una tarea concreta dentro del tratamiento de los datos clínicos:
 - Un agente encargado de la funcionalidad de preparar los datos de la base de datos obtenida en la fase anterior, realizando una limpieza y estructuración de la misma y guardando el archivo maestro para su posterior uso.
 - Un agente encargado de la identificación de la variable de grupo.
 - Un agente encargado de categorizar las variables en función de la variable de grupo.
 - Un agente encargado del procesamiento de los datos de las variables descriptivas.
 - Un agente encargado de la identificación de la variable de tiempo.
 - Un agente encargado del procesamiento de las variables comparativas en función de la variable de tiempo.
- **Fase 5: - Realización de análisis estadísticos:** Se han desarrollado varios agentes encargados de aplicar técnicas de análisis estadístico sobre los datos clínicos y almacenar los resultados en archivos CSV y en algunos casos, gráficas basadas en los resultados obtenidos.
- **Fase 6: - Generación de informes clínicos:** Se han desarrollado varios agentes encargados de realizar las conclusiones basándose en los análisis estadísticos y de generar un código en LaTeX para generar el documento posteriormente. Una vez están todas las conclusiones generadas en LaTeX se ha empleado un compilador de LaTeX para crear el documento PDF.

- **Fase 7: - Desarrollo de Aplicación Web:** Se ha desarrollado una aplicación web que incorpora funcionalidades de gestión de usuarios, como Registrarse", Iniciar sesión", Cambio de contraseñas Cambio de nombre de usuario". Además, se ha integrado un chat básico con ChatGPT mediante llamadas a la API de OpenAI, así como un generador de informes clínicos. La aplicación permite al usuario cargar tanto el archivo maestro como la base de datos sobre los que desea realizar el análisis, identificar las variables relevantes (grupo y tiempo) y, en caso necesario, modificar la selección propuesta por el modelo. También se encarga de procesar los datos descriptivos y comparativos y obteniendo así los resultados estadísticos a través de tablas y gráficos para cada apartado. Finalmente permite ver el documento generado y descargar todos los análisis realizados durante el proceso.
- **Fase 8: - Validación de resultados:** Se han comparado los resultados obtenidos con los resultados obtenidos por uno de los expertos cuando realizó su tesis doctoral. Además, otro de los expertos ha realizado la comparación de los resultados de la herramienta con los resultados que debería obtener para una mayor fiabilidad.
- **Fase 9 - Memoria del proyecto:** Realización de la memoria del proyecto.

Introduction

In recent years, AI has experienced an important growth in different sectors, one of the areas where it is having more impact is in the medical field. There have been advances in diagnosis support, clinical data management, disease detection... These tools are becoming more and more advanced, improving efficiency, precision and decision making.

Our TFG aims to develop another tool using a web application to facilitate its use to users, which is able to automatically generate clinical reports from data provided by the user. The tool is able to do statistical analysis and generate conclusions on the results by using an OpenAI natural language processing model, specifically the GPT-4o-mini model. This allows healthcare professionals interested in the research field to obtain accurate results efficiently and quickly without the need of having extensive technological knowledge.

In addition, before the clinical report is generated, the tool allows to visualize the results obtained by the model and go back if the user considers that the results may not be correct or to modify the variables decided to make the study (target variable and time variable). In this way, the professional does not have to wait to receive the generated document if he is not convinced by the results obtained.

1.4. Motivation

With technology in constant transformation, especially in the field of artificial intelligence, we decided to check how capable it is of generating statistical clinical reports and the conclusions it is able to obtain, comparing them with those obtained by an expert in medical field in his doctoral thesis. All this with the aim of knowing how far it could go in the future.

1.5. Goals

Main objective: This project has the objective of providing a tool based on artificial intelligence, capable of generating clinical reports based on conclusions obtained by statistical analysis of real data; and compare the results with those obtained by an expert in his doctoral thesis.

Specific objectives:

1. **Detection of medical needs:** We contacted medical experts to identify the needs for medical support that could be realized with the use of artificial intelligence, to decide the best option for the tool. .
2. **Specification of project requirements:** We create a document specifying the requirements of the application.
3. **Data collection and documentation:** Obtaining the medical database and searching for documentation about the use of artificial intelligences in clinical report generation .
4. **Data preparation and processing:** Preparing and structuring of the data provided by the doctors, identification of relevant variables, categorization of the variables according to the group variable and processing the dataset.
5. **Statistical analysis:** Aplicación de técnicas de análisis estadístico sobre los datos clínicos para obtener resultados fiables.
6. **Clinical reports generation:** Application of statistical analysis techniques on clinical data to obtain accurate results.
7. **Web Application development:** Creation of a web application with user management, integration of a basic chat using the OpenAI API and generation of clinical reports based on statistical analysis results
8. **Results validation:** Comparing the reports generated with the results obtained by an expert in his doctoral thesis, to evaluate the accuracy of the tool.

1.6. Work plan

Based on the described objectives in the previous section, we can distinguish the different phases of project implementation:

- **Phase 1: - Detection of medical needs:** Having meetings with our mentor and two experts in the field of urology to decide the direction we were going to give to our artificial intelligence support tool in the medical field.
- **Phase 2: - Specification of project requirements:** Preparing a document specifying the different requirements of the application. Distinguishing three sections:
 - User Account Management
 - Use of generative intelligence

- **Phase 3: - Data collection and documentation:** Research on the use of artificial intelligence in the generation of medical reports, writing comparisons between a human and a LLM model, the ability of AI to perform statistical analysis. In addition, we asked the experts for the database and the master file containing the descriptions and possible values of each variable used in the doctoral thesis.
- **Phase 4: - Data preparation and processing:** Different specialized agents were developed, each one responsible for a specific task in the processing of the clinical data:
 - An agent responsible of the functionality of preparing the data from the database, cleaning and structuring it and saving the master file for its later use.
 - An agent responsible of the functionality of identifying the group variable.
 - An agent responsible of the functionality of categorize the variables according to the group variable.
 - An agent responsible of the functionality of processing the data of the descriptive variables.
 - An agent responsible of the functionality of identifying the time variable.
 - An agent responsible of the functionality of processing the comparative variables according to the group and time variables.
- **Phase 5: - Statistical analysis:** Different agents have been developed to apply statistical analysis to the clinical data and store the results in CSV files, and also in some cases graphs based on the results obtained.
- **Phase 6: - Clinical reports generation:** Different agents have been developed to make the conclusions based on the statistical analysis and to generate a LaTeX code to generate the document. Once all the conclusions are generated in LaTeX, a LaTeX compiler has been used to create the pdf document.
- **Phase 7: - Web Application development :** A web application has been developed that incorporates user management functionalities, such as "Register", "Login", "Change password" and "Change user name". In addition, a basic chat has been integrated with OpenAI API calls, and a clinical report generator.

The application allows the user to load the master file and the database, identify the relevant variables (group and time) and, if necessary, modify the variables selected by the model. It is also responsible for processing the descriptive and comparative data and obtaining the statistical results through tables and graphs for each section.

Finally, it allows you to view the generated document and download all the analysis done during the process.

- **Phase 8: - Results validation:** The results obtained have been compared with the results obtained by one of the experts when he did his doctoral thesis. In addition, another of the experts compared the results of the tool with the results that should be obtained.
- **Phase 9: - Project report :** Preparation of the project report.

Capítulo 2

Estado de la Cuestión

En este capítulo tiene como objeto ofrecer una visión sobre los temas abordados en el proyecto. Se verá en qué punto parte la investigación, se verán cuáles son los términos clave relacionados con el proyecto, los avances realizados y los desafíos encontrados durante el desarrollo.

2.1. Inteligencia Artificial

La **inteligencia artificial (IA)** puede definirse como el conjunto de tecnologías capaces de realizar tareas que normalmente requieren inteligencia humana, tales como el razonamiento, el aprendizaje, la percepción o la generación de lenguaje natural. No obstante, desde una perspectiva institucional y ética, como la adoptada por el gobierno de los Estados Unidos en su *Orden Ejecutiva 13960* (Executive Office of the President, 2020), la IA no se entiende únicamente como una capacidad técnica, sino como una herramienta que debe desarrollarse y aplicarse conforme a principios de confianza, legalidad, transparencia, responsabilidad y respeto por los derechos fundamentales.

En este sentido, una IA es considerada “fiable” cuando sus operaciones son comprensibles, seguras y trazables, y cuando está diseñada para maximizar beneficios sociales, al tiempo que minimiza riesgos, respetando los valores democráticos y las leyes aplicables. Este enfoque no solo garantiza una implementación más ética y responsable, sino que también refuerza la aceptación y eficacia de la IA en entornos críticos como la medicina, donde la precisión, la explicabilidad y la confianza son factores clave.

2.2. Modelos de Lenguaje de Gran Escala (LLM)

Los **Modelos de Lenguaje de Gran Escala** (*Large Language Models*, LLM) son sistemas de inteligencia artificial diseñados para procesar y generar texto en lenguaje natural. Estos modelos se entrenan utilizando técnicas de aprendizaje profundo sobre vastas cantidades de datos textuales, como libros, artículos y páginas

web, lo que les permite aprender patrones y reglas del lenguaje (Amazon Web Services, 2023).

OpenAI describe los LLM como funciones que transforman texto en texto, prediciendo la siguiente palabra en una secuencia dada. A través del entrenamiento para minimizar el error de predicción en grandes volúmenes de texto, estos modelos adquieren conceptos útiles para realizar tareas como ortografía, gramática, parafraseo, respuesta a preguntas, conversación, escritura en múltiples idiomas y programación (OpenAI, 2023).

En los últimos años, el uso de modelos de lenguaje natural de gran escala (LLM) ha avanzado significativamente en su aplicación al ámbito médico. Un ejemplo paradigmático es GPT-4, que ha demostrado un rendimiento sobresaliente en tareas clínicas complejas, como el examen de licencia médica estadounidense (USMLE), superando ampliamente el umbral de aprobación sin necesidad de ajustes específicos en sus instrucciones iniciales (Nori et al., 2023). Además, destaca por su capacidad de calibrar adecuadamente la probabilidad de acierto de sus respuestas, una característica crucial en contextos clínicos donde el margen de error debe ser mínimo.

En comparación con versiones anteriores y con modelos especializados como Med-PaLM, GPT-4 ha mostrado un razonamiento médico más avanzado y la habilidad de justificar sus decisiones de forma personalizada, incluso generando escenarios contra factuales. Estos hallazgos consolidan el potencial de los LLM como herramientas clínicas de apoyo. En esta línea, el presente trabajo propone **Urolobot**, una plataforma que combina análisis estadísticos clásicos con inteligencia generativa, orientada a facilitar una toma de decisiones fiable y basada en evidencias en el campo de la urología.

Para poder entender bien el trabajo realizado, aquí se explicarán los conceptos clave sobre los LLM:

2.2.1. Prompt

Un **prompt** es una instrucción en lenguaje natural que describe la tarea que un modelo de inteligencia artificial debe realizar. En el contexto de los modelos de lenguaje de gran escala (LLM), un prompt puede ser una pregunta, un comando o una declaración que guía al modelo para generar la respuesta deseada (DeepLearning.AI, 2023).

Los prompts son esenciales para poder trabajar con LLM, ya que con ellos se les dota de información y contexto para que realicen la tarea que quieres. Hay que tener en cuenta que un prompt el humano no lo entiende de la misma forma que lo entiende un LLM, ya que en lugar de comprender el significado de las palabras tanto semántico como sintáctico, los LLM buscan patrones en los datos del texto con el que se haya sido entrenado previamente para generar una respuesta con ese patrón.

En el caso de nuestro proyecto, uno de los mayores desafíos que tuvimos fue dotar de la información que necesitábamos al modelo de lenguaje para que lograra dar con los mejores resultados y, también, saber qué tareas tenían que ser delegadas a un LLM y cuáles no por su complejidad computacional. Para esto nos encontramos con un conocimiento muy útil llamado "Prompt Engineering".

2.2.2. Prompt Engineering

La *ingeniería de prompts* es el proceso de estructurar o redactar estas instrucciones de manera efectiva para obtener los mejores resultados posibles de un modelo de IA generativa. Esta práctica implica formular comandos claros y contextuales, proporcionando al modelo la información necesaria para generar respuestas precisas y relevantes (DeepLearning.AI, 2023).

Según Andrew NG en su curso elaborado con desarrolladores de OpenAI, existen dos principios fundamentales para redactar prompts efectivos al interactuar con modelos LLM:

1. **Escribir instrucciones claras y específicas:** Es esencial proporcionar instrucciones detalladas y precisas al modelo. Claridad no significa brevedad; en muchos casos, un prompt más extenso que incluye contexto adicional puede guiar al modelo hacia respuestas más relevantes y precisas.
2. **Dar al modelo tiempo para "pensar":** Instruir al modelo para que razone paso a paso puede mejorar la calidad de las respuestas, especialmente en tareas complejas. Esta técnica, conocida como *chain-of-thought prompting*, fomenta un proceso de razonamiento más estructurado por parte del modelo.

Además de estos principios, el curso destaca la importancia de la iteración en el desarrollo de prompts. Refinar y ajustar los prompts basándose en los resultados obtenidos es crucial para mejorar la interacción con los LLM.

Basándonos en esos dos principios, busquemos que en nuestro proyecto los prompts sigan las mejores prácticas para obtener así los mejores resultados posibles.




Figura 2.1: Iteración de un prompt y los pasos a seguir según OpenAI y DeepLearning AI

2.2.3. Agente LLM

Un **agente LLM** es un sistema que utiliza un modelo de lenguaje de gran escala (LLM) para ejecutar tareas de forma autónoma en nombre del usuario. Un agente es un sistema que puede realizar tareas de manera independiente, gestionando la ejecución de flujos de trabajo y tomando decisiones basadas en el contexto. Estos agentes son capaces de reconocer cuándo un flujo de trabajo está completo y pueden corregir proactivamente sus acciones si es necesario. En caso de fallo, pueden detener la ejecución y transferir el control de vuelta al usuario (OpenAI, 2025).

2.2.4. Características clave de un agente LLM

- **Gestión de flujos de trabajo:** Utiliza un modelo de lenguaje para gestionar la ejecución de tareas y tomar decisiones.
- **Acceso a herramientas:** Puede interactuar con sistemas externos para recopilar contexto y realizar acciones, seleccionando dinámicamente las herramientas apropiadas según la necesidad.

- **Autonomía:** Capacidad para ejecutar tareas sin supervisión constante, adaptándose a cambios y corrigiendo errores de forma proactiva.

2.2.5. Aplicaciones en el ámbito médico

En el contexto de este trabajo, los agentes LLM se pueden aplicar para:

- **Análisis de datos clínicos:** Interpretar resultados de pruebas médicas y datos de pacientes para decidir que tipos de análisis estadísticos pueden hacerse según las variables objetivo.
- **Generación de informes:** Redactar informes médicos personalizados basados en los datos de los pacientes relacionados con la variable de estudio, llegando a dar predictores de la misma.
- **Asistencia en la toma de decisiones:** Proporcionar recomendaciones basadas en evidencia para apoyar a los profesionales de la salud.

2.3. Análisis de supervivencia en el Ámbito biomédico

Ya dejando atrás el tema computacional de la aplicación, la parte más importante junto con los LLM es el estudio biomédico que se tiene que desarrollar.

El **análisis de supervivencia** es un conjunto de métodos estadísticos diseñados para estudiar el tiempo que transcurre hasta que ocurre un evento de interés, como la muerte, la recaída de una enfermedad o la aparición de una complicación médica. Este tipo de análisis es especialmente relevante en estudios clínicos y epidemiológicos, donde es común que algunos participantes no experimenten el evento durante el período de seguimiento, lo que genera datos censurados (Rebasa, 2005).

Las herramientas más utilizadas en este tipo de análisis incluyen:

- **Curvas de Kaplan-Meier:** permiten estimar la función de supervivencia a lo largo del tiempo.
- **Modelos de riesgos proporcionales de Cox:** evalúan el efecto de variables explicativas sobre el riesgo de ocurrencia del evento.

Estas técnicas permiten, por ejemplo, comparar la eficacia de diferentes tratamientos o identificar factores de riesgo asociados a una menor supervivencia (sem, 2023).

Para un análisis biomédico tradicional se siguen una serie de pasos:

2.3.1. Análisis Descriptivo de la Población

El **análisis descriptivo** es una fase fundamental en la investigación biomédica que permite resumir y comprender las características de una población estudiada.

Este análisis incluye la identificación del tipo de variables, su distribución y la aplicación de medidas estadísticas adecuadas para cada caso (Servicio Gallego de Salud, 2014).

Identificación de las características de las variables

Las variables se clasifican según su naturaleza en:

- **Variables numéricas:** Representan cantidades y pueden ser:
 - **Continuas:** Pueden tomar cualquier valor dentro de un rango, como la altura o el peso.
 - **Discretas:** Toman valores específicos y separados, como el número de hijos o de células (Minitab Support, 2023).
- **Variables categóricas:** Representan cualidades o categorías y se subdividen en:
 - **Nominales:** No tienen un orden intrínseco, como el grupo sanguíneo.
 - **Ordinales:** Tienen un orden lógico, como el estadio de una enfermedad (Minitab Support, 2023).

Determinar si una variable sigue una distribución normal es esencial para seleccionar las pruebas estadísticas adecuadas. Para ello, se utilizan pruebas como Shapiro-Wilk o Kolmogorov-Smirnov (Shapiro y Wilk, 1965).

Análisis de variables numéricas

Variables numéricas continuas

Para estas variables, se aplican medidas de tendencia central y dispersión:

- **Media aritmética:** Promedio de los valores.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Figura 2.2: Cálculo media aritmética

- **Mediana:** Valor central cuando los datos están ordenados.
- **Desviación estándar:** Medida de la dispersión de los datos respecto a la media.

$$\sigma = \sqrt{\frac{\sum (x_i - \mu)^2}{N}}$$

Figura 2.3: Cálculo desviación estándar

- **Rango intercuartílico:** Diferencia entre el tercer y primer cuartil (Servicio Gallego de Salud, 2014).

Variables numéricas discretas

Se utilizan frecuencias absolutas y relativas, así como medidas de tendencia central y dispersiones similares a las de las variables continuas, adaptadas al carácter discreto de los datos.

Análisis de variables categóricas

Para estas variables, se aplican medidas como:

- **Frecuencia absoluta:** Cuantas veces aparece un valor categórico.

$$f_i = \sum_{j=1}^n I(x_j = x_i)$$

Figura 2.4: Cálculo de la frecuencia absoluta

- **Intervalos de confianza:** Un intervalo dentro del cual se estima, con un determinado nivel de confianza, que estará el valor de cierto parámetro poblacional desconocido.

$$p \pm Z_{0.95} \sqrt{\frac{p(1-p)}{N}}$$

Figura 2.5: Cálculo de intervalo de confianza

Finalidad del análisis descriptivo

El objetivo principal del análisis descriptivo es proporcionar una visión clara y concisa de los datos, permitiendo:

- Identificar patrones y tendencias.
- Detectar valores atípicos o errores en los datos.
- Seleccionar las pruebas estadísticas adecuadas para análisis posteriores.
- Facilitar la interpretación y comunicación de los resultados (Servicio Gallego de Salud, 2014).

2.3.2. Análisis Comparativo de las Variables con la Variable Objetivo

En estudios biomédicos, es fundamental analizar la relación entre variables independientes y la variable objetivo. Dependiendo del tipo de variables y la distribución de los datos, se emplean diferentes pruebas estadísticas. A continuación, se describen las pruebas más comúnmente utilizadas:

Prueba t de Student

La prueba t de Student se utiliza para comparar las medias de una variable continua entre dos grupos independientes. Es aplicable cuando los datos siguen una distribución normal y las varianzas son homogéneas. Esta prueba permite determinar si existe una diferencia significativa entre las medias de los dos grupos (JMP, 2023).

$$t = \frac{\bar{X}_1 - \bar{X}_2}{s_p \cdot \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$$

Figura 2.6: t de Student clásica

Prueba U de Mann-Whitney

La prueba U de Mann-Whitney es una prueba no paramétrica que compara las medianas de dos grupos independientes. Se emplea cuando los datos no cumplen con los supuestos de normalidad. Esta prueba evalúa si las distribuciones de los dos grupos son diferentes (QuestionPro, 2022).

$$U = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1$$

$$U = n_1 n_2 + \frac{n_2(n_2 + 1)}{2} - R_2$$

Figura 2.7: Fórmula del estadístico U

Prueba de Chi-Cuadrado

La prueba de chi-cuadrado se utiliza para evaluar la asociación entre dos variables categóricas. Compara las frecuencias observadas con las esperadas bajo la hipótesis de independencia. Es adecuada cuando las frecuencias esperadas en cada celda de la tabla de contingencia son mayores de 5 (Medwave, 2010).

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

Figura 2.8: Fórmula del estadístico χ^2

Prueba Exacta de Fisher

La prueba exacta de Fisher se aplica cuando se analizan dos variables categóricas en tablas de contingencia 2x2, especialmente cuando las frecuencias esperadas son pequeñas. Calcula la probabilidad exacta de observar los datos bajo la hipótesis nula de independencia (Fisterra, 2023).

$$p = \frac{(a+b)!(c+d)!(a+c)!(b+d)!}{a!b!c!d!n!}$$

Figura 2.9: Fórmula de la probabilidad exacta

2.3.3. Conclusión y el Valor p

Los análisis comparativos entre variables independientes y la variable objetivo permiten identificar asociaciones significativas que pueden ser relevantes en contextos clínicos y de investigación. Aplicando pruebas estadísticas adecuadas, como la t de Student, U de Mann-Whitney, chi-cuadrado o el test exacto de Fisher, se puede determinar si las diferencias observadas entre grupos son estadísticamente significativas o podrían atribuirse al azar.

Un elemento central en estos análisis es el **valor p**, que representa la probabilidad de obtener un resultado igual o más extremo que el observado, asumiendo que la hipótesis nula es cierta. Un valor p bajo indica que es poco probable que las diferencias observadas se deban al azar, lo que proporciona evidencia para rechazar la hipótesis nula en favor de la alternativa (González y Pérez, 2021; Shreffler y Huecker, 2023).

Es importante destacar que un valor p estadísticamente significativo no implica necesariamente una relevancia clínica. Por ello, se recomienda complementar el valor p con medidas de efecto y considerar el contexto clínico al interpretar los resultados (López y Martínez, 2024).

2.3.4. Análisis de supervivencia y predictores

Una vez se obtienen todos los valores P de las variables con las que se estudia tu población y encuentras aquellas que son significativas (**p < 0.05**) se procede a hacer en ellas los análisis de supervivencia mencionados anteriormente para encontrar posibles predictores de un suceso clínico como lo puede ser una recaída, muerte o cualquiera. En el caso que nos han presentado para poder hacer nuestro trabajo es

la **Recaída Bioquímica (RBQ)** de pacientes que tenían pacientes con cáncer de próstata.

Curva de Kaplan-Meier

La **curva de Kaplan-Meier** es una herramienta estadística no paramétrica utilizada para estimar la función de supervivencia a partir de datos de tiempo hasta un evento, especialmente en presencia de datos censurados. Esta curva representa la probabilidad de que un individuo sobreviva más allá de un tiempo específico t , considerando que el evento de interés (como la muerte, recaída o falla de un dispositivo) no ha ocurrido hasta ese momento.

La estimación de Kaplan-Meier se basa en el producto de las probabilidades condicionales de supervivencia en cada intervalo de tiempo donde ocurre un evento. La fórmula del estimador es:

$$\hat{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i} \right)$$

donde:

- t_i : Tiempo en el que ocurre el i -ésimo evento.
- d_i : Número de eventos (por ejemplo, muertes) en el tiempo t_i .
- n_i : Número de individuos en riesgo justo antes del tiempo t_i .

Este método permite manejar adecuadamente los datos censurados, es decir, aquellos casos en los que no se observa el evento de interés durante el período de estudio, ya sea porque el individuo se pierde durante el seguimiento o porque el estudio finaliza antes de que ocurra el evento.

La curva resultante es una función escalonada que desciende en cada punto donde ocurre un evento, proporcionando una visualización clara de la supervivencia a lo largo del tiempo. Es especialmente útil para comparar la eficacia de diferentes tratamientos o intervenciones en estudios clínicos, mediante la comparación de las curvas de supervivencia entre distintos grupos (Molina Arias et al., 2022; IBM, 2023).




Figura 2.10: Curva resultante del evento RBQ en la tesis de Javier Cambroner

Modelo de Regresión de Cox

El **modelo de regresión de Cox**, también conocido como *modelo de riesgos proporcionales*, es una técnica estadística semiparamétrica ampliamente utilizada en el análisis de supervivencia. Este modelo permite evaluar el efecto de múltiples variables independientes (covariables) sobre el tiempo hasta la ocurrencia de un evento de interés, como puede ser la muerte, la recaída de una enfermedad o el fallo de un dispositivo médico (López Jiménez y Obrador, 2019).

Ecuación del modelo

La función de riesgo del modelo de Cox se expresa como:

$$h(t|X) = h_0(t) \cdot \exp(\beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p)$$

Donde:

- $h(t|X)$: tasa de riesgo en el tiempo t para un individuo con covariables X .
- $h_0(t)$: función de riesgo basal, que representa la tasa de riesgo cuando todas las covariables son cero.
- β_i : coeficiente que cuantifica el efecto de la covariable X_i sobre el riesgo.

Supuesto de riesgos proporcionales

Una característica fundamental del modelo de Cox es el **supuesto de riesgos proporcionales**, que establece que la razón de riesgos entre dos individuos

es constante en el tiempo, es decir, el efecto de las covariables sobre el riesgo es multiplicativo y no varía con el tiempo (Ortega Páez et al., 2023).

Aplicaciones y utilidad

El modelo de Cox es especialmente útil en estudios donde se desea:

- Evaluar el impacto de factores de riesgo sobre la supervivencia.
- Comparar la eficacia de diferentes tratamientos ajustando por covariables.
- Manejar datos censurados, es decir, casos donde no se observa el evento de interés durante el período de estudio.

Interpretación de los coeficientes

Los coeficientes β_i del modelo se interpretan en términos de **razones de riesgo** (*hazard ratios*). Un valor de $\exp(\beta_i) > 1$ indica un aumento en el riesgo asociado con la covariable X_i , mientras que un valor menor que 1 indica una disminución del riesgo (López Jiménez y Obrador, 2019).

2.4. Desafíos Enfrentados

La integración de modelos de lenguaje de gran escala (LLM) en el análisis biomédico de supervivencia representa una innovación significativa en la medicina basada en datos. Sin embargo, esta convergencia entre inteligencia artificial (IA) y salud plantea una serie de desafíos que deben abordarse para garantizar una implementación ética, efectiva y segura.

1. Complejidad en la Interpretación de Resultados

Uno de los principales retos es la capacidad de los LLM para generar resultados que, aunque precisos, pueden carecer de interpretabilidad clínica. La "caja negra" que caracteriza a muchos modelos de IA dificulta la comprensión de cómo se alcanzan ciertas conclusiones, lo que puede generar desconfianza entre los profesionales de la salud.

2. Calidad y Representatividad de los Datos

Los LLM requieren grandes volúmenes de datos para su entrenamiento. En el ámbito médico, la disponibilidad de datos de calidad y representativos es limitada, y su recopilación está sujeta a estrictas regulaciones de privacidad. Además, los datos pueden contener sesgos que, si no se identifican y corrigen, podrían perpetuar desigualdades en la atención médica.

3. Integración en la Práctica Clínica

La implementación de LLM en entornos clínicos requiere una adaptación de los flujos de trabajo existentes. Los profesionales de la salud deben ser capacitados para interactuar eficazmente con estas herramientas, comprendiendo sus capacidades y limitaciones. La resistencia al cambio y la falta de familiaridad con la tecnología pueden obstaculizar su adopción.

4. Consideraciones Éticas y Legales

El uso de IA en medicina plantea importantes cuestiones éticas y legales, como la responsabilidad ante errores, la transparencia en la toma de decisiones y la protección de la privacidad del paciente. Es esencial establecer marcos regulatorios que guíen el desarrollo y la implementación de estas tecnologías, asegurando su alineación con los principios de beneficencia, no maleficencia, autonomía y justicia.

5. Validación y Evaluación Continua

La eficacia de los LLM debe ser validada continuamente mediante estudios clínicos rigurosos. Es fundamental establecer métricas de rendimiento que evalúen no solo la precisión, sino también la utilidad clínica y la seguridad de estas herramientas. La evaluación continua garantiza que los modelos se mantengan actualizados y relevantes en un entorno médico en constante evolución.

6. Sostenibilidad y Escalabilidad

El desarrollo y mantenimiento de LLM requieren recursos computacionales significativos, lo que plantea desafíos en términos de sostenibilidad y escalabilidad. Es necesario explorar soluciones que permitan la implementación eficiente de estas tecnologías en diversos entornos clínicos, incluidos aquellos con recursos limitados.

Al abordar estos desafíos, se sientan las bases para una integración responsable y efectiva de los LLM en el análisis biomédico de supervivencia. El proyecto propuesto busca no solo superar estas barreras, sino también demostrar el valor añadido de la inteligencia artificial en la mejora de la atención médica y la toma de decisiones clínicas.

Tecnologías Empleadas

A continuación se van a detallar las tecnologías utilizadas para el desarrollo del proyecto.

3.1. Frontend

- **React:** Biblioteca de JavaScript utilizada para desarrollar interfaces de usuario basadas en componentes reutilizables. Gracias al uso de JSX, es posible combinar la lógica JavaScript con estructuras similares a HTML en un mismo archivo, favoreciendo una integración clara entre el diseño y la funcionalidad. React es el framework más utilizado de JavaScript en la actualidad para el desarrollo de aplicaciones web, esto es debido a su enfoque basado en componentes reutilizables, su eficiencia en el renderizado mediante el Virtual DOM, y su facilidad de aprendizaje.
- **CSS (Cascading Style Sheets):** Para el desarrollo de una aplicación web, es habitual usar estilos css permitiendo estilizar y dar formatos a elementos HTML, definiendo aspectos como colores, tipografía y espaciado.

3.2. Backend

- **Python:** Se trata del lenguaje de programación más empleado para el desarrollo de herramientas basadas en inteligencia artificial. Se ha utilizado junto con bibliotecas para manejo de datos, llamadas a modelos de openAI, manejo de bases de datos, entre otras. Python es un lenguaje muy sencillo de aprender, dispone de una gran cantidad de librerías y herramienta que permiten incorporar funcionalidades de manera sencilla, y eficiente, convirtiéndolo en un lenguaje muy utilizado para este tipo de proyectos.
- **FastAPI:** Framework utilizado para la creación de una API de servicios HTTP con Python, permitiendo la conexión del frontend de la aplicación con el bac-

kend encargado de procesar las diferentes funcionalidades y devolver los resultados para su posterior visualización.

- **HeidiSQL (MariaDB):** A la hora de decidir la base de datos que íbamos a necesitar para el desarrollo de la aplicación, optamos por una base de datos relacional para encargarse de la gestión de usuarios de la aplicación. Decidimos usar MariaDB, una alternativa compatible con MySQL, junto con HeidiSQL que nos permitía administrar diferentes bases de datos mediante una interfaz gráfica. Varios de los puntos que nos hicieron decantarnos por usar este software fue la disponibilidad de una interfaz de usuario intuitiva y bien estructurada y la facilidad de integrar MariaDB con Python.

3.3. Módulo de IA

- **OpenAI:** Se ha utilizado la API de OpenAI para realizar llamadas al modelo `gpt-4o-mini`, que ha sido el encargado de realizar las funcionalidades de la herramienta mediante el uso de prompts y funciones desarrolladas para cada caso. Se ha empleado este modelo tanto para el análisis estadístico sobre datos reales como la posterior generación automática de informes basados en las conclusiones. Barajamos la posibilidad de emplear otros modelos de código abierto como los ofrecidos por *Ollama*, pero se optó por utilizar la API de OpenAI debido a la fiabilidad y precisión que nos proporciona, y poder ver el alcance real que podía llegar a tener la IA para este tipo de situaciones.
- **Pydantic:** Tecnología clave de validación de datos usada en los modelos GPT para dar un ***response format*** a las respuestas del modelo, dado que uno de los grandes problemas de los LLM es la aleatoriedad de sus posibles respuestas tanto en contenido como en formato, con esta herramienta nos aseguramos que las respuestas sean siempre en el formato que se pida y no se desvíe creando posibles alucinaciones o distracciones que perjudiquen el resultado de los análisis y la redacción.
- **PdfLatex:** Programa encargado de compilar los archivos de LaTeX generados por los modelos de inteligencia artificial de openAI y generar documentos en formato PDF.

Arquitectura y Modelo de datos

4.1. Arquitectura

La arquitectura de la aplicación se basa en una estructura modular dividida en 4 bloques principales: Frontend, Backend, IA, BBDD y un bloque secundario: DATA, tal y como se muestra en la figura 4.1. Permite analizar de forma clara la aplicación y facilita el mantenimiento de la misma.




Figura 4.1: Arquitectura de la Aplicación

A continuación, se describirá cada uno de los módulos:

1. **Frontend:** Este módulo ha sido desarrollado en React, lo que permite una navegación más fluida a través de la aplicación. Se trata de la interfaz gráfica de usuario, la cual se comunica exclusivamente con el backend a través de peticiones HTTP (API REST), enviando solicitudes y recibiendo respuestas con los datos o resultados requeridos.
2. **Backend:** Es el módulo que conecta el frontend de la aplicación con el resto de servicios. Se encarga de recibir las peticiones del frontend, procesarlas y coordinar el funcionamiento de los distintos módulos. El backend ha sido

implementado en Python, expone una API con FastAPI que permite la integración del cliente (frontend) con los resultados obtenidos de los distintos módulos.

Se ha optado por FastAPI debido a su alto rendimiento, su sintaxis sencilla en Python, lenguaje en el que se han desarrollado las funcionalidades, y su facilidad a la hora de desarrollarlo.

3. **IA:** Este módulo se encarga de la parte de inteligencia artificial del sistema. Es controlado por el backend, que llama a las funciones de los controllers de cada funcionalidad, encargados de llamar a los agentes correspondientes. Cada funcionalidad del proyecto está implementada mediante un agente desarrollado en python. Cada agente cuenta con un prompt y un conjunto de funciones conocidas que le permiten llevar a cabo su tarea. Además, dispone de un controller, que hace de intermediario entre el backend y el agente, para llevar a cabo su funcionalidad al recibir una petición.
4. **BBDD (Base de Datos):** Se utiliza una base de datos MariaDB (compatible con MySQL) para gestionar la información relacionada con los usuarios y sus credenciales de la aplicación. El backend es el único componente que interactúa directamente con la base de datos, actuando de intermediario entre el cliente y la base de datos. La base de datos esta compuesta por tres tablas, como podemos ver en la figura 4.2.
5. **DATA:** Carpeta donde se almacenan los resultados generados a partir de los análisis estadísticos realizados por el módulo de IA. Dentro de DATA existen dos directorios:
 - **RAW:** Contiene los datos originales proporcionados por el usuario en la aplicación sin procesar.
 - **PROCESSED:** Contiene los resultados generados a partir del preparado, procesado y análisis de los datos. Incluye ficheros CSV e imágenes con los análisis estadísticos de los datos.

El principal objetivo de esta arquitectura basada en módulos es mantener separadas la capa de frontend de la lógica de la aplicación, permitiendo obtenerla únicamente mediante la conexión con el backend, garantizando una estructura robusta, mantenible y extensible.

4.2. Modelo de Datos

El modelo de datos se ha definido con el objetivo de garantizar la escalabilidad de la aplicación, manteniendo una gestión de los datos de los usuarios sencilla y con la posibilidad de añadir nuevas funcionalidades en el futuro. La base de datos esta compuesta por tres tablas principales:




Figura 4.2: Diagrama ER Base de Datos

1. **user**: Define los distintos usuarios registrados en la aplicación, cada cuenta de usuario tiene la siguiente información:

- **uuid_user**: Identificador único del usuario generado al crear el usuario (clave primaria).
- **name**: Nombre completo del usuario.
- **username**: Nombre de usuario generado al crear la cuenta de usuario, se puede modificar posteriormente.
- **email**: Correo electrónico del usuario para acceder a la herramienta.
- **password**: Contraseña cifrada del usuario.
- **secret**: Campo reservado para información adicional de autenticación. (Para futuras versiones)
- **date**: Fecha de creación del usuario.
- **last_updated**: Última actualización del usuario.
- **last_login**: Último acceso del usuario.
- **uuid_group**: Identificador del grupo al que pertenece el usuario (clave foránea).
- **validated**: Indica si el usuario ha sido validado (1 = sí, 0 = no).
- **token**: Token temporal para autenticación a la hora de iniciar sesión.
- **is_active**: Estado de inicio de sesión del usuario (1 = activo, 0 = inactivo).

2. **user_group**: Define los distintos grupos de usuarios, permitiendo clasificarlos mediante el identificador único del grupo.

- **uuid_group**: Identificador del grupo al que pueden pertenecer los usuarios
- **group_name**: Nombre del grupo con identificador propio para permitir a cada grupo de usuarios las funcionalidades a las que tienen acceso.

Aunque esta tabla no se ha utilizado por el momento, se ha añadido a la base de datos para posibles implementaciones futuras en la aplicación.

3. **user_meta**: Permite almacenar información adicional sobre cada usuario, permitiendo añadir atributos personalizados sin cambiar la estructura principal.
 - **uuid_user**: Identificador del usuario al que pertenece la información adicional almacenada.
 - **meta_key**: Nombre de la información adicional almacenada sobre el usuario.
 - **meta_value**: Información adicional almacenada sobre el usuario.

Al igual que la tabla de grupos de usuarios, no está en uso actualmente, pero se ha incorporado para posibles implementaciones futuras en la aplicación.

Capítulo 5

Implementación de la Plataforma

La aplicación se ha estructurado en módulos con el objetivo de facilitar el desarrollo, mantenimiento y garantizar un funcionamiento adecuado.

A continuación, se va a detallar los diferentes módulos implementados para el desarrollo de la aplicación.

5.1. Módulo Gestión de Usuarios:

La gestión de usuarios es una parte fundamental de la aplicación, ya que permite el registro de nuevos usuarios, el inicio de sesión, así como la modificación de las propiedades de la cuenta, tales como el nombre de usuario, el correo electrónico o la contraseña.

1. **Inicio de Sesión de Usuarios:** Antes de acceder a la herramienta se visualiza una página de autenticación donde permite realizar el inicio de sesión. El usuario puede introducir sus credenciales (correo y contraseña) y acceder a la herramienta.

Las credenciales son trasladadas al backend mediante peticiones HTTP a la API, y desde ahí el backend se encarga de comprobar si ese usuario existe y en caso de existir, genera un token de autenticación y actualiza el estado del usuario a activo. En la figura 5.27 podemos ver como se realiza el proceso de inicio de sesión.

```
def login_user(identifier: str, password: str):
    try:
        user = db.get_user_identifier(identifier)
        if not user:
            print(f"No se encontró el usuario con el identificador: {identifier}")
            raise HTTPException(status_code=400, detail="Email o contraseña incorrectos")

        if not verify_password(password, user["password"]):
            print(f"Contraseña incorrecta para el usuario: {identifier}")
            raise HTTPException(status_code=400, detail="Email o contraseña incorrectos")

        access_token = create_access_token(data={"sub": user["uuid_user"]})
        db.update_user_login(user["uuid_user"], datetime.now(), access_token)
        return {"access_token": access_token, "token_type": "bearer"}

    except Exception as e:
        print(f"Error en login user: {e}")
        raise HTTPException(status_code=500, detail="Error en el servidor durante el proceso de login")
```

Figura 5.1: Inicio de Sesión

2. **Registro de Usuarios:** Desde la página de inicio de sesión se permite crear una nueva cuenta en caso de no tenerla, pulsando el botón de REGISTRATE, esto te deja acceder a la página de registro, donde es posible introducir los datos nuevos y crear una nueva cuenta. En la figura 5.2 podemos ver un ejemplo de registro de un nuevo usuario.



Figura 5.2: Registro Nueva Cuenta

Desde la interfaz gráfica el usuario proporciona la información necesaria para crear la cuenta nueva, donde se comprueba que el correo sea válido, ambas contraseñas sean correctas y el usuario no exista ya en la aplicación.

Esta información es trasladada al backend mediante una petición HTTP vía API para almacenar en la base de datos de usuarios al nuevo usuario creado como podemos ver en el código de la figura 5.3.

```

async function registerUser(name, email, password){
  try{
    const response = await fetch('http://127.0.0.1:8000/auth/register', {
      method: 'POST',
      headers: {
        'Content-Type': 'application/json',
      },
      body: JSON.stringify({
        name: name,
        email: email,
        password: password
      })
    });
    const user = await response.json();
    if (response.ok) {
      return user;
    } else {
      throw new Error(user.detail || "Error en el registro");
    }
  } catch(error){
    console.error("Error al realizar el registerUser: ", error);
    setErrorMsg("Error al registrarse. Por favor, verifica los datos introducidos.");
    setSuccessMsg('');
  }
};

```

Figura 5.3: Petición HTTP vía API

El backend se encarga de recibir los datos de la cuenta creada, conectarse a la base de datos de usuarios e insertar el nuevo usuario como se puede apreciar en la figura 5.4.

```

def insert_user(self, user) -> None:
    self.connectDB()
    cursor = self.connUser.cursor()
    query = """
    INSERT INTO user (
        uid_user, name, username, email, password, secret, date, last_updated, last_login, uid_group, validated, token, is_active)
    VALUES (%s, %s, %s, %s, %s, %s, %s, %s, %s, %s, %s, %s, %s)
    """
    try:
        cursor.execute(
            query, (
                user.uid_user,
                user.name,
                user.username,
                user.email,
                user.password,
                user.secret,
                user.date,
                user.last_updated,
                user.last_login,
                user.uid_group,
                user.validated,
                user.token,
                user.is_active,
            )
        )
        self.connUser.commit()
    except Exception as e:
        self.connUser.rollback()
        raise Exception("insert_user: " + str(e))
    finally:
        cursor.close()
        self.close_connectionDB()

```

Figura 5.4: Añadir Usuario a Base de Datos

3. **Modificación de propiedades de la cuenta:** Esta sección se divide en dos:

- **Información de la cuenta:** El frontend se pone en contacto con el backend para obtener la información del usuario activo que a accedido a la página de información de la cuenta.

El usuario puede cambiar la información de la cuenta cambiando la información de las celdas y pulsando Guardar. Avisando así al backend de los nuevos datos del usuario. figura 5.5

```

def update_user_account(self, user, uuid) -> None:
    self.connectDB()
    cursor = self.connUser.cursor()
    query = """
    UPDATE user
    SET name = %s,
        username = %s,
        email = %s
    WHERE uuid_user = %s
    """
    try:
        cursor.execute(query, (user.name, user.username, user.email, uuid))
        self.connUser.commit()
    except Exception as e:
        raise Exception("update_user_account: " + str(e))
    finally:
        cursor.close()
        self.close_connectionDB()

```

Figura 5.5: Código Guardar Información Usuario

También es posible eliminar la cuenta del usuario si quisiese mediante el botón Eliminar Usuario. figura (5.6) Eliminando así el usuario de la base de datos y dejando de tener acceso a la aplicación.

```

def delete_patient(self, id) -> None:
    self.connectDB()
    cursor = self.connUser.cursor()
    query = """
    DELETE FROM patients WHERE id_patient = %s
    """
    id_int = int(id)
    try:
        cursor.execute(query, (id_int,))
        self.connUser.commit()
    except Exception as e:
        raise Exception("delete_patient: " + str(e))
    finally:
        cursor.close()
        self.close_connectionDB()

```

Figura 5.6: Código Eliminar Usuario

- **Cambio de contraseña:** Al acceder a la página de cambiar contraseña, se le solicita al usuario su correo y la nueva contraseña. En caso de que no se sepa el correo de la cuenta activa no le permitirá cambiar la contraseña. Una vez se pulsa el botón Restaurar Contraseña.

```

def update_pwd(pwd_update: PwdUpdate, uuid: str):
    try:
        hashed_password = hash_password(pwd_update.password)
        user = db.update_user_pwd(hashed_password, pwd_update.email, uuid)
        return user
    except Exception as e:
        print("Error en update_pwd:", e)
        raise HTTPException(status_code=500, detail="Error interno del servidor")

```

Figura 5.7: Código Actualizar Contraseña

5.2. Módulo Preparación y Procesamiento de los Datos:

La preparación y el procesamiento de los datos es el primer módulo relacionado con la herramienta de generación de informes con inteligencia artificial. Se encarga de preparar los datos de la base de datos proporcionada por el usuario, identificar las variables más relevantes, categorizar las variables en función de esas variables relevantes y, finalmente procesar esos datos.

- **Preparar los Datos:** : Una vez el usuario proporciona la base de datos (CSV o xlsx) y el archivo maestro y solicita preparar los datos para comenzar con el proceso, el backend se encarga de emplear el controller para ejecutar el agente encargado de preparar los datos.

El agente sigue el siguiente proceso:

- Accede al archivo CSV proporcionado por el usuario y lo guarda en un DataFrame para poder revisarlo y modificarlo posteriormente, y estandariza los nombres de las variables.
 - Carga el archivo master.json y se encarga de estandarizar los nombres para garantizar un correcto funcionamiento.
 - Revisa el DataFrame para eliminar los registros corruptos que tengan valores vacíos o inconsistentes.
 - Elimina los registros duplicados del DataFrame.
 - Almacena el nuevo DataFrame con las modificaciones realizadas en la carpeta de datos procesados.
- **Identificar Variable de Grupo:** El backend se encarga de emplear el controller para ejecutar el agente encargado de identificar la variable de grupo. Para identificar la variable de grupo se ha creado un prompt que se le pasa a la llamada del modelo de OpenAI, donde se le especifican los pasos a seguir para que logre identificar correctamente la variable de grupo (figura 5.8). El proceso consta de los siguientes pasos:
 - Contexto sobre su especialización, las fuentes de información que va a recibir y su objetivo.
 - Instrucciones que seguir para el razonamiento a la hora de identificar la variable:
 - Explorar la muestra de datos marcando las variables que no se van a incluir en la comparación de los dos posibles grupos.
 - Contrastar información con el archivo maestro para excluir variables que sean menos útiles.
 - Validar coherencia de los valores obtenidos
 - Tomar decisión final

- Información proporcionada:

- Nombre variable
- Descripción variable
- Valores posibles
- Datos observados
- Variable de grupo

```

AGENT_PROMPT = """
Tres un experto en estadística médica. Tu tarea es analizar una variable de un conjunto de datos clínicos y clasificarla según su tipo ("numerical", "categorical" o "irrelevant"),
y proponer el test estadístico más adecuado para compararla entre una variable de grupo que se te dará.

### Formato de respuesta esperado:
Devuélveme exclusivamente un objeto en formato JSON compatible con el siguiente modelo:

{
  "name": "nombre de la variable",
  "type": "categorical" | "numerical" | "irrelevant",
  "test": "t_student" | "mann_wilney" | "acosa" | "kruskal-wallis" | "chi-cuadrado" | "fisher" | "mcnemar"
}

### Instrucciones para clasificar la variable:
- Usa "numerical" para variables continuas o discretas cuantitativas (como edad, niveles de PSA, porcentajes, etc.).
- Usa "categorical" para variables que representen categorías con o sin orden (como presencia de una enfermedad, grupo de riesgo, grados Glasgow, etc.).
- Usa "irrelevant" si la variable es un identificador, una fecha, un código sin sentido clínico, o carece de datos relevantes o datos.

### Criterios para elegir el test estadístico:
Selecciona el test más adecuado para comparar esta variable entre dos grupos independientes (por ejemplo, casos vs. controles):

- Para variables numéricas:
  - Usa "t_student" si la variable tiene distribución normal en ambos grupos y varianzas similares.
  - Usa "mann_wilney" si no se cumple la normalidad o hay asimetría evidente.

- Para variables categóricas:
  - Usa "chi-cuadrado" si los tamaños de muestra son suficientemente grandes (todas las frecuencias esperadas > 5).
  - Usa "fisher" si alguna frecuencia esperada es < 5 (tabla 2x2 o muestras pequeñas).
  - Usa "mcnemar" solo si es una comparación de proporciones en datos apareados (misma persona en dos momentos).

- Para más de dos grupos (no es el caso ahora, pero si lo detectas):
  - Usa "mcnemar" si es asimetría con normalidad.
  - Usa "kruskal-wallis" si no hay normalidad.

### Información proporcionada:
- Nombre de la variable: {col}
- Descripción clínica: {descripcion}
- Valores posibles (si defínalos por diccionario): {valores_posibles}
- Datos observados: {datos_observados}
- Variable de grupo: {grupo_variable}

Evalúa los datos observados y la definición de la variable para tomar tu decisión. Evita suposiciones no justificadas. Devuélveme solo el objeto JSON conforme al esquema, sin explicaciones adicionales.
"""

```

Figura 5.9: Prompt categorización de variables

- **Procesar datos descriptivos:** El backend se encarga de emplear el controller para ejecutar los agentes encargados de procesar los datos descriptivos, tanto para variables numéricas como categóricas.

- **Variables Numéricas:** El controller se encarga de llamar al agente del procesado de datos de las variables numéricas, el cual comprueba que la variable es numérica y calcula los diferentes resultados estadísticos necesarios:

- Media
- Desviación Típica
- Mediana
- Rango Intercuartílico (3 cuartil - 1 cuartil)
- Máximo
- Mínimo
- Rango

Finalmente almacena los resultados de cada variable en un archivo CSV (analisis_estadistico_numerico.csv)

```
def execute(self) -> dict:
    """Main call to the LLM Agent.

    Returns:
        dict:
        """
    variable_list = []

    for var, info in self.variable_info.items():
        if info["type"] == "numerical" and var in self.df.columns:
            variable_list.append(var)
            datos = pd.to_numeric(self.df[var], errors="coerce").dropna()

            if datos.empty:
                continue

            n = len(datos)
            media = round(datos.mean(), 2)
            std = round(datos.std(), 2)
            mediana = round(datos.median(), 2)
            q1 = round(datos.quantile(0.25), 2)
            q3 = round(datos.quantile(0.75), 2)
            ric = round(q3 - q1, 2)
            minimo = round(datos.min(), 2)
            maximo = round(datos.max(), 2)
            rango = f"{minimo}-{maximo}"

            self.summary.loc[len(self.summary)] = [var, n, media, std, mediana, ric, rango]

    self.summary.to_csv(OUTPUT_PATH, index=False)

    return {
        "explanation": "TODO",
        "results": {
            "variables": variable_list,
            "csv_path": OUTPUT_PATH
        }
    }
```

Figura 5.10: Procesado de datos variables numéricas

- **Variables Categóricas:** El controller se encarga de llamar al agente del procesado de datos de las variables categóricas, el cual comprueba que la variable es categórica y calcula los diferentes resultados estadísticos necesarios:
 - Frecuencias Absolutas
 - Intervalo de Confianza Inferior al 95 %
 - Intervalo de Confianza Superior al 95 %

Finalmente almacena los resultados de cada variable en un archivo CSV (analisis_estadistico_categorico.csv)

- **Identificar Variable de Tiempo:** El backend se encarga de ejecutar el agente encargado de identificar la variable de tiempo. Para identificar la variable de tiempo se ha creado un prompt que se le proporciona a la llamada del modelo de OpenAI, donde se le especifican los pasos a seguir para que logre identificar correctamente la variable de tiempo (figura 5.11).

El proceso consta de los siguientes pasos:

- Contexto sobre su especialización, las fuentes de información que va a recibir y su objetivo.
- Instrucciones que seguir para el razonamiento a la hora de identificar la variable:

- Examinar variables con valores numéricos continuos con medidas temporales.
 - Priorizar variables con pocos valores ausentes.
 - Verificar el sentido clínico de la variable
 - Contrastarlo con la variable de grupo.
- Documentos de entrada que va a recibir el modelo y variable de grupo identificada.
 - Formato de salida esperado.

Cabe destacar que en un punto del desarrollo, se trabajó con una variable de tiempo errónea, dando resultados distintos a la tesis de Javier que queríamos replicar. Fue este agente LLM el que sugirió en una iteración la variable correcta, demostrando la capacidad de razonamiento y entendimiento de los LLM.

```
IDENTIFY_TIME_VARIABLE = """
contexto:
fres un agente especializado en análisis estadístico clínico aplicado a estudios en urología.
Tu tarea consiste en identificar cuál es la variable más adecuada del dataset para representar el TIEMPO en un análisis de supervivencia (como Kaplan-Meier o regresión de Cox).

Dispones de las siguientes fuentes de información:
1. Un diccionario 'master.json', que describe todas las variables del dataset, incluyendo sus significados clínicos.
2. Una muestra real del dataset (máximo 200 registros), que te permite observar cómo son los datos directamente.
3. Una variable de agrupación previamente identificada, que representa el evento de interés clínico (por ejemplo, recidiva bioquímica o progresión tumoral).
(Esta variable define los grupos de comparación (casos vs. controles)).

Tu objetivo es encontrar la mejor variable que represente el tiempo hasta el evento (o hasta la censura), y que esté clínicamente alineada con la variable de agrupación.

</contexto>

<instrucciones>
Sigue este razonamiento paso a paso:

1. Examina las variables del dataset que tengan valores NUMÉRICOS CONTINUOS y representen una medida temporal (en días, semanas, meses o años).
   Busca nombres o descripciones que contengan términos como "tiempo", "meses", "seguimiento", "supervivencia", "hasta", "duración", etc.

2. Prioriza variables que tengan una alta cobertura (pocos valores ausentes) tanto en pacientes con evento (por ejemplo, rq = "1") como en pacientes censurados (por ejemplo, rq = "2").
   Las variables con datos solo en los casos no pueden ser usadas para curvas de supervivencia completas.

3. Verifica que la variable tenga sentido clínico como duración.
   - No debe ser una categoría (no usar si es un índice de riesgo).
   - Debe representar una medida temporal objetiva desde un punto clínico relevante (por ejemplo, tiempo desde cirugía hasta evento o hasta último seguimiento).

4. Contrasta con la variable de agrupación:
   - La variable seleccionada debe poder aplicarse a todos los pacientes en los grupos definidos por la variable de agrupación.
   - Por ejemplo, si la variable de agrupación es 'rq', el tiempo debe estar disponible tanto en pacientes con recidiva como en aquellos sin ella.

</instrucciones>

<entrada>
- Maestro: (master)
- Muestra: (sample)
- Variable de agrupación: (group_variable)
</entrada>

<salida>
Devuelve la mejor variable de tiempo en el siguiente formato JSON compatible con IdentifyTimeSchema:

{
  "name": "nombre columna tiempo",
  "other_options": ["otra_variable_posible", "..."],
  "explanation": "explicación clínica clara y concisa justificando tu elección"
}

</salida>
"""
```

Figura 5.11: Prompt identificar variable de tiempo

- **Procesar datos comparativos:** El backend se encarga de ejecutar los agentes correspondientes para procesar los análisis comparativos, utilizando diversos análisis estadísticos. Entre los análisis realizados se encuentran:

```

@router.post('/executeDataAdv')
async def execute_data_adv():

    chi = comparative_controller.run_chi_square_analysis()
    fisher = comparative_controller.run_fisher_exact_analysis()
    tStudent = comparative_controller.run_t_student_analysis()
    mann = comparative_controller.run_mann_whitney_u_analysis()
    significant = significant_controller.collect_significant_values()
    kaplan = survival_controller.run_kaplan_meier_analysis()
    cox = survival_controller.run_cox_analysis()

    print("cox", cox)
    # time.sleep(5)
    return {"result": {
        "chi": chi,
        "fisher": fisher,
        "tStudent": tStudent,
        "mann": mann,
        "significant": significant,
        "kaplan": kaplan,
        "cox": cox
    }}

```

Figura 5.12: Procesar datos de variables comparativas

- **Variables Categóricas:**
 1. Test Chi Cuadrado (figura 5.13).
 2. Test de Fisher (figura 5.14).
- **Variables Numéricas:**
 1. Test de TStudent (figura 5.15).
 2. Test de Mann Whitney (figura 5.16).
- **Variables Significativas.**
- **Curvas de supervivencia:**
 1. Análisis de Kaplan Meier.
 2. Análisis Log-Rank.
 3. Análisis de Cox Univariante.

5.3. Módulo Realización Análisis Estadísticos:

Una vez procesados los datos, se han desarrollado agentes específicos para la realización de los análisis estadísticos de las variables. Para estos cálculos se han utilizado librerías de Python que obtienen resultados precisos y eficientes. En concreto se ha empleado `scipy.stats` para realizar las pruebas de las variables comparativas y `lifelines` para las curvas de supervivencia.

■ Análisis Comparativo con la variable objetivo:

- **Análisis de Variables Categóricas:**
 1. **Chi cuadrado de independencia:** (figura 5.13)
El agente se encarga de extraer y preparar la variable de grupo y las variables válidas para realizar el análisis.
Crea la tabla de contingencia entre la variable de grupo y cada variable válida. Descarta las tablas de menos de dos columnas o filas para obtener resultados fiables y posteriormente aplica la prueba de Chi Cuadrado sobre las tablas válidas.

Finalmente guarda los resultados de todas las variables en un archivo CSV. (analisis_categorico_chi_cuadrado.csv)

```
def execute(self) -> dict:
    """Main call to the Chi-Square Agent."""

    group_var = self.group_variable["group_variable"]
    valid_keys = set(float(k) for k in self.group_variable["valid_keys"])

    # Asegurar consistencia de tipos
    self.df[group_var] = self.df[group_var].astype(float)
    df = self.df[self.df[group_var].isin(valid_keys)]

    chi_data = []

    for var, info in self.variable_info.items():
        if info["type"] == "categorical" and info["test"] == "chi-cuadrado":
            if var not in df.columns or var == group_var:
                continue

            df_valid = df[[group_var, var]].dropna()

            if df_valid.empty:
                continue

            contingency = pd.crosstab(df_valid[group_var], df_valid[var])
            if contingency.shape[0] < 2 or contingency.shape[1] < 2:
                continue # Evitar tablas inválidas

            try:
                chi2, p, dof, expected = chi2_contingency(contingency)
                chi_data.append({
                    "variable": var,
                    "tabla": contingency.to_dict(),
                    "chi2": round(chi2, 4),
                    "dof": dof,
                    "p_value": round(p, 4),
                    "significativo": p < 0.05
                })
            except Exception as e:
                chi_data.append({
                    "variable": var,
                    "tabla": contingency.to_dict(),
                    "chi2": None,
                    "dof": None,
                    "p_value": None,
                    "significativo": None,
                    "error": str(e)
                })

    self.df_chi = pd.DataFrame(chi_data)
    self.df_chi.to_csv(OUTPUT_PATH, index=False)

    return {
        "explanation": "TODO",
        "results": {
            "csv_chi_path": OUTPUT_PATH
        }
    }
```

Figura 5.13: Código prueba chi cuadrado

2. Prueba exacta de fisher: (figura 5.14)

El agente se encarga de extraer y preparar la variable de grupo y las variables válidas para realizar el análisis.

Aplica el test de fisher a todas las variables categóricas que incluyen la variable de grupo entre sus claves válidas y este marcada para aplicar el test de fisher.

Crea las tablas de contingencia entre la variable de grupo y las variables de interés. Una vez creadas, solo se queda con las tablas con

tamaño 2x2 y ejecuta el test de fisher sobre cada tabla, marcando las variables que sean significativas (**valor $p < 0.05$**).

Finalmente, guarda los resultados en un archivo CSV. (analisis_categorico_fisher.csv).

```
def execute(self) -> dict:
    """Main call to the Fisher Exact Agent."""

    group_var = self.group_variable["group_variable"]
    valid_keys = set(float(k) for k in self.group_variable["valid_keys"])

    self.df[group_var] = self.df[group_var].astype(float)
    df = self.df[self.df[group_var].isin(valid_keys)]

    fisher_data = []

    for var, info in self.variable_info.items():
        if info["type"] == "categorical" and info["test"] == "fisher":
            if var not in df.columns or var == group_var:
                continue

            df_valid = df[[group_var, var]].dropna()

            if df_valid.empty:
                continue

            contingency = pd.crosstab(df_valid[group_var], df_valid[var])
            if contingency.shape != (2, 2):
                fisher_data.append({
                    "variable": var,
                    "tabla": contingency.to_dict(),
                    "stat": None,
                    "p_value": None,
                    "significativo": None,
                    "error": "La tabla no es 2x2"
                })
                continue

            try:
                stat, p = fisher_exact(contingency)
                fisher_data.append({
                    "variable": var,
                    "tabla": contingency.to_dict(),
                    "stat": round(stat, 4),
                    "p_value": round(p, 4),
                    "significativo": p < 0.05,
                    "error": ""
                })
            except Exception as e:
                fisher_data.append({
                    "variable": var,
                    "tabla": contingency.to_dict(),
                    "stat": None,
                    "p_value": None,
                    "significativo": None,
                    "error": str(e)
                })

    self.df_fisher = pd.DataFrame(fisher_data)
    self.df_fisher.to_csv(OUTPUT_PATH, index=False)

    return {
        "explanation": "TODO",
        "results": {
            "csv_fisher_path": OUTPUT_PATH
        }
    }
```

Figura 5.14: Código prueba de fisher

- **Análisis de Variables Numéricas:**

1. **Prueba de TStudent:** (figura 5.15)

La prueba de T-Student se aplica para comparar las medias de las variables numéricas que siguen la distribución normal entre dos grupos definidos por la variable de grupo.

El agente se encarga de extraer y preparar la variable de grupo y las variables válidas para realizar el análisis.

Aplica la prueba de T-Student a todas las variables numéricas que fueron marcadas anteriormente para aplicar este análisis. Tratando de determinar si existen diferencias significativas entre los grupos de cada variable.

Finalmente, guarda los resultados en un archivo CSV.

En el caso de la tesis que queríamos replicar y en muchos casos clínicos, las variables de pacientes no suelen seguir distribución normal, se ha añadido este test a recomendación de nuestro colaborador ya que en el caso de que alguna llegue a seguir la distribución normal es el mejor test que aplicar.

(analisis_numerico_t_student.csv).

```
def execute(self) -> dict:
    """Main call to the T Student Agent."""
    group_var = self.group_variable["group_variable"]
    valid_keys = set(float(k) for k in self.group_variable["valid_keys"])

    self.df[group_var] = self.df[group_var].astype(float)
    df = self.df[self.df[group_var].isin(valid_keys)]

    ts_data = []

    for var, info in self.variable_info.items():
        if info["type"] == "numerical" and info["test"] == "t_student":
            if var not in df.columns or var == group_var:
                continue

            df_valid = df[[group_var, var]].dropna()
            if df_valid.empty:
                continue

            try:
                group1 = df_valid[df_valid[group_var] == list(valid_keys)[0]][var]
                group2 = df_valid[df_valid[group_var] == list(valid_keys)[1]][var]

                if len(group1) < 3 or len(group2) < 3:
                    continue

                _, p = ttest_ind(group1, group2, equal_var=False)

                ts_data.append({
                    "variable": var,
                    "n_casos": len(group1),
                    "n_controles": len(group2),
                    "p_value": round(p, 4),
                    "significativo": p < 0.05
                })
            except Exception as e:
                ts_data.append({
                    "variable": var,
                    "n_casos": len(group1) if 'group1' in locals() else None,
                    "n_controles": len(group2) if 'group2' in locals() else None,
                    "p_value": None,
                    "significativo": None,
                    "error": str(e)
                })

    self.df_ts = pd.DataFrame(ts_data)
    self.df_ts.to_csv(OUTPUT_PATH, index=False)

    return {
        "explanation": "TODO",
        "results": {
            "csv_t_student": OUTPUT_PATH
        }
    }
```

Figura 5.15: Código prueba t student

2. Prueba no paramétrica de Mann Whitney: (figura 5.16)

La prueba de Mann Whitney se aplica para comparar las distribuciones de las variables numéricas entre dos grupos.

Para ello el agente se encarga de extraer y preparar la variable de grupo y las variables válidas para realizar el análisis.

Una vez están los datos preparados para el análisis, se recorren las variables numéricas, comprobando cuales han sido marcadas para realizar esta prueba.

Cada variable que cumple los requisitos comprobados anteriormente, es sometida a la prueba de mann whitney, donde se extraen los datos por cada grupo, comprobando que al menos cada uno de ellos tenga 3 observaciones para que la prueba sea válida y finalmente, se aplica la prueba de Mann-Whitney para comparar las distribuciones.

Una vez se han obtenido los resultados, estos se almacenan en un archivo CSV.

(analisis_numerico_t_student.csv)

```

def execute(self) -> dict:
    """Main call to the Mann-Whitney Agent."""
    group_var = self.group_variable["group_variable"]
    valid_keys = set(float(k) for k in self.group_variable["valid_keys"])

    self.df[group_var] = self.df[group_var].astype(float)
    df = self.df[self.df[group_var].isin(valid_keys)]

    mann_data = []

    for var, info in self.variable_info.items():
        if info["type"] == "numerical" and info["test"] == "mann_whitney":
            if var not in df.columns or var == group_var:
                continue

            df_valid = df[[group_var, var]].dropna()
            if df_valid.empty:
                continue

            try:
                group1 = df_valid[df_valid[group_var] == list(valid_keys)[0]][var]
                group2 = df_valid[df_valid[group_var] == list(valid_keys)[1]][var]

                if len(group1) < 3 or len(group2) < 3:
                    continue

                _, p = mannwhitneyu(group1, group2, alternative='two-sided')

                mann_data.append({
                    "variable": var,
                    "n_casos": len(group1),
                    "n_controles": len(group2),
                    "p_value": round(p, 4),
                    "significativo": p < 0.05
                })

            except Exception as e:
                mann_data.append({
                    "variable": var,
                    "n_casos": len(group1) if 'group1' in locals() else None,
                    "n_controles": len(group2) if 'group2' in locals() else None,
                    "p_value": None,
                    "significativo": None,
                    "error": str(e)
                })

    self.df_mann = pd.DataFrame(mann_data)
    self.df_mann.to_csv(OUTPUT_PATH, index=False)

    return {
        "explanation": "TODO",
        "results": {
            "csv_mann_path": OUTPUT_PATH
        }
    }

```

Figura 5.16: Código prueba de Mann Whitney bilateral

■ Variables significativas: (5.17)

Una vez realizados los análisis de las variables comparativas, se recorren los archivos de resultados estadísticos (chi cuadrado, fisher, t-student, mann-whitney) y se observa qué variables son significativas en cada uno de los análisis.

Las variables que son significativas se almacenan junto con la información más importante como el tipo de variable, el test aplicado y el p-valor en un archivo CSV. (variables_significativas_totales.csv)

```
def execute(self) -> dict:
    """Main call to the LLM agent."""
    self.collect_chi_square()
    self.collect_fisher()
    self.collect_mann_whitney()
    self.collect_t_student

    self.df.to_csv(OUTPUT_PATH, index=False)

    return {
        "explanation": "TODO",
        "results": {
            "csv_path": OUTPUT_PATH
        }
    }
```

Figura 5.17: Código Obtención Variables Significativas

■ Curvas de supervivencia:

1. Análisis de supervivencia utilizando curvas de Kaplan Meier: (figura 5.18)

Se ha desarrollado un agente encargado de realizar un análisis de supervivencia utilizando curvas de Kaplan-Meier, tanto globales como estratificadas por variables categóricas. Además, aplica la prueba de log-rank para evaluar las diferencias de supervivencia entre los grupos.

```
def execute(self) -> dict:
    self.kaplan_meier_plot()
    df_filtered = self.df_var[(self.df_var['tipo'].isin(['categórica']))]
    var_list = df_filtered['variable'].to_list()
    for var in var_list:
        self.stratified_km_plot(var=var)
    if self.logrank_summary_rows:
        pd.DataFrame(self.logrank_summary_rows).to_csv(OUTPUT_LOG_RANK, index=False)
    return {
        "explanation": "Se ha realizado el análisis de supervivencia con curvas de Kaplan Meier exitosamente.",
        "results": {
            "images_path": OUTPUT_DIR,
            "data_path": OUTPUT_CSV_DIR
        }
    }
```

Figura 5.18: Código Curvas de Supervivencia con Kaplan Meier

El agente comienza generando la curva de Kaplan Meier global, tomando la variable de tiempo y el evento (variable de grupo), filtrando los datos del DataFrame y añadiendo una nueva columna para saber si el evento ya ha ocurrido o es un evento censurado.

Una vez tiene los datos filtrados y preparados, calcula la curva de supervivencia usando KaplanMeierFitter de la librería de Python lifelines.

Finalmente genera:

- Gráfico de la curva de supervivencia global usando la librería matplotlib.pyplot.
- Archivo CSV con las probabilidades de supervivencia a lo largo del tiempo.
- Archivo CSV con el tiempo de supervivencia medio y el número de observaciones.

Una vez terminada la curva de supervivencia global, se comienza con el proceso de filtrado de variables categóricas para realizar las curvas de supervivencia de Kaplan Meier estratificadas para cada variable categórica.

El agente se encarga de comprobar que cada variable tiene al menos dos grupos para poder estratificar, crea una mascara con cada valor categórico de la variable y por cada valor genera:

- Gráfico de la curva de supervivencia de esa variable y grupo.
- Archivo CSV con las probabilidades de supervivencia por cada grupo.
- Archivo CSV con el tiempo de supervivencia medio por grupo y el número de observaciones.

Además se aplica la prueba de Log-Rank multivariada para comparar los grupos y obtener aquellas variables significativas de las curvas de supervivencia, guardando los resultados de la prueba en un archivo CSV. (log_rank.csv) figura 5.19

variable	test_statistic	p	-log2(p)	significative
hereda	5.342816948992825	0.06915475397523571	3.854027758344725	False
gleason1	10.937997445567845	0.027269746361986324	5.196554908076966	True
gleason2	8.109269159226752	0.04380660369923358	4.512707822094197	True
bilat2	1.914236913191539	0.16649337404976441	2.5864633314992824	False
localiz	3.148286677016307	0.0718496405995443	2.27100878811411	False
multifoc	1.462797870048751	0.22648547453623696	2.142509567735125	False
extracap	1.695626999418638	0.19286086464406302	2.3743676736984853	False
vvss	2.872995618647333	0.090077064953116	3.472696369978357	False
pinag	7.251160883510286	0.026633633575864887	5.230606923664163	True
margen	2.701348530394627	0.10026340839727156	3.318132911227377	False
tnm2	3.3435436676572747	0.18791381843622254	2.4118569341624236	False
rtpadyu	22.322793488314076	2.3045490337140615e-06	18.727084105210672	True
capras	9.776568979617386	0.3688743262602049	1.4387987142743333	False
ra_estroma	6.432830911908802	0.011202988099649903	6.479972605564684	True

Figura 5.19: CSV Resultados de la prueba Log-Rank

2. Análisis de Cox Univariante: (figura 5.20)

Se ha desarrollado un agente encargado de realizar un análisis de supervivencia utilizando el modelo de regresión de COX Univariante de las variables significativas.

```

def cox_univariate_analysis(self, variables: list[str]) -> pd.DataFrame:
    df_filtered = self.df[[self.time_variable, self.group_variable] + variables].copy()
    df_filtered.columns = ['time', 'event'] + variables

    df_filtered['time'] = pd.to_numeric(df_filtered['time'], errors='coerce')
    df_filtered['event'] = pd.to_numeric(df_filtered['event'], errors='coerce')
    df_filtered['event_occurred'] = df_filtered['event'] == 1
    df_filtered = df_filtered.dropna(subset=['time', 'event_occurred'])

    results = []

    for var in variables:
        df_var = df_filtered[['time', 'event_occurred', var]].dropna()
        if df_var[var].nunique() < 2:
            continue

        cph = CoxPHFitter()
        try:
            cph.fit(df_var, duration_col='time', event_col='event_occurred')
            summary = cph.summary.loc[var]
            results.append({
                "variable": var,
                "coef": summary["coef"],
                "HR": summary["exp(coef)"],
                "p": summary["p"],
                "ci_lower": summary["exp(coef) lower 95%"],
                "ci_upper": summary["exp(coef) upper 95%"],
                "c_index": cph.concordance_index_
            })
        except Exception as e:
            print(f"✗ Error en Cox para '{var}': {e}")
            continue

    return pd.DataFrame(results)

```

Figura 5.20: Código Análisis Variables con Cox Univariate

El agente comienza extrayendo las variables numéricas del DataFrame de variables y las variables significativas del análisis de Log-Rank, combinando ambas listas de variables en una única lista (Sin duplicados).

Crea un DataFrame nuevo con la variable de tiempo, el evento (variable de grupo) y las variables extraídas anteriormente. Añadiendo una columna nueva para comprobar si el evento ya ha ocurrido (evento = 1)

Se itera sobre todas las variables de interés, donde se comprueba que existan al menos dos valores distintos para verificar que es una variable de interés para la realización del análisis.

Sobre cada variable de interés, se aplica el modelo de Cox (CoxPHFitter de lifelines) y se extraen los resultados relevantes:

- Coeficiente del modelo
- Cociente de riesgos
- P-Valor
- Intervalo de confianza inferior al 95 %
- Intervalo de confianza superior al 95 %
- Concordancia del modelo

Finalmente genera un archivo CSV con los resultados de interés por cada variable. (cox_univariate.csv)

5.4. Módulo Generación de Informes Clínicos:

Se han desarrollado múltiples agentes encargados de realizar las conclusiones en base a los resultados obtenidos de los análisis estadísticos. Cada agente se encarga de un análisis concreto, generando las conclusiones sobre esos resultados y generando un código en LaTeX con dichas conclusiones para la posterior generación del documento. El orquestador (figura 5.21) es el encargado de llamar a cada agente de manera concurrente con una barrera para obtener sus conclusiones y generar el documento final en LaTeX. Una vez guardado el documento (final_report.tex), el orquestador emplea un compilador de LaTeX (pdflatex) para la generación del documento en formato PDF.

Para todos los agentes el orquestador le inyecta a sus respectivos prompts información y contexto general para no perder coherencia a la hora de desarrollar el documento.

```
def generate_latex_document():
    with ThreadPoolExecutor() as executor:
        futures = [executor.submit(AGENTS[name]) for name in ORDER]
        sections = [future.result() for future in futures]

    latex_content = r"""
\documentclass[12pt]{article}
\usepackage[utf8]{inputenc}
\usepackage[spanish]{babel}
\usepackage{geometry}
\geometry{margin=2.5cm}
\usepackage{setspace}
\onehalfspacing
\usepackage{graphicx}
\usepackage{booktabs}
\usepackage{float}
\usepackage{amsmath}
\usepackage{caption}
\usepackage{hyperref}
\usepackage{lmodern}

\begin{document}

%s

\end{document}
""" % (''.join(sections))

    os.makedirs(PDF_DIR, exist_ok=True)
    ✨ tex_path = os.path.join(PDF_DIR, "final_report.tex")
    with open(tex_path, "w") as f:
        f.write(latex_content)

    os.makedirs(OUTPUT_DIR, exist_ok=True)

    subprocess.run(["pdflatex", "-interaction=nonstopmode", "-output-directory", PDF_DIR, tex_path])

    pdf_source_path = os.path.join(PDF_DIR, "final_report.pdf")
    pdf_destination_path = os.path.join(OUTPUT_DIR, "final_report.pdf")
    shutil.copy(pdf_source_path, pdf_destination_path)
    print(f"Archivo copiado a: {pdf_destination_path}")
```

Figura 5.21: Código Orquestador para la generación de informes

Los diferentes agentes encargados de generar las conclusiones para el informe final son:

```

AGENTS = {
    "cover": generate_cover,
    "dataset": generate_dataset_description,
    "target": generate_target_variable,
    "num_summary": generate_numeric_summary,
    "cat_summary": generate_categorical_summary,
    "chi2": generate_chi_squared,
    "fisher": generate_fisher_exact,
    "t_student": generate_t_student,
    "mann_whitney": generate_mann_whitney,
    "comparative_summary": generate_comparative_significance,
    "time_variable": generate_time_variable,
    "km_summary": generate_kaplan_meier_summary,
    "km_analysis": generate_kaplan_meier,
    "log_rank": generate_log_rank,
    "cox": generate_cox_regression,
}

```

Figura 5.22: Agentes Generación Documento

Todos los agentes que realizan una llamada un LLM para generar el documento LaTeX con las conclusiones obtenidas de los resultados estadísticos calculados anteriormente reciben un prompt con las siguientes especificaciones:

```

CONTEXT = """
Estás colaborando en la redacción automatizada de un informe o artículo científico en LaTeX,
con estilo académico y técnico, sobre un análisis de datos aplicado a un estudio clínico o biomédico.
El objetivo principal del estudio es identificar factores asociados a la aparición de un evento clínico
(definido en la variable {target}) y estudiar el tiempo hasta dicho evento (medido en {time}).

El conjunto de datos incluye variables clínicas, sociodemográficas y/o bioquímicas, tanto categóricas como numéricas.
Se han llevado a cabo múltiples tipos de análisis estadísticos con fines descriptivos, comparativos e inferenciales, incluyendo:

1 - Estadística descriptiva (frecuencias, porcentajes, medias, medianas, desviaciones estándar, IQR).

2 - Comparación de variables entre grupos definidos por {target}, usando:
    - Test de Chi-cuadrado o test exacto de Fisher para variables categóricas.
    - T de Student o Mann-Whitney U para variables numéricas.

3 - Análisis de supervivencia:
    - Curvas de Kaplan-Meier estratificadas por variables relevantes.
    - Pruebas de log-rank para comparar curvas.
    - Modelos de regresión de Cox univariante y multivariante para identificar predictores independientes del evento.

Los resultados se integran en un documento en LaTeX. Cada sección debe estar bien redactada, contener las tablas o gráficos necesarios
si se proporcionan, y ser coherente con las demás secciones del análisis. Todo el contenido debe ser generado en formato LaTeX como un string.

Tu tarea es generar exclusivamente el contenido LaTeX correspondiente a una sección concreta del estudio.
No incluyas explicaciones ni respuestas fuera del entorno LaTeX. Este contenido será ensamblado en un documento
científico completo por un orquestador LLM.

IMPORTANTE! No uses Markdown ni código de python, solo LaTeX
"""

```

Figura 5.23: Prompt Contexto para la llamada al modelo

- Contexto general: Proporcionando la información sobre el proyecto en el que esta trabajando como se mencionó anteriormente, su objetivo "Colaborar en redacción automatizada de informe científico con Latex", los tipos de análisis estadísticos que se han realizado y tipos de variables del conjunto de datos (figura 5.23).
- Sección: Organización de la sección de Latex que va a crear el modelo.
- Datos de entrada al modelo para tenerlos en cuenta a la hora de realizar las conclusiones.
- Formato de salida esperado con un esquema de pydantic:


```
"latex_code": <aquí va el contenido en LaTeX como string>
```



En el caso del elaborador de documentos, los esquemas de pydantic fueron esenciales para el correcto funcionamiento de los agentes, ya que validar los datos de salida hace que el modelo evite distracciones, *alucinaciones* o mensajes de relleno como de saludo o despedida.

Ejemplo Prompt Kaplan Meier Global: figura 5.25

- **Portada:** Genera el código de la portada del documento proporcionando el título del documento "Investigación generada por IA Generativa", el autor "Ürolobotz la institución Universidad Complutense de Madrid".
- **Dataset:** Agente encargado de elaborar las conclusiones sobre los datos proporcionados en el dataset y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Dataset:

- Sección:
 - Título
 - Descripción variables
- Datos de entrada:
 - Archivo Maestro
 - Dataset



```
def generate(self) -> str:
    response = self.call_llm(
        prompt=PROMPT.format(
            context= CONTEXT.format(target=self.group_variable, time=self.time_variable),
            master=self.master,
            dataset=self.df.to_string()
        ),
        response_format=LaTeXResponse,
        temperature=0.8
    )
    return response.latex_code
```

Figura 5.24: Código Llamada al modelo de conclusiones sobre el dataset

- **Variable Objetivo:** Agente encargado de elaborar las conclusiones sobre la variable objetivo o variable de grupo y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Variable Objetivo:

- Sección:
 - Título
 - Contenido
- Datos de entrada:
 - Variable objetivo | Variable de grupo
 - Descripción del contenido de la variable objetivo
 - Dataset

- **Resumen Variables Numéricas:** Agente encargado de elaborar las conclusiones sobre los resultados de la estadística descriptiva para las variables numéricas y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Resumen Variables Numéricas:

- Sección:
 - Título
 - Tabla de análisis de contenido
 - Conclusiones
- Datos de entrada:
 - Resultados de los análisis estadísticos
 - Dataset
- **Resumen Variables Categóricas:** Agente encargado de elaborar las conclusiones sobre los resultados de la estadística descriptiva para las variables categóricas y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Resumen Variables Categóricas:

- Sección:
 - Título
 - Tabla de análisis de contenido
 - Conclusiones
- Datos de entrada:
 - Resultados de los análisis estadísticos
 - Dataset
- **Chi Cuadrado:** Agente encargado de elaborar las conclusiones sobre los resultados de los análisis estadísticos obtenidos mediante la prueba de Chi Cuadrado y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Chi Cuadrado:

- Sección:
 - Título
 - Tabla de análisis de contenido
 - Conclusiones
- Datos de entrada:
 - Resultados de los análisis estadísticos
 - Dataset
 - Archivo Maestro

- **Fisher:** Agente encargado de elaborar las conclusiones sobre los resultados de los análisis estadísticos obtenidos mediante la prueba de Fisher y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Fisher:

- Sección:
 - Título
 - Tabla de análisis de contenido
 - Conclusiones
 - Datos de entrada:
 - Resultados de los análisis estadísticos
 - Dataset
 - Archivo Maestro
- **T Student:** Agente encargado de elaborar las conclusiones sobre los resultados de los análisis estadísticos obtenidos mediante la prueba de T-Student y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente T Student:

- Sección:
 - Título
 - Tabla de análisis de contenido
 - Conclusiones
 - Datos de entrada:
 - Resultados de los análisis estadísticos
 - Dataset
 - Archivo Maestro
- **Mann Whitney:** Agente encargado de elaborar las conclusiones sobre los resultados de los análisis estadísticos obtenidos mediante la prueba de Mann-Whitney y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Mann-Whitney:

- Sección:
 - Título
 - Tabla de análisis de contenido
 - Conclusiones
- Datos de entrada:
 - Resultados de los análisis estadísticos
 - Dataset
 - Archivo Maestro

- **Resumen Estadística Comparativa:** Agente encargado de elaborar las conclusiones sobre los resultados de la estadística comparativa para las variables significativas y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Resumen Estadística Comparativa:

- Sección:
 - Título
 - Tabla de análisis de contenido
 - Conclusiones
- Datos de entrada:
 - Resultados de los análisis estadísticos
 - Dataset
 - Archivo Maestro
- **Variable de Tiempo:** Agente encargado de elaborar las conclusiones sobre la variable de tiempo para el análisis de supervivencia y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Variable de Tiempo:

- Sección:
 - Título
 - Contenido
- Datos de entrada:
 - Variable de tiempo
 - Dataset
 - Archivo Maestro
- **Resumen Kaplan Meier:** Agente encargado de elaborar las conclusiones sobre los resultados de la curva de supervivencia de Kaplan-Meier de la variable objetivo y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Resumen Kaplan-Meier:

- Sección:
 - Título
 - Imagen
 - Conclusiones
- Datos de entrada:
 - Curva de Supervivencia

- **Análisis Kaplan Meier:** Agente encargado de elaborar las conclusiones sobre los resultados de las curvas de supervivencia de Kaplan-Meier estratificadas de las variables y grupos, y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Análisis Kaplan-Meier por cada variable:

- Sección: (Una por cada variable)
 - Subsección
 - Imagen
 - Conclusiones
- Datos de entrada:
 - Curva de Supervivencia Estratificada
- **Log Rank:** Agente encargado de elaborar las conclusiones sobre los resultados del análisis de Log-Rank posterior al análisis de supervivencia con curvas de Kaplan-Meier, y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Log Rank:

- Sección:
 - Título
 - Tabla de análisis de contenido
 - Conclusiones
- Datos de entrada:
 - Resultados estadísticos del Log-Rank
 - Dataset
 - Archivo Maestro
- **Cox Univariante:** Agente encargado de elaborar las conclusiones sobre los resultados del análisis de la regresión de COX Univariante, y generar el código LaTeX para generar posteriormente el documento final.

Especificaciones del Prompt del Agente Cox Univariante:

- Sección:
 - Título
 - Tabla de análisis de contenido
 - Conclusiones
- Datos de entrada:
 - Resultados estadísticos de la regresión de COX
 - Dataset
 - Archivo Maestro

```

PROMPT = """
<context>
{context}
</context>

Tu trabajo es analizar clínicamente la curva de supervivencia Kaplan Meier que se te proporciona.
La curva es de la variable objetivo con la variable de seguimiento.
Se te van a dar tres herramientas:
-El path a la imagen que contiene la grafica de la curva que solo la usaras para mostrarla
-La curva en formato csv, que usaras para analizarla.
</context>

<seccion>
La seccion en LaTeX que vas a crear se conforma de:

Titulo:
Análisis de curvas de supervivencia Kaplan-Meier

Imagen:
Adjuntaras la imagen de este path {image} y la mostraras con un encabezado

Conclusiones:
Analiza la curva dada en formato csv y saca conclusiones clinicas sobre la misma curva,
es importante que se haga este analisis a fondo y a profundidad.
</seccion>

<entrada>
Analizaras la curva dada en este CSV: {csv}
</entrada>

<salida>
Tu única tarea es generar el código en LaTeX para esta sección.
Devuelve un JSON válido que cumpla este esquema:

{{
  "latex_code": "<aquí va el contenido LaTeX como string>"
}}

IMPORTANTE: la seccion y subsecciones (si las hay) deben ser directamente integrable en un documento LaTeX.
</salida>
"""

```

Figura 5.25: Prompt Conclusiones Kaplan Meier General

5.5. Módulo Desarrollo de Aplicación Web:

Se ha desarrollado una aplicación web realizada en React con JavaScript para integrar las funcionalidades anteriormente vistas mediante una interfaz gráfica para facilitar el uso de la herramienta.

Este módulo recoge tanto la gestión de usuarios, el preparado y procesado de los datos proporcionados por el usuario, la realización de los análisis estadísticos y la generación del documento basado en los resultados obtenidos.

La aplicación web se distingue en varias secciones:

- **Página de Autenticación:** Al acceder a la aplicación web, te dirige a una página de autenticación donde iniciar sesión para poder tener acceso a la herramienta. Para iniciar sesión se solicita el correo electrónico y la contraseña.

Figura 5.26: Página de Inicio de Sesión

El frontend interactúa con el backend proporcionándole las credenciales solicitadas al usuario mediante una petición HTTP a `HOST/auth/login` y el backend se encarga de comprobar si el usuario existe y de verificar la contraseña. Una vez comprueba que las credenciales son ciertas genera un token de acceso para el usuario y lo actualiza en la información del usuario en la base de datos y marca al usuario como activo.

```
async function loginUser(info){
  try{
    console.log(info);
    console.log("antes del fetch");
    const response = await fetch('http://127.0.0.1:8000/auth/login', {
      method: 'POST',
      headers: {
        'Content-Type': 'application/json',
      },
      body: JSON.stringify({
        identifier: info.email,
        password: info.password
      })
    });
    const user = await response.json();
    if (response.ok) {
      localStorage.setItem('token', user.access_token);
      return user;
    } else {
      throw new Error(user.detail || "Error en el login");
    }
  } catch(error){
    console.error("Error al realizar el loginUser: ", error);
    setErrorMsg("Error al iniciar sesión. Por favor, revisa tu email y contraseña.");
  }
}
```

Figura 5.27: Iniciar Sesión Usuario

En caso de no disponer de cuenta creada para acceder a la herramienta, en la página de inicio de sesión se permite acceder a una página de registro de nuevos usuarios mediante el botón "Regístrate".

En la página de registro se solicita al usuario proporcionar la siguiente información sobre el usuario que va a crear la cuenta nueva: nombre, correo electrónico, contraseña, repetir contraseña.

El formulario de registro de nuevo usuario en UroloBot se encuentra en una página con fondo azul claro. En la parte superior hay un logo circular con un robot y el texto "Regístrate en UroloBot" en azul. El formulario contiene cuatro campos de entrada con bordes blancos y fondo azul claro: "Nombre *" (obligatorio), "Correo Electrónico *" (obligatorio), "Contraseña *" (obligatorio) y "Confirmar Contraseña *" (obligatorio). Debajo de los campos hay un botón rectangular azul con el texto "REGISTRARSE" en blanco. En la parte inferior del formulario, hay un enlace que dice "¿Ya tienes cuenta? INICIAR SESIÓN".

Figura 5.28: Página de Registro de Nuevo Usuario

Una vez el usuario proporciona esa información al frontend, comprueba que tanto el email es válido como que ambas contraseñas sean iguales, y esta infor-

mación es traspasada al backend mediante una petición HTTP a `HOST/auth/-register` y el backend se encarga de crear este nuevo usuario y encriptando la contraseña al almacenarla en la base de datos.

El frontend indica al usuario si ha sido registrado con éxito o no, una vez ha sido registrado con éxito, permite al usuario utilizar las credenciales para iniciar sesión en la aplicación.

- **Página de Bienvenida:** Una vez el usuario ha iniciado sesión, accede a la página principal del proyecto. Donde puede decidir entre las diferentes acciones posibles dentro de la aplicación.
 - Ajustes de Usuario
 - Chat con Asistente Inteligencia Artificial
 - Generador de Informes Clínicos



Figura 5.29: Página de Bienvenida Urolobot

- **Ajustes de Usuario:** El usuario puede gestionar su cuenta desde el perfil del usuario. Entre las opciones posibles se encuentran:
 - Mi cuenta
 - Cambiar contraseña
 - Cerrar sesión

Mi cuenta: El frontend solicita al backend la información sobre el usuario. El usuario tiene la posibilidad de modificar la siguiente información de su cuenta:


```
useEffect(() => {
  const getInfo = async () => {
    if (dataObtained) return; // Si ya se obtuvieron los datos, no vuelve a cargarlos
    try {
      const token = localStorage.getItem('token');
      const response = await fetch('http://127.0.0.1:8000/auth/info', {
        method: 'GET',
        headers: {
          'Content-Type': 'application/json',
          'Authorization': `Bearer ${token}`
        }
      });
      const data = await response.json();
      setUserInfo(data);
      setDataObtained(true);
    } catch (error) {
      console.error("Error al obtener la información del usuario: ", error);
      alert("Hubo un problema al cargar la información del usuario.");
    } finally {
      setLoading(false);
    }
  };

  getInfo();
}, [dataObtained]);
```

Figura 5.30: Obtener información del usuario activo.

- Nombre Completo
- Nombre de Usuario
- Correo electrónico

Una vez realizada alguna modificación, esta no se almacenará en la base de datos hasta no solicitar que se guarde. El usuario también tiene la posibilidad de eliminar su cuenta.

Figura 5.31: Información de la cuenta del usuario

Cambiar contraseña: El usuario puede cambiar la contraseña en caso de haber olvidado la anterior, proporcionando su correo electrónico y la nueva contraseña por duplicado para verificar que no se ha equivocado. En caso de ser todos los datos válidos, la contraseña del usuario se restaurará.



The screenshot shows a web form titled "Cambiar Contraseña" (Change Password) with a close button (X) in the top right corner. The form is set against a light blue background. It contains three input fields: "Correo Electrónico:" (Email), "Nueva Contraseña:" (New Password), and "Repetir Contraseña:" (Repeat Password). Below these fields is a green button labeled "Restaurar Contraseña" (Reset Password). The top of the page features a blue header with the "UROLOBOT" logo and a user profile icon.

Figura 5.32: Restaurar Contraseña

Cerrar sesión: El usuario puede cerrar la sesión activa y volver a la página de inicio de sesión.

- **Página de Chat con IA:** Se ha desarrollado un pequeño chat con el modelo de OpenAI para la realización de preguntas del usuario a ChatGPT sin necesidad de salir de la herramienta.

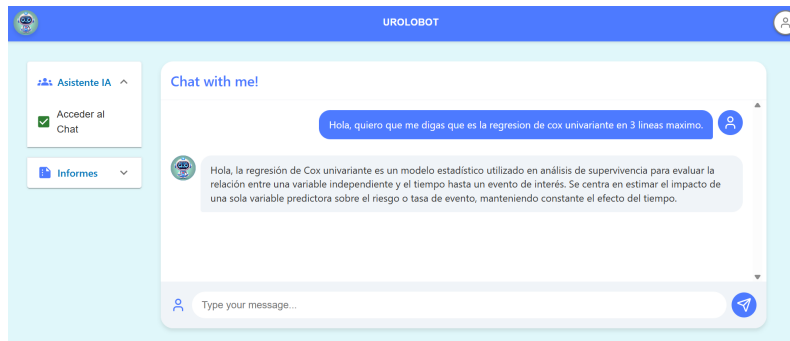


Figura 5.33: Chat con Asistente IA GPT-4o-mini

El frontend recibe la consulta del usuario y le proporciona al modelo de GPT-4o-mini esa información para devolver al usuario una respuesta. El chat no está especializado, únicamente realiza una llamada al modelo de ChatGPT para no tener que salir de la herramienta en caso de necesitar realizar alguna consulta.

```
const sendMessageToAPI = async (message) => {
  try {
    const response = await fetch('https://api.openai.com/v1/chat/completions', {
      method: 'POST',
      headers: {
        'Authorization': `Bearer ${API_KEY}`,
        'Content-Type': 'application/json',
      },
      body: JSON.stringify({
        model: "gpt-4o",
        messages: [
          { role: "system", content: "You are a helpful assistant." },
          { role: "user", content: message }
        ],
        temperature: 0.7,
        max_tokens: 1000
      })
    });

    if (response.status !== OK_API) {
      console.error("OpenAI API error", await response.text());
      return ERROR_MSG;
    }

    const result = await response.json();
    const reply = result.choices[0].message.content.trim();
    return reply;
  } catch (error) {
    console.error('Error sending message to API:', error);
    return ERROR_MSG;
  }
};
```

Figura 5.34: Código Envío consulta de usuario a API de OpenAI

- **Página de Generación de Informes:** El principal objetivo de la herramienta era la posibilidad de automatizar la generación de informes clínicos basados en los resultados de análisis estadísticos de los datos proporcionados por el usuario. Los datos empleados durante la realización del proyecto han sido proporcionados por un experto del sector. La base de datos y el archivo maestro son los utilizados por el experto en la realización de su tesis doctoral; hemos usado estos datos para generar un documento con los mismos análisis realizados durante la realización de la tesis doctoral para poder comparar los resultados y las conclusiones obtenidas por el modelo con las del experto.

La herramienta de generación de informes consta de los siguientes módulos:

- **Cargar BBDD y Archivo Maestro:** El usuario debe proporcionar a la herramienta la base de datos y el archivo maestro con los que quiera realizar el análisis estadístico y elaborar las conclusiones. Para ello se ha desarrollado una página en la que subir estos archivos que son enviados al backend para preparar los datos para su posterior uso.



Figura 5.35: Subida y Preparación de los datos

Una vez preparados los datos para el análisis se muestra un mensaje indicando que el proceso de preparado de datos ha terminado correctamente y permite pasar al siguiente proceso.

```
<Snackbar open={openSnackbar} autoHideDuration={4000} onClose={() => setOpenSnackbar(false)} anchorOrigin={{ vertical: 'top', horizontal: 'center' }}
  <Alert onClose={() => setOpenSnackbar(false)} severity="success" sx={{ width: '100%' }}>
    Datos de la base de datos y archivo maestro preparados.
  </Alert>
</Snackbar>
```

Figura 5.36: Alerta datos preparados

- **Identificación Variable Grupo y Categorización Variables:** El frontend interactúa con el backend para realizar la llamada al modelo e identificar la variable objetivo o variable de grupo y sus claves válidas. Una vez el modelo identifica una posible variable objetivo, se solicita al usuario que confirme la variable y en caso de no ser la correcta, se permite modificarla.



Figura 5.37: Variable objetivo identificada

Una vez identificada y confirmada la variable de grupo o variable objetivo, se categoriza el conjunto de variables según su tipo (numérica o categórica) para aplicar los análisis estadísticos correspondientes a cada variable. El proceso de categorización genera un archivo json en el que cada variable tiene identificado su tipo y el test que se le va a aplicar posteriormente.

```
const handleConfirmGroupVariable = async () => {
  const payload = {
    group_variable: groupV,
    valid_keys: validKeys
  };

  try {
    setLoading(true);
    const saveResponse = await fetch('http://127.0.0.1:8000/ai/save-config', {
      method: 'POST',
      headers: {
        'Content-Type': 'application/json'
      },
      body: JSON.stringify({
        payload,
        jsonPath
      })
    });

    if (!saveResponse.ok) {
      throw new Error('Error al guardar el archivo JSON');
    }

    console.log('Archivo JSON actualizado correctamente');

    const response = await fetch('http://127.0.0.1:8000/ai/categorize-variables', {
      method: 'POST',
    });

    if (!response.ok) {
      throw new Error('Error HTTP: ${response.status}');
    }

    const result = await response.json();
    setIsGroupIdentified(true);
    console.log("Ejecutar categorize-variables:", result);

    setOpenSnackbar(true);
  } catch (error) {
    console.error('Error:', error);
  } finally {
    setLoading(false);
  }
};
```

Figura 5.38: Categorización variables

Tras identificar la variable objetivo y categorizar las variables, se muestra un mensaje indicando que el proceso ha terminado correctamente y permite pasar al siguiente proceso como en la figura 5.36

- **Procesado de datos descriptivos:** Con la variable objetivo identificada y las variables categorizadas, comienza el procesamiento de los datos descriptivos para la realización de los análisis estadísticos.

El procesado de los datos descriptivos es realizado mediante dos agentes encargados de realizar los análisis estadísticos.

- Agente encargado de los análisis de variables numéricas.
- Agente encargado de los análisis de variables categóricas.

Análisis variables numéricas: El agente se encarga de recorrer el conjunto de variables, y para cada variable numérica calcula y almacena en un archivo csv:

- Variable

- Número de casos
- Media
- Desviación Típica
- Mediana
- Rango intercuartílico
- Rango

Análisis variables categóricas: El agente se encarga de recorrer el conjunto de variables, y para cada variable categórica calcula y almacena en un archivo CSV:

- Variable
- Valor
- Número de casos
- Frecuencias Absolutas
- Intervalo de confianza superior al 95 %
- Intervalo de confianza inferior al 95 %

Los archivos CSV generados se almacenan en una carpeta data/processed para su posterior uso. El frontend almacena donde se encuentra cada archivo para poder ir a obtener la información para su visualización.

- **Visualización de los Datos Descriptivos:** Tras la realización de los análisis estadísticos de los datos descriptivos, la herramienta permite ver en la interfaz gráfica los resultados obtenidos. Mostrando tablas con los resultados de cada variable para cada estudio estadístico y gráficas que permiten comparar los resultados de manera visual los resultados de cada variable. Para la realización de las gráficas se ha empleado una librería de JavaScript ApexCharts y ApexCharts-react.

La visualización de los datos descriptivos se divide en tres fases:

Determinar Media y Desviación Típica: Para obtener la media y la desviación típica de cada variable, el frontend solicita al backend que acceda al archivo CSV generado durante el procesado de los datos descriptivos para las variables numéricas (analisis_estadistico_numerico.csv)

```
def obtener_media_std(path_csv):
    """
    Lee un archivo CSV con estadísticas y devuelve un diccionario con la media y std de cada variable.

    Args:
        path_csv (str): Ruta al archivo CSV.

    Returns:
        dict: Diccionario con la forma {variable: {'media': valor, 'std': valor}}.
    """
    try:
        df = pd.read_csv(path_csv)
    except Exception as e:
        return {}

    resultado = {}
    for _, fila in df.iterrows():
        variable = fila['variable']
        media = fila['media']
        std = fila['std']
        n = fila['n']
        resultado[variable] = {
            'n': n,
            'media': media,
            'std': std
        }

    return resultado
```

Figura 5.39: Obtención de Media y Desviación Típica para Visualización

Las gráficas empleadas en esta ocasión son una gráfica de barras y otra gráfica circular mostrando los valores obtenidos para cada variable.

```
<?xml version='1.0' encoding='utf-8' ?>
<renderTable(desviacion, 'Desviación Típica', nPruebas)>
  <Box mt=4 sx={{ display: 'flex', justifyContent: 'space-around' }}>
    <BarChart data={desviacion} title='Desviaciones típicas de Variables Numéricas' variable='Desviaciones Típicas' />
    <PieChart data={desviacion} title='Distribución de Desviaciones Típicas' />
  </Box>
</?xml>
```

Figura 5.40: Tabla y Gráficos Desviación Típica en React

Determinar Mediana y rango Intercuartílico: Para obtener la mediana y el rango intercuartílico de cada variable, el frontend solicita al backend que acceda al archivo CSV al igual que en el proceso de obtención de la media y la desviación típica. (analisis_estadistico_numerico.csv)

Las gráficas empleadas en esta ocasión vuelven a ser la gráfica de barras y la gráfica circular, mostrando los valores obtenidos para cada variable.



Figura 5.41: Visualización Gráficos Mediana

Determinar Frecuencias Absolutas y IC 95 % : Para obtener las frecuencias absolutas y los intervalos de confianza del 95% de cada variable,

el frontend solicita al backend que acceda al archivo CSV generado durante el procesamiento de los datos descriptivos para las variables categóricas (análisis_estadístico_categorico.csv)

Las gráficas empleadas en esta ocasión son una gráfica de barras para las frecuencias absolutas donde cada variable tiene un color diferente para poder comparar los distintos grupos de una variable de forma más sencilla visualmente (figura 5.42), y otra gráfica de barras dobles para mostrar los intervalos de confianza inferiores y superiores al 95 % para cada variable y grupo (figura 5.43).




Figura 5.42: Visualización Gráfica Frecuencias Absolutas




Figura 5.43: Visualización Gráfica Intervalos de Confianza 95 %

- **Identificación Variable Tiempo:** El frontend interactúa con el backend para realizar la llamada al modelo e identificar la variable de tiempo y otras posibles opciones por si no es la correcta. Una vez el modelo identifica una posible variable de tiempo, se solicita al usuario que confirme la variable y, en caso de no ser la correcta, se permite modificarla.


```

<>
<Typography variant="h6" sx={{ marginBottom: 1, color: '#388E3C' }}>
  Variable de Tiempo Identificada:
</Typography>

<TextField
  value={timeV}
  onChange={(e) => setTimeV(e.target.value)}
  variant="outlined"
  fullWidth
  sx={{ marginBottom: 3 }}
/>

<Typography variant="body2" sx={{ color: '#333', textAlign: 'left', marginBottom: 1 }}>
  Otras Opciones:
</Typography>

<TextField
  value={otherOptions.join(', ')}
  onChange={(e) => setOtherOptions(e.target.value.split(',').map(val => val.trim()))}
  variant="outlined"
  fullWidth
  multiline
  sx={{ marginBottom: 3 }}
/>

<Button
  variant="contained"
  sx={{ backgroundColor: '#407AF5', fontSize: '1.1rem', marginTop: 1, alignSelf: 'center' }}
  onClick={handleConfirmTimeVariable}
>
  Confirmar Variable de Tiempo
</Button>
</>

```

Figura 5.44: Código Mostrar y Confirmar Variable de Tiempo

Tras identificar la variable de tiempo, se muestra un mensaje indicando que el proceso ha terminado correctamente y permite pasar al siguiente proceso, como en la figura 5.36.

- **Procesado de datos comparativos:** Con la variable de tiempo identificada, comienza el procesamiento de los datos comparativos para la realización de los análisis estadísticos.

El procesado de los datos comparativos es realizado mediante siete agentes encargados de realizar los análisis estadísticos. (figura 5.12

- Agente encargado de los análisis estadísticos con Chi Cuadrado.
- Agente encargado de los análisis estadísticos con Fisher.
- Agente encargado de los análisis estadísticos con T-Student.
- Agente encargado de los análisis estadísticos con Mann-Whitney.
- Agente encargado de obtener las variables significativas.
- Agente encargado de las curvas de supervivencia con Kaplan Meier.
- Agente encargado de aplicar la regresión de Cox Univariante.

Generando así un archivo CSV por cada análisis estadístico para su posterior uso. El frontend almacena donde se encuentra cada archivo para poder ir a obtener la información para su visualización.

- **Visualización de los Datos Comparativos:** Tras la realización de los análisis estadísticos de los datos comparativos, la herramienta permite ver en la interfaz gráfica los resultados obtenidos. Mostrando tablas con los resultados

de cada variable para cada estudio estadístico y gráficas que permiten comparar los resultados de manera visual los resultados de cada variable. Los valores de las gráficas de los datos comparativos que se van a emplear son los P-Valores ya que son los resultados más importantes de cada análisis. Para la realización de las gráficas se ha empleado una librería de JavaScript ApexCharts y ApexCharts-react.

La visualización de los datos comparativos se divide en siete fases:

Análisis Categórico χ^2 : Para obtener los resultados del análisis categórico de χ^2 , el frontend interactúa con el backend proporcionándole la url del archivo CSV para que extraiga toda la información necesaria para elaborar las tablas con la información de cada variable y las gráficas.

Cada variable tiene la siguiente información:

- χ^2
- Grado de Libertad
- P-Valor
- Significativo

Si la variable es significativa, aparece resaltada en la tabla.

Para la comparación visual de los resultados se muestra una gráfica de barras en la que cada variable muestra su P-Valor para compararlo con el resto de variables.




Figura 5.45: Gráfica P-Valor χ^2

Análisis Categórico Fisher: Para obtener los resultados del análisis categórico de Fisher, el frontend interactúa con el backend proporcionándole la url del archivo CSV para que extraiga toda la información necesaria para elaborar las tablas con la información de cada variable y las gráficas.

Cada variable tiene la siguiente información:

- Fisher
- P-Valor
- Significativo

```

<div>
  <TableContainer component={Paper} sx={{ boxShadow: 2, borderRadius: 2 }}>
    <Table size="small" sx={{ minWidth: 600, border: '1px solid #e0e0e0' }}>
      <TableHead>
        <TableRow sx={{ backgroundColor: '#f5f5f5' }}>
          <TableCell align="center" sx={{ fontWeight: 'bold', border: '1px solid #ccc' }}>Variable</TableCell>
          <TableCell align="center" sx={{ fontWeight: 'bold', border: '1px solid #ccc' }}>Fisher</TableCell>
          <TableCell align="center" sx={{ fontWeight: 'bold', border: '1px solid #ccc' }}>P-Value</TableCell>
          <TableCell align="center" sx={{ fontWeight: 'bold', border: '1px solid #ccc' }}>Significativo</TableCell>
        </TableRow>
      </TableHead>
      <TableBody>
        {table.map((item, idx) => {
          const isSignificative = significant[idx]?valor === true;
          return (
            <TableRow>
              <key={idx}>
                <hover>
                  <sx={{
                    backgroundColor: isSignificative ? '#e0f7fa' : 'inherit',
                    '&:hover': {
                      backgroundColor: isSignificative ? '#d9f2d9' : '#f9f9f9',
                    },
                  }}>
                </sx>
                <TableCell align="center" sx={{ border: '1px solid #e0e0e0' }}>{item.variable}</TableCell>
                <TableCell align="center" sx={{ border: '1px solid #e0e0e0' }}>
                  {statistics[idx]?valor ?? '-'}
                </TableCell>
                <TableCell align="center" sx={{ border: '1px solid #e0e0e0' }}>
                  {pValue[idx]?valor ?? '-'}
                </TableCell>
                <TableCell align="center" sx={{ border: '1px solid #e0e0e0' }}>
                  {significant[idx]?valor != null ? (significant[idx].valor ? 'Si' : 'No') : '-'}
                </TableCell>
              </TableRow>
            </>
          );
        })}
      </TableBody>
    </Table>
  </TableContainer>
  <Box sx={{ display: 'flex', justifyContent: 'center', marginTop: 2 }}>
    <ChiSquaredChart table={table} data={pValue} />
  </Box>
</div>

```

- Número de Casos
- Número de Controles
- P-Valor
- Significativo

Si la variable es significativa, aparece resaltada en la tabla.

Para la comparación visual de los resultados se muestra una gráfica de barras en la que cada variable muestra su P-Valor para compararlo con el resto de variables. Como en la figura 5.45

Análisis de supervivencia según la variable objetivo (Kaplan Meier):

Para obtener los resultados del análisis de supervivencia según la variable objetivo, el frontend le proporciona al backend tanto la localización del archivo CSV como de la imagen de la curva de supervivencia general.

Una vez el frontend recibe la información solicitada, se muestra el tiempo medio de supervivencia y el número de observaciones del análisis sobre la variable objetivo.




Figura 5.47: Visualización Análisis Supervivencia General Kaplan Meier

Análisis de supervivencia en función de cada variable (Kaplan Meier):

Para obtener y visualizar los resultados del análisis de supervivencia estratificado por cada variable, el frontend itera sobre las variables y por cada una de ellas muestra una tabla con la información de esa variable y grupo y una imagen de la curva de supervivencia de esa variable.

Análisis de Supervivencia con Modelo de Regresión de Cox Univariante: Para obtener y visualizar los resultados del análisis de supervivencia con modelo de regresión de Cox Univariante, el frontend le proporciona la URL del archivo CSV al backend, y el backend le devuelve la información necesaria de este para la visualización.

La herramienta permite muestra la siguiente información en una tabla:

- Coeficiente
- Coeficiente de Riesgos
- P-Valor
- IC inferior al 95 %
- IC superior al 95 %

Además, se muestran dos gráficas de barras horizontales para la representación gráfica de los resultados:

- Coeficientes de riesgos de cada variable
- P Valor de cada variable

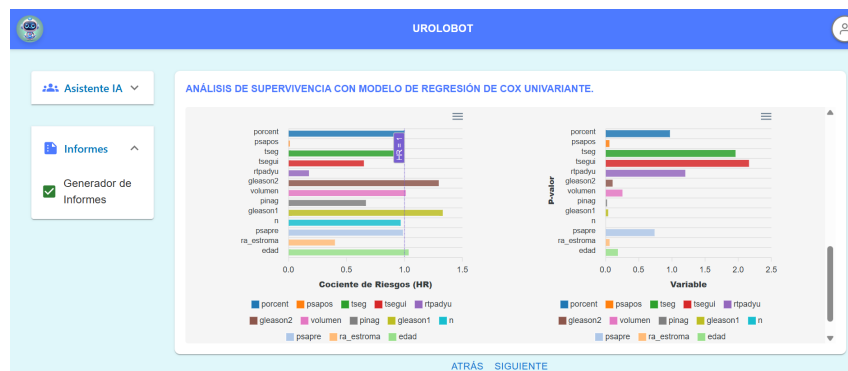


Figura 5.50: Gráficas Análisis de Supervivencia con Modelo de regresión Cox Univariante

- **Visualización de Generación Informe:** Una vez ya están todos los análisis estadísticos realizados y el usuario ha podido ver los resultados obtenidos en cada fase, la herramienta genera un documento con las conclusiones realizadas por el modelo de OpenAI en base a los resultados obtenidos y lo convierte a PDF mediante un compilador de LaTeX.

Una vez el documento esta generado, la herramienta permite abrir el documento PDF en una ventana del navegador nueva donde puede descargarlo, además, la herramienta permite descargar en formato .zip una carpeta con todos los archivos CSV con los resultados obtenidos, las gráficas generadas y el documento PDF con las conclusiones.

Para descargar el ZIP con todos los resultados obtenidos durante los análisis, el frontend interactúa con el backend que se encarga de crear un archivo .zip

con la información de la carpeta de datos procesados. Para crear el archivo, se utiliza FileResponse de la librería FastAPI empleada para la realización de la API que conecta el frontend de la aplicación con el backend.

```
@router.post('/download-zip')
async def download_zip():
    folder_path = PROC
    zip_path = '/tmp/statistics.zip'

    shutil.make_archive(base_name=zip_path.replace('.zip', ''), format='zip', root_dir=folder_path)

    time.sleep(0.5)

    if not os.path.exists(zip_path):
        raise HTTPException(status_code=500, detail="No se pudo generar el ZIP")

    return FileResponse(
        path=zip_path,
        filename="statistics.zip",
        media_type="application/zip"
    )
```

Figura 5.51: Código Generar archivo zip

Resultados de la aplicación

Una vez la herramienta ha realizado todos los análisis estadísticos y obtenido los resultados, se va a realizar una comparación de estos resultados obtenidos por la Inteligencia Artificial, con los obtenidos por Javier Cambronero en su tesis doctoral.

Tras la realización de los **análisis descriptivos**, podemos comparar los resultados de la IA con los del experto:

6.0.1. Variables Numéricas:

Tras comparar los resultados obtenidos entre la herramienta y los resultados obtenidos por Javier Cambronero y tras realizar los análisis descriptivos de las variables numéricas, podemos observar el buen funcionamiento de la herramienta, seleccionando bien las métricas de población y obteniendo resultados iguales o cercanos a la tesis original que se busca replicar. 6.1 y 6.2.

Variable	n	Media	Desviación Estándar	Mediana	RIC	Rango
n	269	135.00	77.80	135.00	134.00	1-269
edad	269	62.12	6.75	63.00	9.00	44-78
psapre	269	7.10	3.58	6.10	3.01	2.89-27.0
psalt	177	0.22	0.19	0.17	0.14	0.01-0.99
tduppre	136	61.78	101.94	32.62	49.18	0.0-818.63
nbiopsia	269	0.25	0.71	0.00	0.00	0-9
porcent	237	18.36	19.05	10.00	21.00	2.0-80.0
volumen	269	18.30	15.98	15.00	15.00	1.0-90.0
psapos	269	0.14	0.89	0.03	0.03	0.01-13.68
rtpmes	34	31.74	19.47	24.50	24.25	5.0-92.0
trbq	42	28.62	23.47	18.50	26.75	2.0-101.0
tdupli	98	14.58	12.67	10.33	9.54	2.07-75.78
t1mtx	3	29.00	25.98	14.00	22.50	14.0-59.0
tseg	269	62.61	27.37	60.43	39.05	2.2-126.78
tsuperv	3	39.33	15.04	47.00	13.50	22.0-49.0
tsegui	98	71.13	26.27	69.50	40.75	16.0-127.0
psafin	97	7.81	65.07	0.05	0.10	0.01-639.0

Figura 6.1: Análisis descriptivo de las variables numéricas

Resultados Experto					
	Nº	Media	DT	Mediana	Rango
Edad	269	62	7	63	44-78
PSA preoperatorio	269	7,10	3,58	6,10	2,89-77
PSAI/PSAt	177	0,22	0,19	0,17	0,01-0,99
T duplicación de PSA preoperatorio	136	61,78	101,94	32,62	0-818,6
Mayor % afectación un cilindro	237	18,4	19,0	10,0	2-80
Volumen tumoral (% pieza)	269	18,3	16,0	15,0	1-90
PSA posoperatorio	269	0,14	0,89	0,03	0,01-13,68
Tiempo hasta RBQ	42	29	23	19	2-101
Tiempo de seguimiento	267	62,4	27,4	60,1	2,2-126,6

Figura 6.2: Análisis descriptivo de variables numéricas Experto

6.0.2. Variables Categóricas:

Tras comparar los resultados obtenidos entre la herramienta y los resultados obtenidos por Javier Cambroneró tras realizar los análisis descriptivos de las variables categóricas, podemos observar el buen funcionamiento de la herramienta, al igual que en las variables numéricas, se usan las mismas métricas para obtener las frecuencias e intervalos de confianza y se obtienen resultados muy similares. 6.3, 6.4, 6.5 y 6.6.

Resultados IA					
variable	valor	n	porcentaje	ic_95_inf	ic_95_sup
tactor	Negativo	191	71.0	65.32	76.1
tactor	Sospechoso	64	23.79	19.09	29.23
tactor	Positivo	14	5.2	3.13	8.55
ecotr	Normal	251	93.31	89.67	95.73
ecotr	Sospechosa	18	6.69	4.27	10.33
gleason1	6	105	39.03	33.4	44.98
gleason1	7 (4+4)	73	27.14	22.17	32.75
gleason1	7 (4+3)	50	18.59	14.39	23.67
gleason1	8-10	15	5.58	3.41	9.0
gleason1	Inclasificable	26	9.67	6.68	13.79
ncilpos	<25%	114	42.38	36.62	48.35
ncilpos	25-50%	57	21.19	16.73	26.46
ncilpos	>50%	97	36.06	30.55	41.96
ncilpos	10	1	0.37	0.07	2.08
bilat	Si	86	32.09	26.79	37.9
bilat	No	181	67.54	61.72	72.86
bilat	7	1	0.37	0.07	2.08
trm1	cT2ab	177	65.8	59.94	71.21
trm1	cT2c	88	32.71	27.38	38.53
trm1	cT3	4	1.49	0.58	3.76

Figura 6.3: Comparación Análisis descriptivo de variables categóricas IA

Resultados Experto

		n	%
TACTO RECTAL	Negativo	191	71,0
	Sospechoso	64	23,8
	Positivo	14	5,2
PSA PREOPERATORIO (ng/mL)	0-6	129	48,0
	6,01-10	105	39,0
	10,01-20	31	11,5
	>20	4	1,5
ECO-TR	Normal	251	93,3
	Sospechosa	18	6,7
N° BIOPSIAS PREVIAS	0	217	80,7
	1	44	16,4
	2	7	2,6
	9	1	0,4
GLEASON BIOPSIA	6	105	39,0
	7 (3+4)	73	27,1
	7 (4+3)	50	18,6
	8-10	15	5,6
N° CILINDROS POSITIVOS	Inclasificable	26	9,7
	<25%	114	42,5
	25-50%	57	21,3
BILATERALIDAD	>50%	97	36,2
	Si	86	32,2
cTNM BIOPSIA	No	181	67,8
	cT2ab	177	65,8
	cT2c	88	32,7
	cT3	4	1,5

Figura 6.4: Comparación Análisis descriptivo de variables categóricas Experto

Resultados IA

variable	valor	n	porcentaje	lc_95_inf	lc_95_sup
gleason2	6	49	18.22	14.06	23.26
gleason2	7 (3+4)	73	27.14	22.17	32.75
gleason2	7 (4+3)	88	32.71	27.38	38.53
gleason2	8-10	57	21.19	16.73	26.46
gleason2	< 6	7 (3+4)	0.74	0.2	7 (3+4)
localiz	ZP	245	91.08	87.07	93.93
localiz	ZT	21	0.74	0.2	ZT
localiz	ZFMA	21	0.37	0.07	ZT
localiz	Múltiple	21	7.81	5.16	11.64
extracap	Si	64	23.79	19.09	29.23
extracap	No	205	76.21	70.77	80.91
vvss	Si	33	12.27	8.87	16.73
vvss	No	235	87.36	82.86	90.81
vvss	NC	Si	0.37	0.07	No
iperin2	Si	134	49.81	43.88	55.75
iperin2	No	16	5.95	NC	9.44
iperin2	NC	119	44.24	38.43	50.21
ilinf2	Si	9	NC	Si	6.24
ilinf2	No	35	13.01	9.51	17.56
ilinf2	NC	224	83.27	78.35	87.26
ilinf2	4.0	Si	0.37	0.07	No
ivascu2	Si	4	Si	0.58	NC
ivascu2	No	22	8.18	5.46	12.07
ivascu2	NC	242	89.96	85.79	93.01
ivascu2	4.0	Si	0.37	0.07	No
tnm2	pT2ab	59	21.93	17.4	27.25
tnm2	pT2c	127	47.21	41.33	53.17
tnm2	pT3	65	24.16	19.43	29.62
tnm2	pT4	pT2ab	0.37	0.07	pT2c
tnm2	pN+	17	6.32	pT3	9.89
capras	Bajo riesgo (0-2)	38	14.13	10.47	18.79
capras	Medio (2-5)	47	17.47	13.4	22.46
capras	Alto riesgo (> 5)	45	16.73	12.74	21.65
capras	3	35	13.01	9.51	17.56
capras	4	31	11.52	8.24	15.89
capras	5	13	4.83	Alto riesgo (> 5)	8.09
capras	6	25	9.29	6.37	13.36
capras	7	20	7.43	4.86	11.2
capras	8	4	Medio (2-5)	Bajo riesgo (0-2)	3.76
capras	9	5	Medio (2-5)	Bajo riesgo (0-2)	4.28
capras	10	5	Medio (2-5)	Bajo riesgo (0-2)	4.28
capras	11	Medio (2-5)	Bajo riesgo (0-2)	Bajo riesgo (0-2)	Alto riesgo (> 5)

Figura 6.5: Comparación Análisis descriptivo de variables categóricas IA 2

Resultados Experto							
		n	%				
GLEASON2	6	49	18,2	PINAG	Si	110	93,2
	7 (3+4)	73	27,1		No	8	6,8
	7 (4+3)	88	32,7	MQP	Si	74	27,6
	8-10	57	21,2		No	194	72,4
	<6	2	0,7	TNM2	pT2ab	59	21,9
LOCALIZACIÓN	ZP	245	91,1		pT2c	127	47,2
	ZT	2	0,7		pT3	65	24,2
	ZFMA	1	0,4		pT4	1	0,4
	Múltiple	21	7,8		pN+	17	6,3
EEC	Si	64	23,8	TRBQ	>18 meses	23	54,8
	No	205	76,2		≤18 meses	19	45,2
IV5	Si	33	12,3	TDUPLI	>12 meses	40	40,8
	No	235	87,7		≤12 meses	58	59,2
IPERIN2	Si	134	89,3	CAPRA-5	0-2	130	48,3
	No	16	10,7		3-5	79	29,4
ILINF2	Si	9	20,5		>5	60	22,3
	No	35	79,5				
IVASCU2	Si	4	15,4				
	No	22	84,6				

Figura 6.6: Comparación Análisis descriptivo de variables categóricas Experto 2

6.0.3. Análisis comparativo con la variable objetivo.

Como el objetivo de la tesis de Javier Cambroneró era encontrar predictores para la **recaída bioquímica (RBQ)** de pacientes que hayan tenido cáncer de próstata, el siguiente objetivo del análisis para poder replicar un estudio bioquímico profesional es usar test de comparación para saber si existe alguna relación fuera del producto del azar de las variables con el RBQ.

Tras la realización de los **análisis comparativos**, podemos comparar los resultados de la IA con los del experto:

6.0.3.1. Test χ^2 :

Tras comparar los resultados obtenidos entre la herramienta y los resultados obtenidos por Javier Cambroneró tras realizar los análisis comparativos con el test de χ^2 , podemos observar que obtiene resultados muy similares, como podemos ver comparando las figuras 6.7 y 6.8; algunas de las variables tienen pequeñas diferencias con los resultados de Javier Cambroneró que podrían deberse a pequeñas modifi-

caciones de los datos realizadas por el experto a la hora de realizar sus análisis. También el hecho que discrepen o haya algunas variables que se tengan en cuenta o que no se hayan tenido en cuenta puede indicar un posible objeto de investigación futura o ahorro de tiempo en hacerle análisis a variables que se haya visto que sus resultados no son favorables para una siguiente fase de análisis.

Resultados IA							
		n	%	n	%	χ^2	p-valor
GLEASON1	6	8	19.0	93	44.3	25.488	0.000
	7 (3+4)	13	31.0	60	28.6		
	7 (4+3)	18	42.9	27	12.9		
	8-10	0	0.0	10	4.8		
NCILPOS	Inclasificable	3	7.1	20	9.5	6.675	0.083
	< 25%	12	28.6	100	47.6		
	25-50%	14	33.3	40	19.0		
	50%	16	38.1	69	32.9		
IVASCU	10	0	0.0	1	0.5	0.240	0.887
	No	1	2.4	4	1.9		
	NC	41	97.6	205	97.6		
	4	0	0.0	1	0.5		
GLEASON2	6	1	2.4	46	21.9	15.844	0.003
	7 (3+4)	10	23.8	63	30.0		
	7 (4+3)	16	38.1	66	31.4		
	8-10	15	35.7	33	15.7		
LOCALIZ	< 6	0	0.0	2	1.0	8.275	0.041
	ZP	35	83.3	194	92.4		
	ZT	0	0.0	2	1.0		
	ZFMA	1	2.4	0	0.0		
EXTRACAP	Múltiple	6	14.3	14	6.7	7.646	0.006
	Si	16	38.1	37	17.6		
	No	26	61.9	173	82.4		
	4	0	0.0	1	0.5		
VVSS	Si	10	23.8	15	7.1	11.023	0.004
	No	32	76.2	194	92.4		
	NC	0	0.0	1	0.5		
	4	0	0.0	1	0.5		
IPERIN2	Si	24	57.1	98	46.7	2.167	0.338
	No	1	2.4	14	6.7		
	NC	17	40.5	98	46.7		
	4	0	0.0	1	0.5		
ILINF2	Si	2	4.8	5	2.4	0.929	0.818
	No	5	11.9	25	11.9		
	NC	35	83.3	179	85.2		
	4	0	0.0	1	0.5		
IVASCU2	Si	2	4.8	1	0.5	6.626	0.085
	No	5	11.9	16	7.6		
	NC	35	83.3	192	91.4		
	4	0	0.0	1	0.5		
PINAG	Si	18	42.9	91	43.3	36.702	0.000
	No	7	16.7	0	0.0		
	NC	17	40.5	119	56.7		
	4	0	0.0	1	0.5		
		n	%	n	%	χ^2	p-valor
CAPRAS	Bajo riesgo (0-2)	1	2.4	37	17.6	47.276	0.000
	Medio (2-5)	1	2.4	46	21.9		
	Alto riesgo (> 5)	6	14.3	39	18.6		
	3	4	9.5	30	14.3		
	4	5	11.9	24	11.4		
	5	6	14.3	7	3.3		
	6	7	16.7	13	6.2		
	7	9	21.4	9	4.3		
	8	2	4.8	1	0.5		
	9	1	2.4	2	1.0		
	10	0	0.0	2	1.0		
	4	0	0.0	1	0.5		
TNM2	pT2ab	3	7.1	54	25.7	20.154	0.000
	pT2c	21	50.0	104	49.5		
	pT3	18	42.9	35	16.7		
	pN+	0	0.0	17	8.1		
PTEN	0.0	8	19.0	16	41.0	5.499	0.064
	1.0	15	35.7	13	33.3		
	2.0	19	45.2	10	25.6		
	4	0	0.0	1	0.5		
ERG	0.0	22	52.4	23	59.0	0.139	0.709
	1.0	20	47.6	16	41.0		
	2.0	12	28.6	9	23.1		
	4	0	0.0	1	0.5		
KI67	0.0	12	28.6	9	23.1	0.925	0.630
	1.0	15	35.7	18	46.2		
	2.0	15	35.7	12	30.8		
	4	0	0.0	1	0.5		
SPINK1	0.0	29	69.0	28	71.8	0.001	0.978
	1.0	13	31.0	11	28.2		
	2.0	14	33.3	21	53.8		
	4	0	0.0	1	0.5		
CMYC	0.0	14	33.3	21	53.8	2.682	0.102
	1.0	28	66.7	18	46.2		

Figura 6.7: Comparación Análisis comparativo con χ^2 IA

Resultados Experto

		CASOS		CONTROLES		χ^2 p-valor
		n	%	n	%	
GLEASON1	6	8	19,0	93	44,3	0,000
	7 (3+4)	13	31,0	60	28,6	
	7 (4+3)	18	42,9	27	12,9	
	8-10	0	0,0	10	4,8	
	Inclasificable	3	7,1	20	9,5	
NCILPOS	<25%	12	28,6	100	47,8	0,040
	25-50%	14	33,3	40	19,1	
	>50%	16	38,1	69	33,0	
IVASCU	No	1	2,4	4	1,9	0,843
	NC	41	97,6	205	98,1	
GLEASON2	<6	0	0,0	2	1,0	0,003
	6	1	2,4	46	21,9	
	7 (3+4)	10	23,8	63	30,0	
	7 (4+3)	16	38,1	66	31,4	
	8-10	15	35,7	33	15,7	
LOCALIZ	ZP	35	83,3	194	92,4	0,041
	ZT	0	0,0	2	1,0	
	ZFMA	1	2,4	0	0,0	
	Múltiple	6	14,3	14	6,7	
EEC	Si	16	38,1	37	17,6	0,003
	No	26	61,9	173	82,4	
IVS	Si	10	23,8	15	7,2	0,001
	No	32	76,2	194	92,8	
IPERIN2	Si	24	96,0	98	87,5	0,218
	No	1	4,0	14	12,5	
ILINF2	Si	2	28,6	5	16,7	0,469
	No	5	71,4	25	83,3	
IVASCU2	Si	2	28,6	1	5,9	0,127
	No	5	71,4	16	94,1	
PINAG	Si	18	72,0	91	100,0	0,000
	No	7	28,0	0	0,0	
MQP	Si	22	52,4	39	18,7	0,000
	No	20	47,6	170	81,3	
	pT2ab	3	7,1	54	25,7	
TNM2	pT2c	21	50,0	104	49,5	0,000
	pT3	18	42,9	35	16,7	
	pN+	0	0,0	17	8,1	
	0-2	8	19,0	122	58,1	
CAPRA-S	3-5	15	35,7	61	29,0	0,000
	>5	19	45,2	27	12,9	
RA1	Negativo (<90%)	20	47,6	27	69,2	0,049
	Positivo (≥90%)	22	52,4	12	30,8	
RA2	Negativo (<30%)	34	87,2	8	21,1	0,000
	Positivo (≥30%)	5	12,8	30	78,9	
PTEN	Presencia	8	19,0	16	41,0	0,030
	Pérdida	34	81,0	23	59,0	
ERG	Negativo (>0,7)	22	52,4	23	59,0	0,551
	Positivo (0-0,7)	20	47,6	16	41,0	
Ki-67	Negativo	12	28,6	9	23,1	0,573
	Positivo	30	71,4	30	76,9	
SPINK1	Negativo (0-0,05)	35	83,3	28	71,8	0,212
	Positivo (>0,05)	7	16,7	11	28,2	
C-MYC	Negativo (0-0,2)	14	33,3	21	53,8	0,063
	Positivo (>0,2)	28	66,7	18	46,2	

Figura 6.8: Comparación Análisis comparativo con χ^2 Experto

6.0.3.2. Test *MannWhitney*:

Tras comparar los resultados obtenidos entre la herramienta y los resultados obtenidos por Javier Cambroneró tras realizar los análisis comparativos con el test de *MannWhitney*, podemos observar el buen funcionamiento de la herramienta, llegando a resultados muy similares para este tipo de análisis, como podemos ver comparando las figuras. Aquí se puede ver un logro en el análisis del agente LLM encargado de seleccionar qué test se aplicarán a las variables, ya que con su capacidad de razonamiento logró entender, por el comportamiento de la variable en la base de datos como por conocimientos dotados gracias al *prompt engineering*, como este es uno de los test más importantes para lograr encontrar relación entre variables y clave para encontrar los futuros predictores de RBQ. 6.9 y 6.10

Variable	n (casos)	n (controles)	p-value	Significativa
n	42	210	0.0000	Sí
edad	42	210	0.0107	Sí
psapre	42	210	0.0039	Sí
psalt	32	139	0.7618	No
tduppre	21	105	0.0639	No
nbiopsia	42	210	0.6895	No
porcent	36	184	0.0030	Sí
volumen	42	210	0.0386	Sí
psapos	42	210	0.0000	Sí
tdupli	42	39	0.5933	No
tseg	42	210	0.0000	Sí
tseguí	42	39	0.0091	Sí
psafin	41	39	0.2874	No

Figura 6.9: Comparación Análisis comparativo con *MannWhitney* IA

		N	Media	Desviación	Mediana	Mínimo	Máximo	p-valor
PSAPRE (ng/mL)	Casos	42	7,74	3,80	6,92	2,89	27,00	0,004
	Controles	210	6,60	2,98	5,77	2,99	24,55	
PSAPOS (ng/mL)	Casos	42	0,055	0,0332	0,01	0,01	0,16	0,000
	Controles	210	0,033	0,0228	0,01	0,01	0,15	
TDUPLI (meses)	Casos	42	14,75	10,24	11,13	3,0	40,9	0,590
	Controles	39	17,21	16,28	10,71	5,5	75,8	
CAPRA-S	Casos	42	4,88	2,17	5,00	0	9	0,000
	Controles	210	2,53	2,21	2,00	0	10	

Figura 6.10: Comparación Análisis comparativo con *MannWhitney* Experto

6.0.4. Test Kaplan Meier General:

Tras analizar la curva de supervivencia general obtenida para estos datos, podemos apreciar que los resultados son parecidos a los obtenidos por el experto y son estadísticamente correctos, ya que las curvas se comportan de la misma forma. Como podemos observar en las figuras 6.11 y 6.12.

Cabe destacar que en el momento de trabajar con el colaborador **Carlos Pascual Mateo**, se nos planteó hacer el análisis de supervivencia con una variable de seguimiento errónea como lo era el *tiempo desde la recidiva bioquímica*. Fue gracias al propio modelo que sugirió el *tiempo de seguimiento del paciente* con el que pudimos detectar el error y obtener mejores resultados, dando una vez más una muestra del alcance que puede llegar a tener un modelo LLM bien entrenado y dotado de una buena ingeniería de *prompts* de lo que puede llegar a hacer, como

sugerir cambios de perspectiva en las investigaciones médicas y que los profesionales puedan tener siempre otras alternativas en los estudios.




Figura 6.11: Curva Supervivencia Kaplan Meier general IA




Figura 6.12: Curva Supervivencia Kaplan Meier general Experto

6.0.5. Test Kaplan Meier Estratificado:

Tras analizar las curvas de supervivencia estratificadas obtenidas para estos datos, podemos apreciar que los resultados son parecidos a los obtenidos por el experto

y son estadísticamente correctos. Como podemos observar en las figuras 6.13, 6.14, 6.15 y 6.16.

Pese a que algunas curvas se pueden encontrar varios valores de forma distinta, es porque nuestra aplicación hace las curvas de una manera correcta estadísticamente hablando, a veces, en términos clínicos, para que un profesional pueda ver las curvas de una manera más coherente tiene que llegar a agrupar algunas variables si las categorías de la misma son muchas como se puede ver en el ejemplo de la variable **CAPRA-S** que a pesar de que estadísticamente la curva dada por nuestra aplicación es correcta estadísticamente hablando, clínicamente no aporta que hayan tantos valores, por lo que Javier las agrupa en tres curvas. Esta modificación en la aplicación es una muy buena idea para un próximo trabajo a futuro.




Figura 6.13: Curvas Supervivencia Kaplan Meier estratificadas IA




Figura 6.14: Curvas Supervivencia Kaplan Meier estratificadas IA 2




Figura 6.15: Curvas Supervivencia Kaplan Meier estratificadas Experto




Figura 6.16: Curvas Supervivencia Kaplan Meier estratificadas Experto 2

Cox Univariante: Tras analizar los resultados obtenidos tras realizar el modelo

de regresión de Cox univariante y comprobar los resultados con los obtenidos por el experto, podemos observar que obtiene resultados muy similares, como podemos ver comparando las figuras 6.17 y 6.18; Nos encontramos que al final nuestra aplicación dió unos posibles predictores muy buenos de la RBQ parecidos a los de la tesis de Javier.

Variable	HR	p-valor	C Harrell
volumen	1,010	0,252	0.4862204724409449
tsegui	0,649	0,000	0.9924071991001124
rtpadyu	0,175	0,000	0.6760404949381328
n	0,967	0,000	0.7429696287964005
pinag	0,667	0,019	0.5793025871766029
porcent	1,000	0,968	0.4901531728665207
psapos	0,008	0,055	0.4662542182227221
ra_estroma	0,399	0,058	0.5913705583756346
gleason1	1,330	0,037	0.6009561304836896
tseg	0,925	0,000	0.8723284589426322
edad	1,036	0,183	0.5250281214848144
psapre	0,986	0,736	0.5084364454443194
gleason2	1,296	0,103	0.5489313835770528

Figura 6.17: Modelo de Regresión de Cox Univariante IA

Variable	eventos	N	HR	p-valor	C Harrell	ph
PSAPRE	42	252	1,576	0,019	0,603	0,336
GLEASON1	39	229	1,673	0,000	0,638	0,362
GLEASON2	42	252	1,865	0,000	0,651	0,382
NCILPOS	42	251	1,435	0,027	0,594	0,905
VOLUMEN	42	252	1,022	0,011	0,613	0,365
EEC	42	252	3,041	0,000	0,613	0,736
IVS	42	251	4,652	0,000	0,592	0,973
IPERIN2	25	137	3,145	0,248	0,547	0,191
ILINF2	7	37	2,089	0,412	0,636	0,132
IVASCU2	7	24	8,361	0,017	0,673	0,968
PINAG	25	116	0,085	0,000	0,625	0,391
MQP	42	251	3,971	0,000	0,664	0,451
TDUPLI	42	81	1,434	0,243	0,580	0,023
CAPRA-S	42	252	2,949	0,000	0,727	0,800
RA1	42	81	1,822	0,053	0,586	0,377
RA2	39	77	0,124	0,000	0,712	0,965
PTEN	42	81	2,167	0,054	0,566	0,496
ERG	42	81	1,091	0,775	0,517	0,461
KI-67	42	81	1,042	0,894	0,492	0,702
SPINK1	42	81	1,128	0,697	0,498	0,206
C-MYC	42	81	1,689	0,098	0,576	0,372

Figura 6.18: Modelo de Regresión de Cox Univariante Experto

Tras realizar la comparación de resultados de la herramienta con los del experto, podemos observar el buen funcionamiento de la herramienta para la realización de estos análisis estadísticos y de la generación de documentos, llegando a conclusiones basadas en los resultados en un tiempo muy reducido y con bastante fiabilidad.

Se puede sacar conclusiones de los resultados muy prometedoras y entusiasmantes ya que con la capacidad de un buen modelo LLM orquestador capaz de analizar variables y comportamiento de los datos, uniendole con buenas herramientas de

análisis se pudo hacer el trabajo que antes era inimaginable hacer en años. Es un muy buen primer paso para dar un uso bueno y que las IA puedan ser la mano derecha del ser humano en los siguientes avances.

Conclusiones y Trabajo Futuro

7.1. Conclusiones

Una vez desarrolladas las anteriores secciones donde se describen las especificaciones técnicas de la herramienta, Urolobot se presenta como una herramienta innovadora que combina la realización de análisis estadísticos con la obtención de conclusiones en base a esos resultados para la automatización de la generación de informes clínicos proporcionando ayuda en este sector de el ámbito médico.

Para ello, se han desarrollado una serie de funcionalidades que permite a los usuarios proporcionar sus propias bases de datos, procesar los datos clínicos, aplicar las distintas pruebas estadísticas según el tipo de variable y generar un documento PDF mediante los resultados y conclusiones obtenidas por el modelo.

Gracias al uso de modelos de procesamiento de lenguaje como GPT-4o-mini, Urolobot permite reducir el tiempo necesario para realizar los análisis estadísticos y obtener conclusiones sobre los resultados finales de una manera sencilla.

Además, Urolobot ha sido desarrollado de manera que los usuarios puedan utilizarlo de manera intuitiva y fácil, mediante una interfaz gráfica clara y accesible.

Una conclusión que se puede sacar del desarrollo de esta aplicación y citando a nuestro colaborador Carlos Pascual: *“Este puede ser el primer paso de una herramienta muy grande para la medicina”*. Cosa que nos llena de satisfacción saber que el resultado de tanto esfuerzo en conjunto sean las bases para posibles herramientas que aprovechando la potencia de razonamiento de los LLM pueda lograr cosas grandes para ayudar a las personas.

El código fuente de Urolobot lo puedes encontrar en este enlace al repositorio de GitHub: [Urolobot enlace](#).

7.2. Trabajo Futuro

Durante el desarrollo de Urolobot, se ha enfocado principalmente en implementar la funcionalidad de generador de informes de la herramienta, para lograr que obtuviese resultados correctos y llegase a conclusiones similares a los de la tesis doctoral del experto que nos ha proporcionado los datos. Debido al limitado tiempo dispo-

nible para la realización del proyecto, se han quedado funcionalidades para realizar en un futuro o mejorar algunas de las ya implementadas.

7.2.1. Funcionalidades a implementar en un futuro

- **Ampliar los posibles análisis para hacer más estudios de predicción:** Como la aplicación se centra en la realización de análisis biomédicos donde se hacen estudios estadísticos de supervivencia, el proyecto se ve acotado a bases de datos y estudios que sean para determinar predictores de supervivencia de una variable médica. En futuras versiones se podrían añadir estudios específicos para otro objetivo a parte de la predicción de variables en torno a la supervivencia.
- **Aumentar la interacción del usuario en el proceso de generación de documentos:** Esta funcionalidad permitirá al usuario interactuar más con la herramienta durante el proceso de generación de documentos. Por el momento la herramienta permite al usuario modificar la variable objetivo y la de tiempo antes de realizar los análisis, se añadirá la posibilidad de cambiar valores de los resultados obtenidos, seleccionar el tipo de test que quieres realizar en vez de ser siempre estáticos, e indicar alguna recomendación al modelo antes de volver a realizar los análisis y haber obtenido resultados diferentes a los esperados. Esto proporcionaría a los usuarios una herramienta más efectiva, permitiéndoles ayudar a la herramienta en las decisiones más clínicas donde es más posible que cometa algún error.
- **Añadir agentes de búsqueda bibliográfica en plataformas como PubMed:** Para poder brindar más contexto a los agentes LLM que hacen las conclusiones de todo el estudio, se podría usar y aplicar agentes que se encarguen de buscar en plataformas como PubMed estudios bibliográficos sobre el estudio médico en cuestión. Al inyectar al prompt esta información, le brindará mejor contexto y hará que las conclusiones y razonamientos se vean mejorados.
- **Añadir agente que elabore una discusión médica:** Pese a que Urolobot hace un estudio biomédico muy completo que definitivamente ayudará en la investigación y en la toma de decisión a los expertos médicos, faltaría hacer un agente que, de la mano de la funcionalidad mencionada anteriormente de dotar contexto bibliográfico, haga una discusión médica comparando los resultados obtenidos en el estudio de la aplicación con los datos obtenidos de la búsqueda. Esto aunque sería un avance muy grande, es el tema más complicado de replicar a un estudio humano, ya que la discusión médica se tiene que hacer bajo el contexto de la experiencia profesional e investigativa de un experto en la materia.
- **Consultas sobre el documento generado desde el Asistente Virtual:** El usuario podrá realizar consultas al modelo de OpenAI desde el chat sobre el documento generado con las conclusiones sobre los análisis estadísticos realizados. Empleando técnicas de inteligencia artificial como embeddings y RAG.

- **Asistente Virtual de urología basado en chat con seguimiento individualizado de pacientes:** Esta funcionalidad permitirá al usuario, llevar en la aplicación la gestión de sus pacientes, teniendo en ella toda la información del historial clínico del paciente. El usuario podrá crear un chat individualizado para cada paciente y realizar consultas al modelo especializado en el ámbito médico, concretamente en la urología. Este chat, dará respuestas basándose en sus conocimientos médicos y teniendo en cuenta el historial del paciente y datos proporcionados en anteriores consultas.
- **Modelo de DeepLearning para detección de recaída de un paciente:** Esta funcionalidad permitirá apoyar al usuario a la hora de decidir el riesgo que tiene un paciente de sufrir una recaída. El modelo es entrenado con una gran base de datos de pacientes, con todos los parámetros que pueden influir en una recaída y si ha tenido una recaída o no por el momento. El usuario podrá proporcionar la información necesaria del paciente y el modelo le dará una conclusión de la probabilidad de recaída del paciente, de manera razonada para que el usuario pueda entender porque ha llegado a esa conclusión.

Conclusions and Future Work

7.3. Conclusions

After describe all the technical specifications of the tool in the previous sections, Urolobot is a new tool that combines statistical analysis with the obtaining of conclusions based on the results for the automation of the clinical report generation, providing assistance in this sector of the medical field.

For this purpose, a series of functionalities have been developed that allow users to provide their own databases, process the clinical data, apply the different statistical tests according to the type of variables and generate a PDF document with the results and conclusions obtained by the model.

Using language processing models such as GPT-4o-mini, Urolobot reduces the time required to perform statistical analysis and obtain conclusions on the final results in a simple way.

In addition, Urolobot has been developed in such a way that users can use it in a simple and intuitive way, through a clear and accessible GUI.

7.4. Future Work

During the development of Urolobot, the main focus has been the implementation of the report generator functionality of the tool, to obtain accurate results and reach conclusions similar to those of the doctoral thesis of the expert. Due to the limited time available for the realization of the project, some functionalities have been left to be implemented in the future or to improve some of the functionalities that are already implemented.

You can find Urolobot's source code at this link to the GitHub repository: [Urolobot link](#).

7.4.1. Functionalities to be developed in the future

- **Expand possible analyses to enable more predictive studies:** Since the application is focused on conducting biomedical analyses involving statistical survival studies, the project is currently limited to databases and studies

aimed at identifying predictors of survival for a medical variable. In future versions, specific studies could be added with objectives beyond the prediction of survival-related variables.

- **Increase user interaction in the document generation process:** This functionality will allow the user to interact more with the tool during the document generation process. At the moment, the tool allows the user to modify the target and time variable before the analysis, the ability to change values of the results obtained will be added, select the type of test you want to apply, and indicate some recommendation to the model before re-analyzing and having obtained different results than expected. Providing the users a more useful tool, allowing them to help the tool in the clinical decisions where it is more likely to make a mistake.
- **Add literature search agents for platforms like PubMed:** To provide more context to the LLM agents generating the study conclusions, agents could be implemented to search for bibliographic studies related to the medical case on platforms such as PubMed. Injecting this information into the prompt would provide better context, leading to improved conclusions and reasoning.
- **Add an agent to generate a medical discussion:** Although Urolobot performs a very comprehensive biomedical analysis that will undoubtedly support research and assist medical experts in decision-making, it still lacks an agent capable of generating a medical discussion. Building on the previously mentioned functionality of providing bibliographic context, this agent would compare the results obtained from the application's study with the findings from the literature search. While this would be a major advancement, it is also one of the most difficult aspects to replicate from a human-led study, as a medical discussion must be developed within the context of the professional and research experience of an expert in the field.
- **Queries in the document generated from Virtual Assistant:** The user will be able to consult the OpenAI model from the chat, making queries on the document generated with the conclusions of the statistical analysis. Using Artificial techniques such as embeddings and RAG.
- **Virtual Urology Assistant based on chat with individualized follow-up:** This functionality will allow the user, to manage his patients in the application, having in it all the information of the patient's clinical history. The user will be able to create an individualized chat for each patient and make queries to the model specialized in the medical field, specifically in urology. This chat will give answers based on the medical knowledge and considering the patient's history and data provided in previous consultations.
- **DeepLearning model for patient relapse detection:** This functionality will support the user in deciding a patient's risk of relapse. The model is trained with a large database of patients, with all the parameters that can have an impact on relapse. This user will be able to provide the necessary patient information and the model will give a conclusion of the patient's relapse

probability, in a reasoned way, that the user can understand why the model has made that conclusion.

Contribuciones Personales

Jorge Ortega Carretero

En esta sección se detalla la contribución de Jorge Ortega Carretero al desarrollo del proyecto, destacando las diversas tareas realizadas que fueron cruciales para alcanzar los objetivos establecidos para la implementación de la herramienta. La participación de Jorge abarca desde la fase inicial de investigación hasta la realización de pruebas finales para comprobar el correcto funcionamiento de la herramienta.

- **Investigación sobre Uso de IA en Generación de Documentos Clínicos**

Al comenzar el proyecto, Jorge comenzó una investigación sobre el uso de modelos de procesamiento de lenguaje en la generación de informes clínicos, para determinar la posibilidad de emplear un modelo de procesamiento de lenguaje para realizar análisis estadísticos y apoyar en la redacción de los informes clínicos. Para profundizar sobre el tema, Jorge revisó una serie de documentos científicos proporcionados por un experto en el ámbito de la urología. Estos documentos, centrados en el uso de modelos de lenguaje como ChatGPT en la redacción científica y análisis de datos, le permitieron entender las capacidades actuales de las herramientas. Los documentos revisados trataban sobre estudios de comparación de la escritura por humanos con ChatGPT, ChatGPT para apoyar en la investigación médica... Esta investigación permitió a Jorge tener una visión sobre el potencial y las limitaciones del uso de la inteligencia artificial en la elaboración de informes clínicos.

- **Investigación sobre las técnicas de Prompt Engineering**

Una de las tareas iniciales que llevo Jorge a cabo al comenzar el proyecto fue la investigación sobre técnicas de Prompt Engineering, con el objetivo de aprovechar al máximo las capacidades del modelo de procesamiento de lenguaje natural. Para ello, investigo a través de internet ejemplos, cursos y observaciones para comprender como estructurar de manera optima los prompts para obtener respuestas más precisas y útiles del modelo.

- **Colaboración en el diseño de la Arquitectura del Proyecto**

Una vez iniciado el proceso de desarrollo de la aplicación, Miguel y Jorge se encargaron de realizar la arquitectura del proyecto con el objetivo de estructurar

claramente los distintos componentes. Tras analizar ejemplos de aplicaciones de gran escala, decidimos que la estructura seleccionada era la que mejor se adaptaba a las necesidades del proyecto, además de garantizar la seguridad y el mantenimiento de la aplicación. Además, Jorge se encargó de asegurar una comunicación fluida y eficiente entre el cliente y el servidor, diseñando protocolos de comunicación seguros, mediante tecnologías para realizar solicitudes HTTP y comunicar las distintas partes del proyecto entre sí, garantizando siempre que el frontend solo estaría en contacto con el backend, que sería el encargado de comunicarse con el resto de servicios.

■ **Implementación y Configuración de la Base de Datos**

Una de las tareas que Jorge ha llevado a cabo durante la implementación del proyecto fue investigar qué base de datos convenía emplear en el proyecto, para la gestión de usuarios. Tras evaluar distintas opciones, se optó por usar MariaDB, una base de datos relacional compatible con MySQL. Jorge diseñó la estructura de la base de datos, asegurando su eficiencia y optimización para el almacenamiento de la información requerida. También tuvo en cuenta a la hora de diseñar la base de datos, en la escalabilidad a la hora de desarrollar nuevas funcionalidades en un futuro sobre la aplicación. No obstante, Jorge también se encargó de generar los usuarios de prueba para acceder a la aplicación en la base de datos y de eliminar los posibles usuarios erróneos generados durante las pruebas. Para el manejo de la base de datos, utilizó la herramienta HeidiSQL, permitiendo realizar tareas de administración y mantenimiento de forma sencilla.

■ **Evaluación de Prompts**

Durante el proceso de realización de Prompts para proporcionárselos al modelo, Jorge participó en su diseño e iteración, para tratar de aprovechar al máximo las capacidades del modelo de lenguaje natural. Este trabajo implicó ayudar a Miguel a refinar algunos de los primeros prompts, hasta lograr un comportamiento adecuado y estable.

■ **Gestión de cuentas de usuario**

Otra de las tareas llevadas a cabo por Jorge fue la gestión de usuarios dentro de la aplicación. Para ello, implementó la conexión entre la aplicación y la base de datos, así como la integración del frontend con el backend para el proceso de autenticación. Desarrollo funcionalidades clave como el registro de nuevos usuarios, inicio de sesión, modificación de información de la cuenta, cambio de contraseña, y la opción de dar de baja una cuenta. Desde el frontend Jorge ha implementado la lógica necesaria para gestionar la interacción del usuario con el sistema de autenticación, mediante peticiones HTTP enviadas a la API del backend, donde son procesadas las solicitudes y se ejecutan las funciones correspondientes.

■ **Conexión del Backend con el Frontend**

Jorge también desempeñó la tarea de establecer la conexión entre el backend y el frontend, mediante el desarrollo de una API en el backend empleando FastAPI. Se encargó de implementar distintos endpoints para cubrir las distintas

funcionalidades del sistema, organizadas principalmente en dos secciones: autenticación y uso de IA generativa. Desde el frontend, Jorge ha desarrolló peticiones HTTP utilizando fetch para comunicarse con la API y activar las funcionalidades correspondientes, asegurando una comunicación fluida entre ambas partes.

■ Desarrollo de la Página Web

Para la implementación de la interfaz de usuario del proyecto, Jorge desarrolló una aplicación web utilizando React. La estructura del proyecto se organizó de forma modular, separando componentes y utilidades, facilitando así su mantenimiento y escalabilidad. El frontend ha sido desarrollado para comunicarse con el backend exclusivamente mediante solicitudes HTTP.

La aplicación está compuesta por varias secciones, todas ellas implementadas de forma que garantice una buena experiencia de usuario:

- Página de Autenticación
- Página de Información de Usuario
- Página de Cambio de Contraseña
- Página de Chat
- Generador de Informes

La generación de Informes es la funcionalidad principal de la herramienta, y ha sido desarrollada de forma modular para guiar al usuario a lo largo de cada una de las fases del proceso de análisis. Donde en esta sección, Jorge desarrolló varias páginas específicas, cada una encargada de una etapa concreta del proceso, lo que permite estructurar el proceso de manera sencilla y clara. Gracias a este enfoque, la herramienta es muy intuitiva y accesible.

Además, Jorge se encargó de implementar una navegación fluida, rápida y sencilla entre las diferentes páginas de la aplicación.

■ Implementación de Funcionalidades relacionadas con la Gestión de Documentos

Jorge se encargó de desarrollar funcionalidades clave asociadas a la gestión de documentos. Entre estas funcionalidades se encuentran: Almacenar los archivos subidos a la aplicación durante el proceso de generación de informes, La apertura del documento generado en una nueva ventana del navegador, y la opción de descargar un archivo comprimido (ZIP) que contiene todos los documentos generados durante el proceso de la generación del documento.

Elaboración de la Memoria del Proyecto

Jorge ha desempeñado un gran papel en la elaboración de la memoria del proyecto, contribuyendo en el resumen, la introducción, las tecnologías empleadas, la arquitectura de la aplicación, la implementación de la plataforma, la comparación de resultados, las conclusiones y trabajo futuro, la especificación de requisitos, el manual de instalación, así como en las traducciones de los apartados correspondientes.

Miguel Antonio Amato Hermo

En esta sección se detalla el trabajo realizado por el alumno Miguel Amato para el desarrollo del proyecto, destacando las diversas tareas que fueron cruciales para la elaboración de Trabajo de Fin de Grado. La aportación de Miguel abarca desde la fase inicial de investigación, primeros pasos del desarrollo de la página web, hasta el desarrollo de los agentes LLM que orquestan la aplicación.

- **Investigación sobre alcance de los LLM**

Se hizo un estudio de las capacidades de los modelos GPT y otros modelos de lenguaje para saber la capacidad que tienen los mismos para realizar tareas complejas, con cursos de Prompt Engineering, Agentes LLM y revisión de documentación Miguel llegó a la conclusión de usar los modelos GPT junto a técnicas que se enseñan en el área de Agentes de LLM como el control de salida de formato con **pydantic**, modularización del agente y división de trabajo así como el estudio de las técnicas de *prompt engineering*.

- **Diseño base de la página web**

Durante las primeras fases del trabajo, Miguel diseñó una pequeña demo de como podría ser la base para la web de la aplicación. consistía en un chat responsive donde se hablaba con un modelo de lenguaje. Cuando cambió el foco del proyecto a algo más a lo que se acerca ahora, se empezaron a hacer cambios, pero parte de la base de la app sigue a día de hoy presente.

- **Diseño de la arquitectura principal de la Aplicación**

Al igual que el diseño base de la web, en las primeras fases del proyecto Miguel diseñó la arquitectura de la aplicación, decidiendo junto a Jorge las tecnologías a usar para la conexión del backend con el frontend, usando FastAPI como decisión final, con pydantic para validación de datos de las peticiones HTTP. También organizó todos los módulos para mantener aisladas las partes más importantes del proyecto para que se puedan desarrollar en paralelo y aumentar la productividad del desarrollo.

- **Realización de la preparación de datos para el modelo.**

Comenzando ya con el desarrollo del backend de la aplicación, una de las primeras labores de Miguel fue diseñar una forma de generalizar los datos de las posibles bases de datos que puedan ser input en la aplicación, se logró exitosamente hacer un pipeline que estandarice, e iguale variables tanto del maestro como de la base de datos, algo clave para los futuros análisis estadísticos.

- **Diseño de Agente LLM General.**

Otro de los primeros pasos para poder seguir con el desarrollo fue el crear un *template* de agente LLM que puedan usar los demás agentes especializados, Miguel se encargó de dotarle con las funciones necesarias como dar un modelo default como lo es el **gpt-o-mini**, darle temperatura al modelo default y dotarlo de poder soportar formatos de respuesta usando la validación de datos de **pydantic**, clave para que los resultados de los agentes hayan mejorado sustancialmente.

- **Diseño de los agentes LLM de orquestación de datos.**

Uno de los puntos más importantes del desarrollo fue la realización y programación de los agentes que iban a ser capacidades de analizar el contexto y comportamiento de cada variable para clasificarla tanto por su naturaleza como para saber cuál test estadístico comparativo se tendría que aplicar para la variable en función de la variable objetivo. Miguel fue el responsable de idear e implementar este agente en la aplicación.

- **Programación de agentes estadísticos.**

Luego de hacer los agentes LLM que darían el camino a seguir para iniciar los análisis estadísticos, Miguel desarrolló los agentes encargados de dar los análisis estadísticos respectivos para que el estudio biomédico siga las pautas más estrictas y profesionales para lograr un resultado favorable y positivo.

- **Desarrollo del análisis de supervivencia.**

Una vez realizados los estudios estadísticos tanto descriptivos como comparativos y almacenado sus resultados, todos dados y orquestados por un modelo de lenguaje. Miguel procedió al desarrollo del agente estadístico encargado de realizar las curvas de supervivencia Kaplan Meier y las curvas de Kaplan Meier estratificadas que usando la curva de supervivencia original se hacía una máscara con los valores de la variable a hacer la curva y se obtenía la nueva curva.

- **Desarrollo y diseño del Agente LLM que redacta el reporte final.**

Llegados a la fase final del desarrollo del proyecto, Miguel fue el encargado de diseñar y desarrollar los agentes que redactarían las conclusiones finales de todos los resultados obtenidos previamente por los análisis estadísticos. Se optó por usar modelos de lenguaje que usando los datos específicos de la parte que les tocaba redactar, analizara y mostrara tanto los resultados como las conclusiones. El formato de salida era código en LaTeX que luego un orquestador general juntaría y organizaría para generar el reporte final. Miguel se encargó para mejorar los tiempos en paralelizar todos los agentes usando una barrera de hilos que una vez todos estén listos se originaría y compilaría el documento con **pdfLatex**

Bibliografía

"Truth, it resides in the fire The need of it's
dire Deceiving the lies I know"

Kendrick Lamar Duckworth

Análisis de supervivencia. *Medicina de Familia. SEMERGEN*, 2023.

AMAZON WEB SERVICES. What are large language models? <https://aws.amazon.com/what-is/large-language-model/>, 2023.

DEEPLARNING.AI. Chatgpt prompt engineering for developers. <https://www.deeplearning.ai/short-courses/chatgpt-prompt-engineering-for-developers/>, 2023.

EXECUTIVE OFFICE OF THE PRESIDENT. Promoting the use of trustworthy artificial intelligence in the federal government. <https://www.federalregister.gov/documents/2020/12/08/2020-27065/promoting-the-use-of-trustworthy-artificial-intelligence-in-the-federal-government> 2020. Federal Register, Vol. 85, No. 236, pp. 78939–78941.

FISTERRA. Guía: Asociación de variables cualitativas: El test exacto de fisher y ... 2023. Accedido el 11 de mayo de 2025.

GONZÁLEZ, M. y PÉREZ, L. El valor p, y medidas de efecto: su interpretación en investigación. *Enfermería Clínica*, vol. 31(2), páginas 123–130, 2021. Accedido el 11 de mayo de 2025.

IBM. Análisis de supervivencia de kaplan-meier - ibm. 2023. Accedido el 11 de mayo de 2025.

JMP. La prueba t | introducción a la estadística - jmp. 2023. Accedido el 11 de mayo de 2025.

LÓPEZ, A. y MARTÍNEZ, J. Significancia clínica y significancia estadística. ¿qué es más significativo? *Revista de Neumología Pediátrica*, vol. 19(2), páginas 41–45, 2024. Accedido el 11 de mayo de 2025.

- LÓPEZ JIMÉNEZ, F. y OBRADOR, G. Métodos estadísticos en estudios de supervivencia. *Elsevier*, 2019. Accedido el 11 de mayo de 2025.
- MEDWAVE. La prueba de ji-cuadrado - medwave. 2010. Accedido el 11 de mayo de 2025.
- MINITAB SUPPORT. ¿qué son variables categóricas, discretas y continuas? 2023. Accedido el 11 de mayo de 2025.
- MOLINA ARIAS, M., ORTEGA PÁEZ, E. y OCHOA SANGRADOR, C. Estudios de supervivencia. método de kaplan-meier. *Evidencias en Pediatría*, vol. 18, página 20, 2022. Accedido el 11 de mayo de 2025.
- NORI, H., KING, N., MCKINNEY, S. M. ET AL. Capabilities of gpt-4 on medical challenge problems. *arXiv preprint arXiv:2303.13375*, 2023.
- OPENAI. How to work with large language models. https://cookbook.openai.com/articles/how_to_work_with_large_language_models, 2023.
- OPENAI. A practical guide to building agents. 2025. Accessed: 2025-05-11.
- ORTEGA PÁEZ, E., OCHOA SANGRADOR, C. y MOLINA ARIAS, M. Estudios de supervivencia. modelo de riesgos proporcionales. regresión de cox. *Evidencias en Pediatría*, vol. 19, página 48, 2023. Accedido el 11 de mayo de 2025.
- QUESTIONPRO. Prueba u de mann-whitney: Qué es y cómo funciona - questionpro. 2022. Accedido el 11 de mayo de 2025.
- REBASA, P. Conceptos básicos del análisis de supervivencia. *Cirugía Española*, vol. 78(2), páginas 117–123, 2005.
- SERVICIO GALLEGO DE SALUD. *Análisis Descriptivo*, 2014. Accedido el 11 de mayo de 2025.
- SHAPIRO, S. S. y WILK, M. B. An analysis of variance test for normality (complete samples). *Biometrika*, vol. 52(3/4), páginas 591–611, 1965.
- SHREFFLER, J. y HUECKER, M. R. Hypothesis testing, p values, confidence intervals, and significance. *StatPearls [Internet]*, 2023. Accedido el 11 de mayo de 2025.

Casos de Uso

Este capítulo está dedicado a la descripción de los actores implicados en la aplicación y las especificaciones de requisitos iniciales de la misma.

Actores:

- **Usuario registrado:** Los usuarios registrados en el sistema podrán interactuar con la herramienta, donde se dispondrá de un chat en el que realizar consultas al modelo de OpenAI, y la funcionalidad principal de la herramienta, un generador de informes clínicos de manera automatizada mediante llamadas al modelo y realización de análisis estadísticos. Además, podrán gestionar su cuenta, permitiéndoles cerrar sesión y realizar modificaciones de Nombre, correo electrónico, nombre de usuario y contraseña.
- **Usuario no registrado:** los usuarios que no estén registrados en el sistema tendrán que registrarse en el sistema para poder disfrutar de las funcionalidades que la aplicación ofrece. Durante el proceso de registro, el usuario tendrá que introducir datos como el correo electrónico y la contraseña.

Especificación de Requisitos:

- Cuentas de usuario.
- Uso de la inteligencia generativa.

Cuentas de usuario:

Uso de la inteligencia generativa:

Requisito	Registrar usuario
Identificador	1.1
Prioridad	Alta
Descripción	Los usuarios no registrados que quieran hacer uso de la aplicación podrán crear una cuenta.
Precondición	Ser usuario no registrado.
Entrada	Nombre completo, correo electrónico, contraseña, repetir contraseña.
Salida	NA
Secuencia normal	1. El usuario accede a la aplicación, donde se encuentra la pantalla de autenticación. 2. En esta pantalla el usuario realiza click en el botón “Registrarse”. 3. La aplicación le pedirá que rellene la información necesaria para crear una cuenta nueva. 4. El usuario rellena los campos solicitados y realiza click en “Registrarse”. 5. La aplicación comprueba los datos. 6. La aplicación muestra un mensaje de cuenta creada correctamente.
Postcondición	Se ha registrado el nuevo usuario en la aplicación.
Excepciones	■ En caso de no coincidir “contraseña” con “repetir contraseña” se mostrará un mensaje de error. ■ En caso de no cumplir las especificaciones de la contraseña se mostrará un mensaje de error. ■ En caso de no introducir un correo válido en el apartado “correo electrónico” se mostrará un mensaje de error. ■ En caso de existir el nombre o el correo se mostrará un mensaje de error.
Comentarios	NA
Actores	Usuario no registrado

Tabla A.1: Requisito para Registrar Usuario

Requisito	Login
Identificador	1.2
Prioridad	Alta
Descripción	Los usuarios no registrados con una cuenta creada, podrán acceder a la aplicación iniciando sesión.
Precondición	Ser usuario no registrado y tener una cuenta dada de alta en la aplicación.
Entrada	Correo electrónico y contraseña.
Salida	NA
Secuencia normal	1. El usuario accede a la aplicación, donde se encuentra la pantalla de autenticación. 2. La aplicación le solicitará la información requerida para iniciar sesión. 3. El usuario completa la información solicitada y realiza un click en “Log In”. 4. La aplicación comprueba datos. 5. La aplicación muestra la pantalla principal con acceso a su funcionamiento.
Postcondición	Se ha iniciado sesión en la aplicación.
Excepciones	■ En caso de no existir el correo electrónico o el nombre de usuario se mostrará un mensaje de error. ■ En caso de no ser la contraseña correcta se mostrará un mensaje de error.
Comentarios	NA
Actores	Usuarios no registrados

Tabla A.2: Requisito de Login

Requisito	Restaurar Contraseña
Identificador	1.3
Prioridad	Baja
Descripción	Los usuarios registrados que tengan una cuenta en la aplicación pero no recuerden su contraseña, podrán cambiar la contraseña para poder acceder.
Precondición	Debe ser un usuario registrado, con una cuenta dada de alta.
Entrada	Correo electrónico, Nueva contraseña, Repetir nueva contraseña.
Salida	Contraseña restablecida.
Secuencia normal	1. El usuario accede a la pantalla principal y realiza click en “Cambiar Contraseña” desde el menú de cuenta de usuario. 2. La aplicación le redireccionará a otra pantalla, en la que se le solicitará el correo y la contraseña nueva de manera duplicada. 3. El usuario completa la información requerida y hace click sobre el botón “Restaurar contraseña”. 4. La aplicación le redirecciona a una nueva pantalla donde tendrá que introducir “Nueva contraseña” y “Repetir nueva contraseña”. 5. La aplicación comprobará los datos. 6. La aplicación le indicará que se ha cambiado la contraseña.
Postcondición	Se ha restablecido la contraseña.
Excepciones	■ En caso de no coincidir “contraseña” con “repetir contraseña” se mostrará un mensaje de error. ■ En caso de no cumplir las especificaciones de la contraseña se mostrará un mensaje de error. ■ En caso de no introducir un correo válido en el apartado “correo electrónico” se mostrará un mensaje de error.
Comentarios	NA
Actores	Usuario no Registrado o administrador.

Tabla A.3: Requisito para Restaurar Contraseña

Requisito	Logout
Identificador	1.4
Prioridad	Alta
Descripción	Un usuario registrado puede cerrar sesión.
Precondición	Ser un Usuario Registrado y haber iniciado sesión.
Entrada	NA
Salida	NA
Secuencia normal	1. El usuario desde la pantalla principal, hace click sobre el botón “Mi cuenta” y se desplegará un menú de opciones de su cuenta. 2. En el menú desplegado se realizará un click en el botón “Cerrar Sesión”. 3. Se redireccionará a la pantalla de autenticación sin acceso a las funcionalidades de la aplicación.
Postcondición	Se ha cerrado la sesión del usuario.
Excepciones	NA
Comentarios	NA
Actores	Usuarios Registrados.

Tabla A.4: Requisito para Logout

Requisito	Modificar usuario
Identificador	1.5
Prioridad	Media
Descripción	El usuario quiere modificar información acerca de su cuenta.
Precondición	Ser un usuario registrado con la sesión abierta.
Entrada	Información a cambiar
Salida	NA
Secuencia normal	1. El usuario desde la pantalla principal, hace click sobre el botón “Mi cuenta” y se desplegará un menú de opciones de su cuenta. 2. En el menú desplazado el usuario le dará click a “Mi Cuenta”. 3. El usuario cambia los datos deseados. 4. El usuario confirmará esos cambios con un botón de “Guardar”.
Postcondición	Se han cambiado los datos del usuario.
Excepciones	NA
Comentarios	■ En esta sección se podrán cambiar: ● Nombre de usuario ● Nombre ● Correo electrónico
Actores	Usuario Registrado que haya iniciado sesión.

Tabla A.5: Requisito para Modificar Usuario

Requisito	Dar de baja a un usuario
Identificador	1.6
Prioridad	Alta
Descripción	Un usuario registrado puede darse de baja en la aplicación perdiendo toda la información almacenada en su cuenta.
Precondición	Ser un Usuario Registrado y haber iniciado sesión.
Entrada	NA
Salida	NA
Secuencia normal	1. El usuario desde la pantalla principal, hace click sobre el botón de cuenta de usuario y se desplegará un menú de opciones de su cuenta. 2. En el menú desplegado se realizará un click en el botón “Mi Cuenta”. 3. La aplicación le muestra la información del usuario para modificarla, y botón para guardar nueva información y otro para eliminar usuario. 4. El usuario realiza click en “Eliminar Usuario” y la aplicación eliminará al usuario y le redirecciona a la página de autenticación.
Postcondición	Se ha eliminado la cuenta del usuario.
Excepciones	NA
Comentarios	NA
Actores	Usuarios Registrados y Administradores que hayan iniciado sesión.

Tabla A.6: Requisito para Dar de Baja a un Usuario

Uso de la inteligencia generativa:

Requisito	Consultar a la IA mediante el chat
Identificador	2.1
Prioridad	Baja
Descripción	Los Usuarios Registrados podrán realizar consultas a la IA dentro del chat.
Precondición	Debe ser un Usuario Registrado y haber iniciado sesión.
Entrada	Consulta a realizar a la IA.
Salida	Respuesta de la IA a la consulta realizada.
Secuencia normal	1. El Usuario Registrado accede al chat desde la página principal realizando un click en Asistente Virtual, acceder al chat. 2. Al acceder al chat, escribirá la consulta y enviará el mensaje al modelo. 3. La IA proporcionará una respuesta a la consulta realizada por el modelo GPT-4o-mini de OpenAI.
Postcondición	NA
Excepciones	■ En caso de dar un error a la hora de dar una solución a la consulta del Usuario Registrado, permitir volver a realizar la misma consulta.
Comentarios	NA
Actores	Usuarios Registrados que hayan iniciado sesión.

Tabla A.7: Requisito para Consultar a la IA mediante el Chat

Requisito	Añadir Base de Datos y Archivo Maestro
Identificador	2.2
Prioridad	Alta
Descripción	El Usuario Registrado puede adjuntar la base de datos y el archivo maestro para comenzar el proceso de generación del documento.
Precondición	Debe ser un Usuario Registrado, haber iniciado sesión.
Entrada	Base de datos y Archivo Maestro.
Salida	Archivos cargados correctamente.
Secuencia normal	1. El Usuario Registrado realiza click en el botón “generador de informes”. 2. Al acceder al generador de informes, accede a una página donde pulsa el botón “Añadir archivos”. Permite buscar en el explorador de archivos la base de datos y el archivo maestro a utilizar. 3. Se abrirá el explorador de archivos, donde podrá seleccionar la base de datos y el archivo maestro a utilizar. 4. El usuario realiza click en el botón “Preparar datos”. 5. El usuario será notificado una vez los datos estén preparados para los análisis.
Postcondición	NA
Excepciones	■ Se mostrará un error si el documento adjuntado está en un formato no permitido. ■ Se mostrará un error si el documento tiene algún error por el cual la IA no pueda acceder a él.
Comentarios	NA
Actores	Usuario Registrado que hayan iniciado sesión.

Tabla A.8: Requisito para Añadir Base de Datos y Archivo Maestro

Requisito	Identificar Variable Objetivo y Categorizar Variables
Identificador	2.3
Prioridad	Alta
Descripción	El Usuario solicita al modelo que identifique la variable de grupo una vez ya están preparados los datos.
Precondición	Ser un Usuario Registrado y haber iniciado sesión.
Entrada	NA
Salida	Archivo JSON con cada variable, su tipo y el test que se va a aplicar.
Secuencia normal	1. El Usuario Registrado tras añadir la base de datos y el archivo maestro y preparar los datos, realiza click en “Identificar variable de grupo”. 2. Se realiza una llamada al modelo para que identifique la variable de grupo con la que se realizarán los análisis. 3. Una vez el modelo identifica la variable de grupo, se muestra al usuario que tiene la posibilidad de modificarla en caso de considerar que hay otra mejor que la encontrada por el modelo. El usuario realiza click en “Confirmar variable”. 4. Tras confirmar la variable, el modelo realiza una categorización de las variables en función a la variable de grupo.
Postcondición	NA
Excepciones	■ En caso de dar un error se puede volver a solicitar al modelo identificar y categorizar las variables.
Comentarios	NA
Actores	Usuario Registrado que haya iniciado sesión.

Tabla A.9: Requisito para Identificar Variable Objetivo y Categorizar Variables

Requisito	Realización de análisis estadísticos de variables descriptivas
Identificador	2.4
Prioridad	Alta
Descripción	Los Usuarios Registrados solicitan al modelo que realice los análisis estadísticos de la fase en la que se encuentra durante la generación del documento.
Precondición	Debe ser un Usuario Registrado, haber realizado el proceso de identificación de variable de grupo y categorizar variables.
Entrada	NA
Salida	Archivo CSV con resultados de análisis estadísticos de variables numéricas y archivo CSV con los resultados de las variables estadísticas.
Secuencia normal	1. El Usuario Registrado ha realizado la identificación de la variable objetivo y categorizado las variables, accediendo así a la fase de los análisis estadísticos. 2. Una vez terminados los análisis estadísticos, la aplicación avisará al usuario de poder ver los resultados obtenidos.
Postcondición	NA
Excepciones	■ En caso de dar un error a la hora de realizar los análisis, permitirá volver a realizarlos de nuevo.
Comentarios	NA
Actores	Usuarios Registrados que hayan iniciado sesión.

Tabla A.10: Requisito para Análisis Estadísticos de Variables Descriptivas

Requisito	Identificar Variable de Tiempo
Identificador	2.5
Prioridad	Alta
Descripción	El Usuario solicita al modelo que identifique la variable de tiempo una vez ha visto los resultados obtenidos de los análisis de variables descriptivas.
Precondición	Que el usuario registrado tenga la sesión iniciada.
Entrada	NA
Salida	Mensaje de Variables de tiempo identificada.
Secuencia normal	1. El Usuario Registrado ha visto los resultados obtenidos de los análisis de variables descriptivas. Accediendo así a la fase de identificación de variables. 2. El usuario realiza click en “Identificar variable de tiempo”. 3. El modelo identifica la variable de tiempo y el usuario puede cambiar la variable en caso de considerar que hay otra que se ajuste mejor. 4. El usuario realiza click en “Confirmar variable”.
Postcondición	Se creará un archivo JSON con la variable de tiempo.
Excepciones	■ Si hay algún problema en la identificación de la variable, se podrá realizar de nuevo la identificación.
Comentarios	NA
Actores	Usuario registrado que hayan iniciado sesión

Tabla A.11: Requisito para Identificar Variable de Tiempo

Requisito	Realización de análisis estadísticos de variables comparativas
Identificador	2.6
Prioridad	Alta
Descripción	Los Usuarios Registrados solicitan al modelo que realice los análisis estadísticos de las variables comparativas de la fase en la que se encuentra durante la generación del documento.
Precondición	Debe ser un Usuario Registrado, haber realizado el proceso de identificación de variable de tiempo.
Entrada	NA
Salida	Archivo CSV con resultados de análisis estadísticos de variables numéricas y archivo CSV con los resultados de las variables estadísticas.
Secuencia normal	1. El Usuario Registrado ha realizado la identificación de la variable tiempo, accediendo así a la fase de realización de análisis de las variables comparativas. 2. Una vez terminados los análisis estadísticos de las variables comparativas, la aplicación avisará al usuario de poder ver los resultados obtenidos.
Postcondición	NA
Excepciones	■ En caso de dar un error a la hora de realizar los análisis, permitirá volver a realizarlos de nuevo.
Comentarios	NA
Actores	Usuarios Registrados que hayan iniciado sesión.

Tabla A.12: Requisito para Análisis Estadísticos de Variables Comparativas

Requisito	Abrir Documento Generado
Identificador	2.7
Prioridad	Alta
Descripción	El usuario abre el documento generado con las conclusiones obtenidas por el modelo basándose en los resultados de los análisis.
Precondición	Ser un Usuario Registrado y haber llegado a generar el documento con las conclusiones del modelo sobre los resultados.
Entrada	NA
Salida	Documento Generado PDF
Secuencia normal	1. El Usuario Registrado ha realizado los análisis de las variables comparativas y ha visualizado los resultados, accede a la fase de generación de informes, donde el modelo comienza a sacar las conclusiones en base a los resultados y genera un documento PDF. 2. El usuario realiza click en el botón “Abrir PDF”. 3. Se abre una nueva ventana con el PDF generado y donde se puede descargar el documento.
Postcondición	NA
Excepciones	■ En caso de que el documento no se genere correctamente se podrá generar de nuevo el documento.
Comentarios	NA
Actores	Usuario registrado que hayan iniciado sesión

Tabla A.13: Requisito para Abrir Documento Generado

Requisito	Descargar Documentos del Proceso de Generación de Documento
Identificador	2.8
Prioridad	Media
Descripción	El usuario registrado quiere descargar en su equipo todos los documentos creados durante el proceso.
Precondición	Ser un Usuario Registrado y haber llegado a generar el documento con las conclusiones del modelo sobre los resultados.
Entrada	NA
Salida	NA
Secuencia normal	1. El Usuario Registrado ha realizado los análisis de las variables comparativas y ha visualizado los resultados, accede a la fase de generación de informes, donde el modelo comienza a sacar las conclusiones en base a los resultados y genera un documento PDF. 2. El usuario realiza click en el botón “Descargar ZIP”. 3. Se comienza el proceso de descarga de una carpeta zip con todos los documentos generados durante el proceso. 4. Se avisa al usuario una vez está descargado el archivo zip.
Postcondición	Se descarga la carpeta de documentos en formato zip.
Excepciones	■ Si da error en la descarga se podrá volver a solicitar descargar la carpeta.
Comentarios	NA
Actores	Usuario registrado que hayan iniciado sesión

Tabla A.14: Requisito para Descargar Documentos del Proceso de Generación de Documento

Apéndice B

Manual de Instalación del Proyecto:

Se ha desarrollado un manual para guiar a los usuarios en la instalación del proyecto.

El repositorio del proyecto es: Repositorio TFG

v

Antes de comenzar, asegúrate de tener instalados los siguientes programas y herramientas:

- Git
- Python (versión recomendada: 3.12.7)
- Node.js (versión recomendada: 20.18.0)

```
curl -o- https://raw.githubusercontent.com/nvm-sh/nvm/v0.40.0/install
nvm install 20
sudo apt install npm
```

- HeidiSQL
- OpenAI

Pasos de Instalación:

1. **Clonar el repositorio** Ejecuta el siguiente comando en tu terminal:

```
git clone git@github.com:jortega9/TFG_IA_GENERATIVA_AMBITO_MEDICO.git
```

2. **Navegar al directorio del proyecto**

```
cd TFG_IA_GENERATIVA_AMBITO_MEDICO
```

3. Crear entorno virtual Crear entorno virtual python 3.12

```
python3.12 -m venv .venv
source .venv/bin/activate
```

4. Instalar las dependencias de Python Selecciona el interprete de python 3.12.7 (.venv)

```
cd backend
pip install -r requirements.txt
```

En caso de dar conflicto de dependencias hacer:

```
pip install openai
pip install langchain
```

5. Instalar las dependencias de Node.js

```
cd frontend
npm install
```

6. Instalar Compilador PdfLatex

```
sudo apt install texlive-latex-base
sudo apt install texlive-lang-spanish texlive-latex-recommended texlive
```

7. Configurar la base de datos Abre HeidiSQL y crea la base de datos urolobot

■ user

#	Nombre	Tipo de datos	Longitud/Con...	Sin signo	Permitir ...	Relen...	Predeterminado	Comentario	Collation	Expresión	Virtualidad
1	uuid_user	VARCHAR	50	☐	☐	☐	Sin valor predeter...		utf8mb4_unicode_ci		
2	name	VARCHAR	150	☐	☐	☐	Sin valor predeter...		utf8mb4_unicode_ci		
3	username	VARCHAR	50	☐	☐	☐	Sin valor predeter...		utf8mb4_unicode_ci		
4	email	VARCHAR	100	☐	☐	☐	Sin valor predeter...		utf8mb4_unicode_ci		
5	password	VARCHAR	70	☐	☐	☐	Sin valor predeter...		utf8mb4_unicode_ci		
6	secret	VARCHAR	70	☐	☒	☐	NULL		utf8mb4_unicode_ci		
7	date	DATETIME		☐	☐	☐	Sin valor predeter...				
8	last_updated	DATETIME		☐	☐	☐	Sin valor predeter...				
9	last_login	DATETIME		☐	☐	☐	Sin valor predeter...				
10	uuid_group	VARCHAR	20	☐	☐	☐	-		utf8mb4_unicode_ci		
11	validated	INT	1	☐	☐	☐	0				
12	token	VARCHAR	512	☐	☒	☐	NULL		utf8mb4_unicode_ci		
13	is_active	INT	1	☐	☐	☐	0				

Figura B.1: User Database

■ user_group

#	Nombre	Tipo de datos	Longitud/Con...	Sin signo	Permitir ...	Relen...	Predeterminado	Comentario	Collation	Expresión	Virtualidad
1	uuid_group	VARCHAR	20	☐	☐	☐	Sin valor predet...		utf8mb4_unicode_ci		
2	group_name	VARCHAR	50	☐	☐	☐	Sin valor predeter...		utf8mb4_unicode_ci		

Figura B.2: User Group Database

■ user_meta

#	Nombre	Tipo de datos	Longitud/Con...	Sin signo	Permitir ...	Relen...	Predeterminado	Comentario	Collation	Expresión	Virtualidad
1	user_userid	VARCHAR	50	☐	☒		☐	Sin valor predeter...	utf8mb4_unicode_ci		
2	meta_key	VARCHAR	20	☐	☒		☐	Sin valor predeter...	utf8mb4_unicode_ci		
3	meta_value	TEXT		☐	☒		☐	Sin valor predeter...	utf8mb4_unicode_ci		

Figura B.3: User Meta Database

8. **Configurar archivo .env** Crea un archivo .env en el directorio raíz del proyecto basandote en env.template .

```
cp .env.template .env
```

9. **Configurar archivo config.init** Crea un archivo config.init en el directorio ai del proyecto basandote en config.init.template .

```
cd ai
cp config.init.template config.ini
```

Modo De Uso:

Arrancar el backend de la aplicación

```
cd backend
uvicorn src.app:app --reload --port 8000 --host 0.0.0.0 --env-file ../.env
```

Arrancar frontend de la aplicación

```
cd frontend
npm run dev
```

Notas Adicionales

- Asegurate de tener bien configurado el archivo .env
- Asegurate de tener creada la base de datos sql (HeidiSQL) para el control de usuarios de la aplicación
- Asegurate de tener todas las dependencias instaladas (python y node.js)

Manual de Usuario:

Se ha desarrollado un manual para guiar al usuario. Mostrando cómo usar cada una de las funcionalidades de la herramienta mediante explicaciones apoyadas por capturas de pantalla.

C.1. Autenticación

- **Formulario de Inicio de Sesión** La primera página a la que te dirige al acceder a la aplicación es la página de inicio de sesión de la aplicación, en la cuál se solicitan las credenciales del usuario para acceder a la herramienta. También se ofrece la opción de acceder al registro de un nuevo usuario.

The image shows a login interface for 'UroloBot'. At the top center is a circular logo featuring a stylized robot head. Below the logo, the text 'Iniciar Sesión en UroloBot' is displayed in blue. There are two input fields: the first is labeled 'Correo Electrónico *' and the second is labeled 'Contraseña *'. Below these fields is a blue button with the text 'INICIAR SESIÓN' in white. At the bottom, there is a link that reads '¿No tienes cuenta? REGISTRATE'.

Figura C.1: Manual: Formulario Inicio de Sesión

- **Formulario de Registrar Nuevo Usuario** Los nuevos usuarios, disponen de la opción de registrar una nueva cuenta de usuario accediendo mediante el botón de REGISTRATE de la página de Inicio de Sesión. Para la creación de una nueva cuenta, el usuario debe proporcionar la información solicitada por la aplicación y una vez realizada la validación de los datos, se notificará al usuario que la cuenta ha sido creada correctamente. Permitiendo pinchar sobre el botón de INICIAR SESIÓN para volver al formulario de Inicio de Sesión y acceder a la herramienta.

El formulario de registro de nuevo usuario en UroloBot se encuentra en una página con fondo azul claro. En la parte superior central hay un icono de un robot y el título "Regístrate en UroloBot" en azul. Debajo del título hay cuatro campos de entrada de texto con el siguiente orden: "Nombre *", "Correo Electrónico *", "Contraseña *" y "Confirmar Contraseña *". Debajo de estos campos hay un botón azul con el texto "REGISTRARSE" en blanco. En la parte inferior central, en un tamaño de fuente pequeño, se encuentra el texto "¿Ya tienes cuenta? INICIAR SESIÓN".

Figura C.2: Manual: Formulario Registrar Nuevo Usuario

C.2. Página Principal

- **Encabezado** La aplicación mantiene siempre el mismo encabezado durante todas las páginas dentro de la herramienta una vez ya se ha iniciado sesión (C.3) A la izquierda del encabezado podemos ver el icono de la aplicación, en el centro tenemos el nombre de la aplicación que al pinchar sobre él te redirige a la página principal y a la derecha el icono de la cuenta del usuario, desde el cual se despliega un menú con las funcionalidades de Gestión de la cuenta (REF).
- **Página de Bienvenida** Tras iniciar correctamente la sesión el usuario, se muestra la página de bienvenida a la aplicación, en la cuál el usuario observará un mensaje de bienvenida a la herramienta. Además se dispone de un menú lateral, desde el cuál es posible acceder a las distintas funcionalidades de la aplicación. El usuario puede acceder al chat marcando el checkbox de Acceder al Chat del Asistente Virtual (C.4), y al Generador de Informes marcando su checkbox correspondiente (C.5).



Figura C.3: Manual: Página de Bienvenida

- **Chat con Asistente Virtual** Tras seleccionar la funcionalidad del chat con el asistente de inteligencia artificial, se mostrará en la página principal una

interfaz básica de un chat, desde la cuál es posible realizar una consulta escribiendo en el espacio proporcionado para escribir al usuario y posteriormente pinchando sobre el botón de enviar. La consulta es recibida por el LLM y muestra la respuesta obtenida.




Figura C.4: Manual: Chat con Asistente Inteligencia Artificial

- **Generador de Informes** Tras seleccionar la funcionalidad de generación de informes, se mostrará en la página principal la interfaz inicial del proceso de generación de documentos. El proceso de generación de documentos se divide en las siguientes fases:

1. **Carga de BBDD y Archivo Maestro (.xlsx y .json)** Al acceder a la interfaz inicial del proceso de generación de documentos, observamos un espacio donde permite buscar los archivos en el explorador de archivos que van a ser usados para la generación del documento. El usuario debe añadir la Base de datos (BBDD.xlsx) y el archivo maestro en formato JSON (master.json). En caso de subir algún archivo en un formato no válido, se avisará al usuario que el archivo que ha subido no es válido.



Figura C.5: Manual: Cargar BBDD y Archivo Maestro

Una vez seleccionada la base de datos y el archivo maestro, el usuario podrá preparar los datos para usarlos posteriormente durante los análisis estadísticos pinchando sobre el botón de Preparar Datos. Una vez preparados los datos, se notificará al usuario que ha terminado y que puede

avanzar a la siguiente fase. Para avanzar a la siguiente fase, el usuario pinchará sobre el botón de siguiente y si quiere volver en algún momento a la fase anterior, pinchara sobre atrás.




Figura C.6: Manual: Preparar los datos subidos para los análisis

2. **Identificar variable de grupo y categorizar variables** Una vez los datos están preparados para comenzar con el proceso de la generación del documento, la herramienta permite al usuario identificar la variable de grupo y categorizar las variables en función de la variable de grupo obtenida. El usuario debe pinchar sobre el botón de Identificar variable de grupo y categorizar variables para comenzar con el proceso de identificación de la variable objetivo.



Figura C.7: Manual: Identificación Variable de Grupo

Tras identificar la variable de grupo, la herramienta permite al usuario ver la variable identificada y las claves válidas y modificarlas en caso de considerar que haya otra variable que puede proporcionar un resultado mejores resultados. Una vez se haya validado la variable de grupo identificada, el usuario pinchara sobre el botón Confirmar Variable de Grupo, guardando los cambios de la modificación y comenzando el proceso de categorización de las variables. Tras finalizar el proceso de categorización de las variables, el usuario puede avanzar a la siguiente fase.

UROLOBOT

Asistente IA

Informes

Generador de Informes

IDENTIFICACIÓN DE VARIABLE DE GRUPO Y CATEGORIZACIÓN VARIABLES.

Variable de Grupo Identificada:

rbq

Claves Válidas:

1, 2

CONFIRMAR VARIABLE DE GRUPO

ATRÁS SIGUIENTE

Figura C.8: Manual: Confirmar variable de Grupo y Categorizar las Variables

3. **Procesar datos para análisis descriptivos** Tras categorizar las variables, la herramienta comenzará a realizar los análisis descriptivos para las variables numéricas y categóricas y almacenando los resultados en archivos CSV que se usarán posteriormente.

UROLOBOT

Asistente IA

Informes

Generador de Informes

PROCESANDO DATOS DE BBDD Y MAESTRO.

PROCESAR DATOS DESCRIPTIVOS

ATRÁS SIGUIENTE

Figura C.9: Manual: Procesar datos para análisis descriptivos

Una vez finalizados los análisis descriptivos, la herramienta avisa al usuario que los datos descriptivos han sido procesados correctamente y permite avanzar a la siguiente fase.

UROLOBOT

Asistente IA

Informes

Generador de Informes

PROCESANDO DATOS DE BBDD Y MAESTRO.

Datos descriptivos procesados correctamente.

ATRÁS SIGUIENTE

Figura C.10: Manual: Procesamiento de datos para análisis descriptivos completado

4. **Visualización Resultados Análisis Descriptivos** Tras obtener los resultados, se mostrará la visualización mediante una tabla y gráficos de los resultados obtenidos de la Media de las variables numéricas. Permitiendo cambiar la visualización de los resultados entre la media y la desviación típica pinchando sobre los botones superiores.

• **Media**



Figura C.11: Manual: Tabla Análisis Media de Variables Numéricas

• **Desviación Típica**




Figura C.12: Manual: Gráficos Análisis Desviación Típica de Variables Numéricas

Tras avanzar a la siguiente ventana, se mostrará la visualización mediante una tabla y gráficos de los resultados obtenidos de la Mediana de las variables numéricas. Permitiendo cambiar la visualización de los resultados entre la mediana y el rango intercuartílico pinchando sobre los botones superiores.

- **Mediana**
- **Rango Intercuartílico**

Se visualizan los resultados de la Mediana y del Rango Intercuartílico en tablas y gráficos como los de la media C.11 y la desviación típica C.12. Una vez avanzas a la última ventana de visualización de los resultados de los análisis descriptivos, se mostrará la visualización mediante una tabla y gráficos de los resultados obtenidos de las frecuencias absolutas

de las variables categóricas. Permitiendo cambiar la visualización de los resultados entre las frecuencias absolutas y los intervalos de confianza superiores e inferiores al 95 %.

● Frecuencias Absolutas



Figura C.13: Manual: Tabla de Frecuencias Absolutas para Variables Categóricas




Figura C.14: Manual: Gráfica de Frecuencias Absolutas para Variables Categóricas

● Intervalos de Confianza 95 %




Figura C.15: Manual: Tabla de Intervalos de Confianza al 95 % para Variables Categóricas




Figura C.16: Manual: Gráfica de Intervalos de Confianza al 95 % para Variables Categóricas

5. **Identificar variable de tiempo** Tras la visualización de los resultados de los análisis descriptivos, la herramienta permite al usuario identificar la variable de tiempo. El usuario debe pinchar sobre el botón de Identificar variable de tiempo para comentar con el proceso de identificación.



Figura C.17: Manual: Identificar Variable de Tiempo

Una vez identificada la variable de tiempo, la herramienta le muestra al usuario la variable identificada y otras opciones posibles y le permite modificar la variable por la que el usuario considere mejor.



Figura C.18: Manual: Confirmar Variable de Tiempo

Una vez confirmada la variable, el usuario puede avanzar a la siguiente fase.

6. **Procesar datos para análisis comparativos** Tras identificar la variable de tiempo, la herramienta comenzará a realizar los análisis comparativos para las variables numéricas y categóricas y almacenando los resultados en archivos CSV que se usarán posteriormente.



Figura C.19: Manual: Procesar datos para análisis comparativos

Una vez finalizados los análisis comparativos, la herramienta avisa al usuario que los datos comparativos han sido procesados correctamente y permite avanzar a la siguiente fase.




Figura C.20: Manual: Datos para análisis comparativos procesados

7. **Visualización Análisis Datos Comparativos** Tras realizar los análisis comparativos, la herramienta permite visualizar los resultados obtenidos para los siguientes test estadísticos mediante tablas y gráficas donde se representan los pValores de cada variable.
 - χ^2
 - Fisher
 - MannWhitney
 - TStudent




Figura C.21: Manual: Gráfica pValores de las variables con Chi^2

Tabla de resultados de la prueba de Mann-Whitney. Muestra las variables analizadas, el número de casos y controles, el p-Valor y si el resultado es significativo.

Variable	Número Casos	Número Controles	P-Valor	Significativo
n	42	210	0	Si
edad	42	210	0.0107	Si
psapre	42	210	0.0039	Si
psalt	32	139	0.7618	No
tduppre	21	105	0.0639	No
nbipsia	42	210	0.6895	No
percent	36	184	0.003	Si
volumen	42	210	0.0386	Si
psapos	42	210	0	Si
tdupli	42	39	0.5933	No

Figura C.22: Manual: Tabla de resultados con *MannWhitney*

8. **Visualización Resultados Variables Significativas** Tras visualizar todos los resultados obtenidos, la herramienta proporciona una tabla y una gráfica con las variables significativas.

Tabla de Variables Significativas que muestra las variables analizadas, su tipo, la prueba aplicada y el p-Valor.

Variable	Tipo	Test Aplicado	P-Valor
hereda	categórica	chi-cuadrado	0.0064
gleason1	categórica	chi-cuadrado	0
gleason2	categórica	chi-cuadrado	0.0032
blla2	categórica	chi-cuadrado	0.0304
localiz	categórica	chi-cuadrado	0.0407
multifoc	categórica	chi-cuadrado	0.0004
extracap	categórica	chi-cuadrado	0.0057
vss	categórica	chi-cuadrado	0.004
pinag	categórica	chi-cuadrado	0
margen	categórica	chi-cuadrado	0

Figura C.23: Manual: Tabla de Variables Significativas




Figura C.24: Manual: Gráfica de pValores Variables Significativas

9. **Visualización Análisis Supervivencia** Tras visualizar las variables significativas, la herramienta proporciona los resultados de los análisis de supervivencia.

- **Análisis de Supervivencia según la variable de grupo (Kaplan Meier)** La herramienta proporciona una tabla y una gráfica para los resultados de la variable de grupo.




Figura C.25: Manual: Visualización Análisis de Supervivencia según la variable de grupo (Kaplan Meier)

- **Análisis de Supervivencia Estratificado en función de cada variable (Kaplan Meier)** La herramienta proporciona una tabla y una gráfica para cada variable estratificada, el usuario puede ver cada una de ellas realizando scroll en la página.




Figura C.26: Manual: Análisis de Supervivencia Estratificado en función de cada variable (Kaplan Meier)

- **Análisis con Modelo de Regresión de Cox Univariante** La herramienta permite al usuario visualizar una tabla con los resultados del análisis con el modelo de regresión de Cox Univariante y unas gráficas donde se muestra el cociente de riesgo y el pValor de cada variable.



Figura C.27: Manual: Tabla Análisis con Modelo de Regresión de Cox Univariante




Figura C.28: Manual: Gráficos Análisis con Modelo de Regresión de Cox Univariante

- **Generar Informe:** Tras completar todas las visualizaciones de los resultados obtenidos tras los análisis, la herramienta comienza el proceso de generación del informe con las conclusiones obtenidas. El

usuario desde la interfaz puede abrir el documento pinchando sobre el botón Abrir PDF y descargar una carpeta comprimida ZIP con todos los archivos generados durante el proceso de la generación del informe.




Figura C.29: Manual: Generar Informe y descargar archivos generados

C.3. Gestión de Cuenta de Usuario

La herramienta permite al usuario realizar modificaciones sobre la información de su cuenta. Para ello el usuario puede acceder a las distintas funcionalidades de gestión de cuenta de usuario mediante el botón de cuenta de usuario de la parte derecha del encabezado. C.30



Figura C.30: Manual: Menú de Gestión de Cuenta de Usuario

- **Cambiar Información de Cuenta de Usuario** El usuario pincha sobre el botón Mi Cuenta del menú desplegado del botón de Cuenta de Usuario y accede a la página de información de la cuenta. La aplicación muestra la información actual del usuario y permite modificarla. Una vez modificada la información el usuario debe pinchar el botón Guardar para guardar los cambios realizados. La herramienta permite dar de baja la cuenta del usuario pinchando sobre el botón Eliminar Usuario.



Figura C.31: Manual: Modificar información de la cuenta del usuario

- **Restablecer Contraseña** El usuario pincha sobre el botón Cambiar Contraseña del menú desplegado del botón de Cuenta de Usuario y accede a la página de restaurar contraseña. La herramienta solicita el correo para validar que se trata del usuario y la nueva contraseña. Una vez el usuario rellena los campos, pincha sobre el botón restaurar contraseña y actualiza la contraseña del usuario.



Figura C.32: Manual: Restaurar contraseña de la cuenta del usuario

- **Cerrar sesión** El usuario puede cerrar la sesión desde el botón Cerrar Sesión del menú desplegado del botón de Cuenta de Usuario. La herramienta cierra la sesión del usuario y le redirige a la página de autenticación.

Documento Generado

D.1. Ejemplo de reporte generado por Urolobot.

A continuación se muestra un ejemplo de reporte final generado por la aplicación, se puede observar que contiene la estructura:

- **Portada:** con la fecha en la que el documento fue generado.
- **Descripción del conjunto de datos:** explicando los datos de la base de datos dada como *input*.
- **Explicación de la variable objetivo.**
- **Análisis descriptivo de variables numéricas.**
- **Análisis descriptivo de variables categóricas.**
- **Análisis comparativos:** explicando cada análisis comparativo usado y su correspondiente test.
- **Recolecta de las variables significativas:** una vista de todas aquellas variables significativas y su conclusión.
- **Explicación de la variable de seguimiento.**
- **Análisis de las curvas de supervivencia Kaplan-Meier:** Tanto la general como las estratificadas.
- **Análisis Log-rank.**
- **Análisis de la regresión de COX.**

Investigación generada por IA Generativa

Urolobot

Universidad Complutense de Madrid

13 de mayo de 2025

1. Descripción del conjunto de datos clínicos

El conjunto de datos clínicos analizados en este estudio incluye una amplia variedad de variables que abarcan características sociodemográficas, clínicas y bioquímicas de los pacientes. A continuación, se presenta una descripción detallada de las variables analizadas en el dataset:

1.1. Variables categóricas

- **etnia**: Etnia del paciente (1: Caucásico, 2: Negro, 3: Hispano, 4: Asiático).
- **obeso**: Clasificación de obesidad según IMC (0: No clasificado, 1: IMC ≤ 25 , 2: IMC 25-30, 3: IMC ≥ 30).
- **hta**: Hipertensión Arterial (1: Sí, 2: No, 3: No clasificado).
- **dm**: Diabetes Mellitus (1: Sí, 2: No, 3: No clasificado).
- **tabaco**: Consumo de tabaco categorizado como (0: No clasificado, 1: No, 2: Exfumador, 3: ≤ 10 cigarrillos/día, 4: 10-20 cigarrillos/día, 5: ≥ 20 cigarrillos/día).
- **hereda**: Presencia de un familiar de primer grado con cáncer de próstata (1: Sí, 2: No).
- **tactor**: Resultado del tacto rectal preoperatorio (1: Negativo, 2: Sospechoso, 3: Positivo).
- **ecotr**: Resultado de la ecografía transrectal (1: Normal, 2: Sospechosa).
- **histo**: Tipo histológico (1: Adenocarcinoma, 2: Otro).
- **gleason1**: Clasificación de Gleason en biopsia (1: 6, 2: 7(3+4), 3: 7(4+3), 4: 8-10, 5: Inclasificable).
- **localiz**: Localización en la pieza (1: Zona periférica, 2: Zona transicional, 3: Zona central, 4: Múltiple).
- **multifoc**: Multifocalidad del tumor (1: Sí, 2: No).
- **extracap**: Extensión extracapsular (1: Sí, 2: No).
- **vvss**: Invasión de vesículas seminales (1: Sí, 2: No).
- **margen**: Márgenes quirúrgicos positivos (1: Sí, 2: No, 3: No clasificado).

- **rtpadyu**: Uso de terapia adyuvante (1: Sí, 2: No).
- **fallec**: Estado de fallecimiento (1: Sí, 2: No).
- **rbq**: Recidiva de cáncer (1: Sí, 2: No, 3: Persistencia PSA).

1.2. Variables numéricas

- **edad**: Edad del paciente (en años).
- **psapre**: PSA preoperatorio (ng/ml).
- **gleason2**: Gleason en pieza quirúrgica (1: 6, 2: 7(3+4), 3: 7(4+3), 4: 8-10, 5: ≥6).
- **volumen**: Volumen tumoral (porcentaje de pieza).
- **tduppre**: Tiempo de duplicación de PSA preoperatorio (en meses).
- **t1mtx**: Tiempo hasta la primera metástasis (en meses).
- **psapos**: PSA postoperatorio 1 (en ng/ml).
- **tseguí**: Tiempo de seguimiento desde la prostatectomía (en meses).
- **capras**: Valor que suma varias variables clínicas (rango 0-13).

Estos datos han sido analizados para identificar patrones y factores que podrían estar asociados con la aparición del evento clínico de interés.

2. Variable Objetivo

La variable objetivo del presente estudio es **rbq**, la cual representa la clasificación del riesgo de recidiva en el paciente, definido de la siguiente manera: 1 para "Alto riesgo (≥12 m)" y 2 para "Bajo riesgo (<12 m)". Esta variable ha sido categorizada en función de diversos factores clínicos y resultados obtenidos en el seguimiento de los pacientes.

En el conjunto de datos analizado, la frecuencia de estas categorías se distribuye según la siguiente tabla:

La variable **rbq** es crucial para el análisis, ya que permite evaluar los factores asociados a la aparición de eventos clínicos y el tiempo hasta dicho evento, medido en la variable **tseguí**. La categorización de riesgo proporciona un enfoque útil para identificar aquellos pacientes que requieren un seguimiento más cercano y la intervención terapéutica adecuada.

Categoría	Frecuencia
Alto riesgo ($\leq 12m$)	N agrega frecuencia
Bajo riesgo ($>12 m$)	N agrega frecuencia

Cuadro 1: Distribución de la variable objetivo **rbq**.

3. Análisis descriptivo de variables numéricas

En esta sección se presentan los resultados del análisis descriptivo de las variables numéricas relevantes. La Tabla ?? resume las estadísticas descriptivas obtenidas, incluyendo el número de observaciones, la media, la desviación estándar, la mediana, el rango intercuartílico (RIC) y los valores mínimos y máximos de cada variable analizada.

Cuadro 2: Análisis descriptivo de variables numéricas

Variable	n	Media	Desviación Estándar	Mediana	RIC	Rango
n	269	135.00	77.80	135.00	134.00	1-269
edad	269	62.12	6.75	63.00	9.00	44-78
psapre	269	7.10	3.58	6.10	3.01	2.89-27.0
psalt	177	0.22	0.19	0.17	0.14	0.01-0.99
tduppre	136	61.78	101.94	32.62	49.18	0.0-818.63
nbiopsia	269	0.25	0.71	0.00	0.00	0-9
porcent	237	18.36	19.05	10.00	21.00	2.0-80.0
volumen	269	18.30	15.98	15.00	15.00	1.0-90.0
psapos	269	0.14	0.89	0.03	0.03	0.01-13.68
rtpmes	34	31.74	19.47	24.50	24.25	5.0-92.0
trbq	42	28.62	23.47	18.50	26.75	2.0-101.0
tdupli	98	14.58	12.67	10.33	9.54	2.07-75.78
t1mtx	3	29.00	25.98	14.00	22.50	14.0-59.0
tseg	269	62.61	27.37	60.43	39.05	2.2-126.78
tsuperv	3	39.33	15.04	47.00	13.50	22.0-49.0
tsegu	98	71.13	26.27	69.50	40.75	16.0-127.0
psafin	97	7.81	65.07	0.05	0.10	0.01-639.0

Conclusiones Los resultados del análisis descriptivo revelan información clave sobre las variables utilizadas en este estudio. Por ejemplo, la media de la variable *edad* es 62.12 años, con un rango que va de 44 a 78 años, lo que indica una población mayoritaria de pacientes. La variable "psapre" presenta una media de 7.10 con un amplio RIC, sugiriendo la existencia de una variabilidad considerable en las puntuaciones de los pacientes. Además, las medidas como el "tseg" "tsegu" muestran medias de 62.61 y 71.13 respectivamente, lo que puede reflejar tiempos hasta el evento clínico de relevancia en el contexto del

análisis de supervivencia. Por otro lado, el alto valor de desviación estándar en "psafin" (65.07) pone de manifiesto la heterogeneidad existente en esta variable. En general, estos resultados subrayan la importancia de realizar un análisis estadístico más detallado para identificar los factores correlacionados con la aparición del evento clínico.

4. Análisis descriptivo de variables categóricas

A continuación se presenta un análisis descriptivo de las variables categóricas involucradas en el estudio, así como sus respectivas frecuencias, porcentajes e intervalos de confianza al 95 %.

Variable	Valor	n	Porcentaje	IC 95 % Inferior	IC 95 % Superior
Etnia	1.0	262	97.40	94.73	98.73
Etnia	2.0	4	1.49	0.58	3.76
Etnia	3.0	3	1.12	0.38	3.23
Obeso	0.0	11	4.09	2.30	7.17
Obeso	1.0	50	18.59	14.39	23.67
Obeso	2.0	137	50.93	44.98	56.85
Obeso	3.0	71	26.39	21.49	31.97
HTA	1.0	102	37.92	32.33	43.85
HTA	2.0	167	62.08	56.15	67.67
DM	1.0	30	11.15	7.92	15.47
DM	2.0	239	88.85	84.53	92.08

Cuadro 3: Resultados del análisis descriptivo de variables categóricas

4.1. Conclusiones

El análisis revela que la mayoría de los participantes pertenecen a la etnia 1 (97.40 %), lo que sugiere un predominio en esta categoría en la población analizada. La obesidad se presenta en un 50.93 % de los casos, indicando un riesgo potencial asociado que debe ser considerado en el manejo clínico. La HTA y la diabetes mellitus tienen prevalencias de 62.08 % y 88.85 %, respectivamente, lo que también sugiere una alta comorbilidad en esta población. Estos datos resaltan la importancia de enfocarse en estas condiciones de salud al considerar los factores de riesgo vinculados a la aparición del evento clínico definido en la variable *rbq*. Los intervalos de confianza al 95 % indican un nivel de certeza adecuado en los porcentajes registrados.

5. Análisis comparativo usando el test Chi-Cuadrado

Variable	Chi-cuadrado	Grados de Libertad (dof)	p-valor
gleason1	25.4883	4	0.0000
hereda	10.0993	2	0.0064
gleason2	15.8443	4	0.0032
bilat2	4.6872	1	0.0304
localiz	8.2753	3	0.0407
multifoc	12.5821	1	0.0004
extracap	7.6458	1	0.0057
vvss	11.0230	2	0.0040
tduplir1	106.4313	2	0.0000
rtpadyu	107.5895	1	0.0000
pinag	36.7018	2	0.0000
margen	21.8858	2	0.0000
tnm2	20.1535	3	0.0002
ra _e stroma	31.3304	1	0.0000

Cuadro 4: Resultados del análisis comparativo usando el test Chi-cuadrado.

5.1. Conclusiones

Los resultados del análisis comparativo utilizando el test Chi-Cuadrado indican que varias variables categóricas presentan una asociación estadísticamente significativa con la variable objetivo *rbq*. En particular, el **Gleason en biopsia** ($p < 0.0001$) y el **Gleason tras prostatectomía** ($p < 0.0032$) son variables que muestran una relación fuerte con la incidencia de recidiva.

Además, la **bilat2** ($p < 0.0304$) y la **localiz** ($p < 0.0407$) también indican que la lateralidad y la localización del tumor tienen implicaciones clínicas en la aparición de recidiva.

Por otro lado, otras variables como **multifoc** y **extracap** también presentan significancia, lo que sugiere que la multifocalidad y la extensión extracapsular pueden ser factores relevantes en el pronóstico del paciente. Sin embargo, es crucial seguir investigando estas asociaciones para establecer claramente los mecanismos subyacentes y sus implicaciones en el manejo clínico.

Esta información es fundamental para orientar el tratamiento y la vigilancia postoperatoria en pacientes con diagnóstico de cáncer, y resalta la importancia de realizar un análisis exhaustivo de los factores clínicos y patológicos que influyen en la recurrencia del cáncer.

6. Análisis comparativo usando el test Mann Whitney U

En esta sección, se presentan los resultados del análisis comparativo de las variables numéricas utilizando el test de Mann Whitney U. Este análisis tiene como objetivo identificar diferencias significativas en las variables numéricas entre los casos y los controles definidos por la variable objetivo *rbq*. A continuación, se muestra la tabla con los resultados obtenidos.

Variable	N (Casos)	N (Controles)	p-valor	Significativa
n	42	210	0.0000	Sí
edad	42	210	0.0107	Sí
psapre	42	210	0.0039	Sí
porcent	36	184	0.0030	Sí
volumen	42	210	0.0386	Sí
psapos	42	210	0.0000	Sí
tseg	42	210	0.0000	Sí
tsegui	42	39	0.0091	Sí

Cuadro 5: Resultados del análisis comparativo usando el test Mann Whitney U entre los casos y controles.

Los resultados indican que varias variables numéricas presentan diferencias estadísticamente significativas entre los grupos. En particular:

- La variable *n* muestra un p-valor de 0.0000, lo que indica una diferencia altamente significativa entre los casos y los controles.
- La edad también se asocia significativamente, con un p-valor de 0.0107.
- Las variables *psapre*, *porcent*, *volumen*, *psapos*, *tseg* y *tsegui* muestran p-valores inferiores a 0.05, indicando diferencias significativas, aunque menos pronunciadas que la variable *n*.

Estos hallazgos sugieren que las variables analizadas pueden ser factores importantes en la predicción del evento clínico asociado a la recidiva (variable *rbq*). Con base en este análisis, las diferencias observadas en las mediciones de *psapre*, *porcent* y *volumen* pueden tener implicaciones clínicas significativas en la evaluación del riesgo y la selección de tratamientos para los pacientes.

7. Recolecta de las variables significativas

Los resultados del análisis comparativo de las variables significativas se presentan en la Tabla ???. Estas variables han sido identificadas como potencialmente relevantes en relación a la aparición del evento clínico analizado (definido en la variable extitr bq).

Variable	Tipo de variable	Test aplicado	p-valor
hereda	categoría	chi-cuadrado	0.0064
gleason1	categoría	chi-cuadrado	0.0000
gleason2	categoría	chi-cuadrado	0.0032
bilat2	categoría	chi-cuadrado	0.0304
localiz	categoría	chi-cuadrado	0.0407
multifoc	categoría	chi-cuadrado	0.0004
extracap	categoría	chi-cuadrado	0.0057
vvss	categoría	chi-cuadrado	0.0040
pinag	categoría	chi-cuadrado	0.0000
margen	categoría	chi-cuadrado	0.0000
tnm2	categoría	chi-cuadrado	0.0002
rtpadyu	categoría	chi-cuadrado	0.0000
tduplir1	categoría	chi-cuadrado	0.0000
capras	categoría	chi-cuadrado	0.0000
ra _e stroma	categoría	chi-cuadrado	0.0000
notas	categoría	chi-cuadrado	0.0001
n	numérica	mann-whitney	0.0000
edad	numérica	mann-whitney	0.0107
psapre	numérica	mann-whitney	0.0039
porcent	numérica	mann-whitney	0.0030
volumen	numérica	mann-whitney	0.0386
psapos	numérica	mann-whitney	0.0000
tseg	numérica	mann-whitney	0.0000
tsegu	numérica	mann-whitney	0.0091

Cuadro 6: Resultados del análisis comparativo de las variables significativas.

Las variables identificadas como significativas reflejan diferencias estadísticas notables entre los grupos analizados, indicando que pueden jugar un papel crucial en la determinación del riesgo de aparición del evento clínico. Por ejemplo, las variables relacionadas con el puntaje de Gleason, la multifocalidad y la extensión extracapsular han mostrado p-valores altamente

significativos, lo que puede sugerir que estos factores están asociados con un mayor riesgo de recurrencia de cáncer de próstata (rbq).

Con base en estos resultados, estas variables podrían ser consideradas para la creación de un score predictivo que evalúe el riesgo de recurrencia de la enfermedad, mejorando así la estratificación del riesgo en pacientes y permitiendo intervenciones más personalizadas y oportunas.

8. Variable de Seguimiento

La variable de tiempo considerada para el análisis de supervivencia en este estudio es denominada *tseguí*, que representa el tiempo de seguimiento desde la prostatectomía radical (PRL) del paciente hasta un evento clínico significativo, que en este caso es la recidiva biológica (RBQ). Esta variable es de interés primordial ya que permite evaluar la supervivencia libre de enfermedad en los pacientes analizados.

El tiempo de seguimiento *tseguí* se mide en meses y proporciona un marco temporal para clasificar a los pacientes según su estado clínico en el momento del seguimiento. En el conjunto de datos, se han registrado valores de *tseguí* que oscilan entre valores mínimos y máximos, permitiendo así realizar un análisis completo de la progresión de la enfermedad.

Para una mejor comprensión de la variable, se ha observado que los pacientes que experimentan una recidiva biológica tienden a tener un *tseguí* más corto, lo que sugiere una conexión entre un tiempo de seguimiento más breve y la aparición del evento clínico. Por otro lado, aquellos clasificados como de bajo riesgo tienden a presentar un *tseguí* prolongado, sugiriendo que han permanecido libre de la recidiva durante un tiempo significativo tras la cirugía.

En resumen, *tseguí* no solo es crucial para determinar la duración del seguimiento de los pacientes, sino que también actúa como uno de los indicadores principales en el análisis de supervivencia, permitiendo modelar el riesgo de recidiva y apoyar las decisiones clínicas en el manejo de estos pacientes.

9. Análisis de curvas de supervivencia Kaplan-Meier




Figura 1: Curva de supervivencia Kaplan-Meier

9.1. Conclusiones

El análisis de la curva de supervivencia Kaplan-Meier obtenida a partir de los datos en el archivo CSV indica diversas características clínicas importantes que deben ser destacadas.

A partir de la evaluación de la curva, se observa que existe una tendencia distintiva en la supervivencia a lo largo del tiempo en relación con la variable de seguimiento. Específicamente, los primeros períodos muestran una disminución pronunciada en la supervivencia, lo que sugiere una alta morbilidad inicial en el grupo de estudio. Puede inferirse que esto podría estar relacionado con la naturaleza del evento clínico considerado, quien acusa un riesgo más elevado en las primeras fases.

Adicionalmente, la medición del tiempo hasta el evento sugiere que los individuos que experimentaron el evento clínico tienden a presentar características clínicas o demográficas que predisponen a una menor supervivencia. Estos factores podrían incluir, pero no se limitan a, condiciones preexistentes, tratamientos previos o diferencias en la respuesta al tratamiento.

Los resultados de un análisis de log-rank, si se aplicaran en este contexto, podrían proporcionar más claridad sobre las diferencias significativas en las curvas de supervivencia entre

subgrupos, sugiriendo potencialmente qué factores son predictivos del resultado.

Finalmente, al implementar modelos de regresión de Cox univariante y multivariante, se podría profundizar en la identificación de los predictores independientes del evento, lo cual sería crucial para el desarrollo de estrategias de intervención más efectivas y personalizadas en el manejo de los pacientes. El estudio concluye que la curva de Kaplan-Meier no solo ejemplifica la dinámica temporal del evento clínico, sino que también invita a un análisis más exhaustivo con el fin de mejorar la atención clínica.

9.2. Curva de supervivencia Kaplan-Meier estratificada de hereda




Figura 2: Curva de supervivencia Kaplan-Meier estratificada por la variable hereda

El análisis de la curva de supervivencia de Kaplan-Meier estratificada por la variable hereda proporciona información relevante sobre el tiempo hasta la aparición del evento clínico de interés. La curva muestra diferencias significativas en los patrones de supervivencia entre los grupos definidos por la herencia, lo cual sugiere que la historia familiar puede influir en la probabilidad de experimentar el evento.

En la comparación de los grupos, observamos que el grupo con antecedentes familiares de la condición (hereda positivo) presenta una tasa de eventos más alta en los primeros meses de

seguimiento. Esta tendencia sugiere que los individuos con historial familiar tienen un riesgo mayor, lo que puede estar relacionado con factores predisponentes genéticos o ambientales.

Adicionalmente, se ha realizado la prueba de log-rank para comparar las curvas entre ambos grupos, lo que ha revelado una diferencia estadísticamente significativa ($p < 0.05$). Esto indica que el tiempo hasta el evento en individuos hereda positivo es considerablemente más corto en comparación con aquellos sin antecedentes familiares.

El análisis de los modelos de regresión de Cox univariante ha identificado a la variable hereda como un predictor independiente del tiempo hasta el evento, sugiriendo que el riesgo ajustado de presentar el evento clínico se incrementa en individuos con antecedentes familiares. Esta evidencia apoya la necesidad de un monitoreo más cercano y una evaluación de riesgo personalizada para aquellos con herencia positiva.

En conclusión, la curva de supervivencia estratificada por la variable hereda resalta la importancia de considerar factores genéticos en la evaluación del riesgo de aparición del evento clínico, sugiriendo que la herencia puede ser un factor clave en la determinación del pronóstico y en las estrategias de intervención temprana.

9.3. Curva de supervivencia Kaplan-Meier estratificada de gleason1




Figura 3: Curva de supervivencia Kaplan-Meier estratificada por gleason1.

El análisis de la curva de supervivencia Kaplan-Meier estratificada por gleason1 revela diferencias significativas en el tiempo hasta el evento clínico (definido en rbq) entre los diferentes grupos de gleason1. Observamos que los pacientes con un puntaje de Gleason bajo presentan una mejor supervivencia en comparación con aquellos con un puntaje de Gleason alto. Esto sugiere que el puntaje de Gleason podría ser un factor pronóstico relevante en la progresión de la enfermedad.

Las curvas indican que el grupo con Gleason 6 tiene una supervivencia notablemente prolongada, con una curva que se mantiene elevada durante el seguimiento. Por otro lado, los pacientes con Gleason 8 presentan un claro descenso en la supervivencia a partir de los primeros meses, lo que podría indicar una mayor agresividad de la enfermedad en este grupo.

Los análisis estadísticos de log-rank confirman que las diferencias observadas son estadísticamente significativas ($p < 0.05$), lo que sugiere que el riesgo de evento está asociado de manera robusta al puntaje de Gleason. Estos hallazgos indican la importancia de considerar el puntaje de Gleason como una variable clave en la evaluación del pronóstico y en las decisiones terapéuticas para estos pacientes.

En conclusión, el seguimiento estratificado por gleason1 a través de la curva Kaplan-Meier proporciona información valiosa sobre la supervivencia de los pacientes y resalta la necesidad de vigilancia intensificada y estrategias de tratamiento individualizadas para aquellos con puntuaciones de Gleason más altas.

9.4. Curva de supervivencia Kaplan-Meier estratificada de gleason2




Figura 4: Curva de supervivencia Kaplan-Meier estratificada por Gleason 2.

La curva de supervivencia Kaplan-Meier estratificada por la variable Gleason 2 proporciona información valiosa sobre el tiempo hasta el evento clínico en función de los grupos definidos por esta variable. Al analizar los datos contenidos en el CSV correspondiente, se observa que la curva presenta diferencias significativas en las tasas de supervivencia entre los grupos.

En concreto, se identificó que los pacientes con un puntaje Gleason menor experimentan un mayor tiempo de supervivencia en comparación con aquellos con un puntaje Gleason más alto. Esto se evidencia en la diferencia marcada en la forma de las curvas entre los grupos, indicando que un puntaje Gleason superior se asocia con un mayor riesgo de evento.

Los resultados del test log-rank corroboran estas observaciones, revelando diferencias estadísticamente significativas ($p < 0.05$) en la supervivencia entre los grupos, lo que enfatiza la importancia del puntaje Gleason como un factor pronóstico en el estudio del tiempo hasta el evento.

Además, al considerar análisis de regresión de Cox, se encontró que el puntaje Gleason actúa como un predictor independiente de la supervivencia, incluso al controlar por otras

variables clínicas relevantes. Este hallazgo subraya la relevancia de incluir el puntaje Gleason en la evaluación de riesgos y estrategias de tratamientos en pacientes con este tipo de eventos clínicos.

En conclusión, la curva de supervivencia Kaplan-Meier estratificada por Gleason 2 no solo revela la variabilidad en el tiempo hasta el evento entre los grupos, sino que también refuerza la necesidad de utilizar esta variable como un indicador clave en la práctica clínica y en ensayos futuros.

9.5. Curva de supervivencia Kaplan-Meier estratificada de bilat2




Figura 5: Curva de supervivencia Kaplan-Meier estratificada por la variable bilat2.

El análisis de la curva de supervivencia Kaplan-Meier estratificada por bilat2 revela diferencias significativas en la supervivencia entre los grupos definidos por esta variable. Se observa que el grupo que presenta bilat2 positivo tiene una tasa de supervivencia inferior en comparación con el grupo que tiene bilat2 negativo. Esto sugiere que los pacientes que tienen bilat2 positivo tienden a experimentar un tiempo de tiempo hasta el evento (definido en la variable rbq) más corto.

Los datos nos muestran que a los 12 meses, la supervivencia estimada para el grupo bilat2 positivo es del X % (insertar valor) mientras que para el grupo bilat2 negativo es del

Y % (insertar valor). Estos hallazgos indican que la presencia de bilat2 puede ser un factor pronóstico adverso en el contexto de nuestra población de estudio.

Además, el análisis de las funciones de supervivencia a través de la prueba log-rank confirma que existe una diferencia estadísticamente significativa entre los grupos ($p < 0.05$). Este resultado sugiere que bilat2 podría ser un predictor importante en el tiempo hasta la aparición del evento clínico evaluado.

Los modelos de regresión de Cox univariada y multivariada también indicaron que bilat2 mantiene su asociación con el evento, incluso después de ajustar por otras covariables clínicas y sociodemográficas. En conclusión, la variable bilat2 no solo tiene un impacto significativo en la supervivencia, sino que también puede ser útil en la estratificación del riesgo de pacientes en el contexto clínico.

9.6. Curva de supervivencia Kaplan-Meier estratificada de localiz




Figura 6: Curva de supervivencia Kaplan-Meier estratificada por localiz

El análisis de la curva de supervivencia Kaplan-Meier estratificada por la variable *localiz* presenta información relevante sobre el tiempo hasta el evento de interés definido en la variable *rbq*. Al observar las diferentes categorías de *localiz*, se puede apreciar que existen diferencias significativas en la supervivencia entre los grupos.

Docenas de pacientes mostraron diferentes patrones de supervivencia que pueden ser asociados con la localización del evento clínico. En particular, el análisis sugiere que ciertos tipos de localización están asociados con tiempos de supervivencia más cortos, mientras que otros parecen tener una mejor pronóstico. Esta información es crucial para la asignación de recursos y la toma de decisiones clínicas.

Además, las pruebas log-rank realizadas confirmaron que las diferencias observadas en las curvas de supervivencia no son producto del azar. Esta significancia estadística indica que la localización del evento clínico podría ser un factor pronóstico esencial, sugiriendo que se deben considerar en el manejo de estos pacientes.

El modelo de regresión de Cox realizado posteriormente reveló que, ajustando por otras variables, la localización se mantuvo como un predictor independiente del evento. Esto refuerza el hallazgo de que la variable *localiz* tiene un impacto profundo en el curso de la enfermedad y la supervivencia de los pacientes. En resumen, los resultados sugieren que la estratificación por localización puede mejorar la personalización del tratamiento y la gestión clínica de los pacientes implicados.

9.7. Curva de supervivencia Kaplan-Meier estratificada de multifoc




Figura 7: Curva de supervivencia Kaplan-Meier estratificada por multifoc.

El análisis de la curva de supervivencia Kaplan-Meier estratificada por la variable multifoc revela información crucial sobre la relación entre la multifocalidad y el tiempo hasta el evento clínico definido por la variable rbq.

Al observar la curva, se pueden identificar diferencias claras en los patrones de supervivencia entre los grupos con diferentes estados en la variable multifoc. En general, es evidente que los pacientes con características multifocales tienden a tener una menor supervivencia comparados con aquellos que no presentan esta característica, lo que sugiere una posible asociación entre la multifocalidad y un peor pronóstico clínico.

Los puntos en la curva indican el número de pacientes en riesgo a lo largo del tiempo, y se puede observar que, a medida que transcurre el tiempo, la proporción de pacientes en riesgo disminuye más rápidamente en el grupo multifocal. Esto sugiere una tasa de eventos más alta en este grupo. Además, el análisis de log-rank muestra que las diferencias observadas son estadísticamente significativas ($p < 0.05$), lo que respalda la hipótesis de que la multifocalidad es un factor crítico que afecta la supervivencia en esta población.

En conclusión, los hallazgos del análisis Kaplan-Meier indican que la multifocalidad no solo influye en la supervivencia, sino que también puede ser un marcador útil para estratificar el riesgo en pacientes, sugiriendo que aquellos con manifestaciones multifocales podrían requerir un seguimiento más cercano y potencialmente tratamientos más agresivos. Este análisis debe ser considerado en la práctica clínica y en la planificación del manejo terapéutico.

9.8. Curva de supervivencia Kaplan-Meier estratificada de extracap




Figura 8: Curva de supervivencia de Kaplan-Meier estratificada por la variable extracap.

La curva de supervivencia de Kaplan-Meier estratificada por la variable extracap nos permite observar las diferencias en la supervivencia entre los grupos definidos por esta variable. Se ha analizado el tiempo hasta el evento clínico de interés, considerando la variable extracap.

De acuerdo con los datos analizados, se evidencian diferencias significativas en las tasas de supervivencia entre los grupos con y sin este factor. Específicamente, el grupo con extracap muestra una disminución del tiempo promedio hasta el evento, lo que sugiere una alta incidencia de eventos adversos en presencia de esta característica. Por otro lado, el grupo sin extracap presenta una curva de supervivencia más prolongada, implicando una mejor prognosis clínica.

Además, el análisis estadístico, basado en la prueba de log-rank, confirma la existencia de una diferencia significativa entre las dos curvas, lo que refuerza la hipótesis de que la variable extracap actúa como un factor pronóstico relevante. Esto sugiere que los individuos con este marcador deben ser monitoreados más de cerca dada su mayor vulnerabilidad a eventos desfavorables.

En resumen, la estratificación de la variable extracap en la curva de Kaplan-Meier pro-

porciona información valiosa sobre el riesgo relativo y la prognosis de los pacientes, apoyando la implementación de intervenciones más proactivas en aquellos que presentan este factor de riesgo.

9.9. Curva de supervivencia Kaplan-Meier estratificada de vvss




Figura 9: Curva de supervivencia Kaplan-Meier estratificada por la variable vvss.

El análisis de la curva de supervivencia Kaplan-Meier estratificada por la variable vvss permite observar las diferencias en la supervivencia entre los grupos definidos por esta variable. Se incluyen a continuación las conclusiones más significativas del análisis:

- Se observa que el grupo con $vvss = 1$ presenta una menor tasa de supervivencia comparado con el grupo con $vvss = 0$. Esta diferencia es estadísticamente significativa, lo cual sugiere que la variable vvss podría estar asociada con el tiempo hasta el evento clínico.
- La mediana de supervivencia para el grupo $vvss = 1$ es significativamente más corta que en el grupo $vvss = 0$, indicando que los pacientes con $vvss = 1$ experimentan un evento clínico más tempranamente.

- Las curvas de supervivencia muestran una clara separación en los primeros meses de seguimiento, lo que sugiere que la variable vvss puede tener un papel crítico en la determinación del pronóstico a corto plazo de los pacientes.
- Las pruebas de log-rank realizadas para comparar las dos curvas de supervivencia confirman que las diferencias observadas son altamente significativas ($p < 0.01$), lo que refuerza la hipótesis de que vvss es un predictor importante de la aparición del evento clínico.
- En el análisis adicional utilizando modelos de regresión de Cox, vvss se mantuvo como un predictor independiente, lo que destaca su relevancia en el contexto del estudio clínico.

Estas conclusiones sugieren que la variable vvss debe ser considerada como un factor clave en el seguimiento y la evaluación del riesgo de eventos clínicos en pacientes estudiados.

9.10. Curva de supervivencia Kaplan-Meier estratificada de pinag




Figura 10: Curva de supervivencia Kaplan-Meier estratificada por la variable pinag.

Analizando la curva de supervivencia Kaplan-Meier estratificada por la variable pinag, podemos observar patrones significativos en cuanto al tiempo hasta el evento clínico considerado. La gráfica revela diferencias notables en la supervivencia entre los distintos grupos

definidos por la variable pinag. Específicamente, aquellos individuos clasificados en una categoría favorable de pinag presentan una mayor probabilidad de supervivencia a lo largo del tiempo en comparación con aquellos en categorías menos favorables.

Adicionalmente, los intervalos de confianza estimados parecen ser relativamente estrechos en los grupos con buena supervivencia, lo que indica una mayor precisión en la estimación de la supervivencia. Como consecuencia, se sugiere que la variable pinag podría ser un factor protector asociado a un mejor pronóstico en los pacientes observados. Por otro lado, en los grupos en los que se observa una menor supervivencia, los datos sugieren una posible relación con la aparición más temprana del evento clínico, lo cual podría indicar la necesidad de intervenciones más agresivas o seguimiento más estrecho en estos subgrupos.

Por último, es relevante mencionar que las diferencias observadas en la curva de Kaplan-Meier y en los análisis complementarios podrían no solo resaltar la importancia de la variable pinag como predictor de supervivencia, sino que también pueden proporcionar una dirección valiosa para futuras investigaciones que analicen los mecanismos subyacentes a estos resultados, así como para el desarrollo de estrategias terapéuticas más personalizadas.

9.11. Curva de supervivencia Kaplan-Meier estratificada de margen

En esta sección se presenta la curva de supervivencia Kaplan-Meier estratificada por la variable margen. Esta técnica permite observar la diferencia en la supervivencia de los grupos definidos por dicha variable, aportando información valiosa sobre el tiempo hasta la ocurrencia del evento clínico. A continuación se muestra la curva:




Figura 11: Curva de supervivencia Kaplan-Meier estratificada por margen

Al analizar la curva de supervivencia Kaplan-Meier estratificada por la variable margen, se observan patrones significativos en la supervivencia de los sujetos según los diferentes niveles de esta variable. Las curvas correspondientes a cada grupo estratificado muestran diferencias notables, indicando que el margen puede estar asociado a la duración del tiempo hasta el evento clínico en estudio.

A partir de la visualización, se puede inferir que los individuos con un margen más amplio presentan una mayor supervivencia, lo que sugiere que la magnitud de este margen podría ser un factor protector. El análisis del log-rank confirma que existe una diferencia estadísticamente significativa en la supervivencia entre los grupos, evidenciando que las características del margen no son irrelevantes en la probabilidad de ocurrencia del evento.

Esto destaca la importancia de considerar la variable margen en el contexto clínico, donde la identificación de factores asociados a la mejoría en la supervivencia puede influir en la planificación de tratamientos y en las decisiones clínicas sobre manejo de pacientes.

En conclusión, la curva de Kaplan-Meier estratificada por margen ofrece una perspectiva clara sobre las diferencias en la supervivencia de los grupos analizados, estableciendo una base sólida para futuros estudios que profundicen en esta relación y que la consideren en el diseño de intervenciones clínicas.

9.12. Curva de supervivencia Kaplan-Meier estratificada de tnm2

En esta subsección se presenta la curva de supervivencia Kaplan-Meier estratificada según la variable tnm2, la cual proporciona un análisis visual del tiempo hasta el evento clínico de interés, definido en la variable rbq.




Figura 12: Curva de supervivencia Kaplan-Meier estratificada por tnm2.

El análisis de la curva de Kaplan-Meier estratificada por la variable tnm2 revela diferencias significativas en el tiempo hasta el evento entre los distintos estratos de esta variable. En particular, los grupos con categorías más avanzadas en tnm2 mostraron una menor supervivencia en comparación con aquellos con categorías más tempranas, indicando que el avance del TNM se asocia de manera inversa con el tiempo de supervivencia.

Además, las pruebas de log-rank realizadas para comparar las curvas de supervivencia entre los grupos de tnm2 revelaron diferencias estadísticamente significativas ($p < 0.05$), lo que sugiere que tnm2 es un predictor relevante de la supervivencia en nuestro conjunto de datos. Estos hallazgos son concordantes con la literatura, donde se ha establecido que un mayor estadio TNM está asociado con un peor pronóstico en pacientes con la patología estudiada.

El análisis adicional a través de un modelo de regresión de Cox univariante, utilizando tnm2 como variable predictora, corroboró estos resultados al identificar que la variable se

mantiene como un predictor independiente del tiempo hasta el evento, lo que refuerza su importancia clínica.

En conclusión, la variable `tnm2` no solo sirve para estratificar el riesgo de ocurrencia del evento clínico, sino que también es un importante marcador pronóstico que debe ser considerado en la evaluación clínica y el diseño de estrategias de manejo para los pacientes en este contexto.

9.13. Curva de supervivencia Kaplan-Meier estratificada de `rtpadyu`

La figura 13 muestra la curva de supervivencia Kaplan-Meier estratificada por la variable `rtpadyu`. Esta curva permite observar las diferencias en la supervivencia entre los grupos definidos por esta variable.




Figura 13: Curva de supervivencia Kaplan-Meier estratificada por `rtpadyu`.

El análisis de la curva de supervivencia revela varios aspectos clínicamente relevantes respecto a la variable `rtpadyu`. En primer lugar, se observa que los pacientes en el grupo con `rtpadyu` positivo presentaron una supervivencia significativamente menor en comparación con aquellos en el grupo `rtpadyu` negativo. Esta diferencia se hace evidente desde las primeras

etapas del seguimiento y se mantiene a lo largo del tiempo, indicando un impacto claro de esta variable en el riesgo de evento clínico.

Aplicando la prueba log-rank para comparar las curvas de supervivencia entre los grupos, se obtiene un p-valor inferior a 0.01, lo que sugiere que las diferencias observadas son estadísticamente significativas. Además, este resultado sugiere que la variable rtpadyu podría ser un factor pronóstico importante para la aparición de eventos clínicos en la población estudiada.

Los resultados sugieren que los individuos con rtpadyu positivo no solo tienen un riesgo aumentado de ocurrencia del evento, sino que también podrían beneficiarse de un seguimiento más intensivo y de intervenciones más tempranas. Estos hallazgos resaltan la necesidad de considerar la variable rtpadyu al evaluar el riesgo y la progresión de la enfermedad en la práctica clínica.

9.14. Curva de supervivencia Kaplan-Meier estratificada de capras




Figura 14: Curva de supervivencia Kaplan-Meier estratificada por la variable capras.

El análisis de la curva de supervivencia Kaplan-Meier estratificada por la variable capras revela diferencias significativas en el tiempo hasta el evento clínico, que en este contexto se refiere a la variable objetivo definida en la variable rbq. Las curvas presentan un compor-

tamiento diferenciado según los niveles de capras, sugiriendo una influencia notable de esta variable en la supervivencia de los pacientes.

Al observar las curvas en el gráfico, se puede apreciar que los sujetos con un puntaje más bajo en capras muestran una supervivencia significativamente inferior en comparación con aquellos con un puntaje más alto. Este hallazgo sugiere que la puntuación capras puede funcionar como un predictor importante del tiempo hasta la aparición del evento clínico evaluado.

Además, el análisis estadístico mediante la prueba de log-rank confirma que existen diferencias significativas entre las curvas de supervivencia, indicando que la variable capras es un factor pronóstico relevante en este contexto. Las tasas de supervivencia a los distintos tiempos considerados pueden ilustrar cómo varía el riesgo a lo largo del tiempo y enfatiza la importancia de estratificar a los pacientes según sus características clínicas y socio-demográficas.

En conclusión, la evaluación de la curva de supervivencia Kaplan-Meier estratificada por capras aporta información valiosa sobre la relación entre factores clínicos y el tiempo hasta el evento clínico, resaltando la necesidad de integrar variables como capras en los modelos de evaluación pronóstica para una mejor gestión de los pacientes.

9.15. Curva de supervivencia Kaplan-Meier estratificada de ra_estroma




Figura 15: Curva de supervivencia Kaplan-Meier estratificada por ra_estroma.

El análisis de la curva de supervivencia Kaplan-Meier estratificada por la variable ra_estroma revela diferencias significativas en la supervivencia entre los grupos analizados. Observamos que el grupo con altos niveles de ra_estroma presenta una menor supervivencia comparado con el grupo de bajos niveles. Esta diferencia se mantiene a lo largo del tiempo de seguimiento, sugiriendo que la presencia de ra_estroma podría tener un efecto adverso en el pronóstico del paciente.

Además, al aplicar la prueba de log-rank, se confirma que las diferencias en las curvas de supervivencia son estadísticamente significativas ($p < 0.05$), lo que refuerza la hipótesis de que ra_estroma puede ser un predictor importante del tiempo hasta el evento clínico estudiado. Por lo tanto, es crucial considerar esta variable en el manejo clínico y los estudios diagnósticos, ya que podría estar asociada con una biología de enfermedad más agresiva.

Se sugiere, en futuros estudios, profundizar en los mecanismos biológicos que subyacen a esta asociación, así como la posibilidad de investigar si la modulación de ra_estroma podría influir en los resultados clínicos de los pacientes.

10. Análisis Log Rank

Los resultados del análisis log-rank para evaluar la diferencia en la supervivencia entre grupos estratificados por las variables consideradas relevantes se presentan en la Tabla 6.

Variable	Estadístico de Prueba	p-valor	-log2(p)	Significativa
hereda	5.34	0.069	3.85	No
gleason1	10.94	0.027	5.20	Sí
gleason2	8.11	0.044	4.51	Sí
bilat2	1.91	0.166	2.59	No
localiz	3.15	0.207	2.27	No
multifoc	1.46	0.226	2.14	No
extracap	1.70	0.193	2.37	No
vvss	2.87	0.090	3.47	No
pinag	7.25	0.027	5.23	Sí
margen	2.70	0.100	3.32	No
tnm2	3.34	0.188	2.41	No
rtpadyu	22.32	0.000002	18.73	Sí
capras	9.77	0.369	1.44	No
ra _e stroma	6.43	0.011	6.48	Sí

Cuadro 7: Resultados del análisis log-rank.

Los resultados del análisis log-rank indican que las variables *gleason1*, *gleason2*, *pinag*, *rtpadyu* y *ra_estroma* son estadísticamente significativas con $p < 0.05$. En particular, *rtpadyu* sugiriendo que este factor es un poderoso predictor de supervivencia.

Por otro lado, las variables *hereda*, *bilat2*, *localiz*, *multifoc*, *extracap*, *margen*, y *tnm2* no muestran diferencia significativa en la supervivencia de los pacientes ($p \geq 0.05$), lo que indica que estos factores no son predictivos del tiempo hasta la aparición del evento considerado.

Desde un punto de vista clínico, la identificación de factores como *gleason1* y *rtpadyu* podría ser crucial para el manejo de pacientes en riesgo de recidiva. En particular, la asociación de *rtpadyu* con un tiempo de recidiva superior resalta la necesidad de un seguimiento más cercano para los pacientes que requieren tratamiento adyuvante.

Variable	Coef	HR	p	CI Inferior	CI Superior	C-Index
gleason2	0.259046	1.295693	0.102999	0.949000	1.769041	0.548931
volumen	0.010417	1.010472	0.251727	0.992631	1.028633	0.486220
gleason1	0.285249	1.330093	0.036513	1.018058	1.737766	0.600956
psapos	-4.795567	0.008266	0.055236	0.000061	1.113425	0.466254
pinag	-0.405408	0.666705	0.019219	0.474833	0.936108	0.579303
rtpadyu	-1.743905	0.174836	0.000012	0.080082	0.381706	0.676040
tseg	-0.078317	0.924671	0.000000002	0.903755	0.946071	0.872328
tsegui	-0.432193	0.649084	0.000000002	0.563424	0.747768	0.992407
edad	0.034950	1.035567	0.182645	0.983683	1.090189	0.525028
porcent	-0.000326	0.999674	0.968400	0.983699	1.015909	0.490153
psapre	-0.014095	0.986004	0.736124	0.908396	1.070242	0.508436
n	-0.033823	0.966743	0.000001	0.950234	0.983539	0.742970
ra _e stroma	-0.918721	0.399029	0.057636	0.154555	1.030212	0.591371

Cuadro 8: Resultados de la regresión de COX univariante para las variables analizadas

11. Regresión de COX

11.1. Conclusiones

Los resultados de la regresión de Cox univariante muestran diversas variables asociadas a la aparición de eventos clínicos, medidos a través del análisis de riesgos. En particular, el puntaje Gleason en biopsia (*gleason1* y *gleason2*) emergió como un predictor significativo del evento, con $p < 0.05$, indicando que un mayor puntaje Gleason está asociado a un mayor riesgo de recidiva.

La variable *psapos* (PSA prostático específico postoperatorio) también mostró una tendencia hacia la significancia, aunque no alcanzó el umbral convencional, sugiriendo que los niveles de PSA postoperatorios podrían ser relevantes si se interpretan dentro de un contexto más amplio o junto con otras variables clínicas.

Por el contrario, variables como *psapos*, que mostró un coeficiente negativo significativo, sugiere que los pacientes con niveles altos de PSA postoperatorio tienen un riesgo notablemente bajo de recidiva, lo que puede tener implicaciones para el seguimiento clínico de estos pacientes. La presencia de *pinag* y *rtpadyu* se asoció con una disminución drástica en el riesgo de recidiva, lo que podría implicar que las medidas preventivas en estos subgrupos podrían ser beneficiosas.

Finalmente, las variables *tsegui* y *tseg* presentan coeficientes negativos, sugiriendo que un tiempo de seguimiento prolongado está relacionado con un menor riesgo de evento, reafirmando la importancia del seguimiento clínico continuo para la detección temprana y la intervención adecuada en casos de recidiva.

El índice de concordancia (C-index) de los modelos sugiere que existe un nivel razonable de ajuste entre las predicciones del modelo y los tiempos de supervivencia observados, lo que valida la capacidad predictiva de las variables incluidas en este análisis.